

Fundamentos de Estatística Aplicada

Licenciatura em Engenharia de Telecomunicações e Informática

Lino Costa

Departamento de Produção e Sistemas
Escola de Engenharia
lac@dps.uminho.pt

Revisto em 2021/2022

Sumário

1. dados categoriais
2. probabilidades completamente especificadas
 - hipóteses
 - frequências esperadas
 - estatística de qui-quadrado
3. probabilidades não completamente especificadas
 - estimação de parâmetros
 - hipóteses
 - frequências esperadas
 - estatística de qui-quadrado
4. Teste de independência
 - tabela de contingência
 - hipóteses
 - frequências esperadas
 - estatística de qui-quadrado

Testes de bom ajuste

Dados categoriais

Uma variável categórica é usada para representar um conjunto de categorias. Dois tipos de variáveis categóricas podem ser definidos:

- **variável nominal** - a medição apenas define a que classe a unidade pertence, em relação àquela propriedade (e.g., sexo)
- **variável ordinal** - a medição também esclarece quando uma unidade tem mais da propriedade do que outra unidade (e.g., opinião)

Classe	1	2	...	k
Frequência	f_1	f_2	...	f_k

Teste de bom ajuste

A distribuição da variável categórica é desconhecida. O objetivo do teste de bom ajuste é testar se uma determinada distribuição se ajusta à população com base nos dados de uma grande amostra ($n \geq 30$).

Testes de bom ajuste

Probabilidades completamente especificadas

A distribuição está completamente especificada na hipótese nula para as k classes, sem haver necessidade de estimar parâmetros.

$$\begin{aligned} H_0 : p_1 &= p_{10}, p_2 = p_{20}, \dots, p_k = p_{k0} & (p_{10} + p_{20} + \dots + p_{k0} &= 1) \\ H_1 : p_i &\neq p_{i0} & \exists i \in \{1, \dots, k\} \end{aligned}$$

Estatística de teste

$$E.T. : Q = \sum_{i=1}^k \frac{(f_i - e_i)^2}{e_i} \text{ onde } f_i \text{ são as frequências observadas e } e_i = np_i$$

são as frequências esperadas. Se a frequência esperada de uma classe i for pequena ($e_i < 5$), a classe deve ser agrupada com a classe adjacente e o número de classes k reduzido de uma unidade.

Região de rejeição

$$R.R. : Q > \chi_{\alpha, k-1}^2 \text{ onde } \alpha \text{ é o nível de significância.}$$

Testes de bom ajuste

Exemplo 1

Em 2003, o número de AVCs masculinos no concelho de Braga foram os reportados na tabela, de acordo com a estação do ano. Teste se as probabilidades de ocorrência de AVCs é idêntica nas quatro estações do ano ($\alpha = 0.05$).

Estação do ano	Primavera	Verão	Outono	Inverno
Número de AVCs	64	81	39	28

- Estação do ano é uma variável categórica nominal com $k = 4$ classes
- Teste do bom ajuste para testar se as probabilidades de AVCs são idênticas (probabilidades completamente especificadas), i.e.,

$$H_0 : p_1 = 1/4, p_2 = 1/4, p_3 = 1/4, p_4 = 1/4 \quad H_1 : \neg H_0$$

Estação do ano	Primavera	Verão	Outono	Inverno	$\sum$
f_i	64	81	39	28	$212 = n$
p_i	1/4	1/4	1/4	1/4	1
$e_i = np_i$	53	53	53	53	212
$\frac{(f_i - e_i)^2}{e_i}$	2.28	14.79	3.70	11.79	$32.56 = Q$

- $E.T. : Q = \sum_{i=1}^4 \frac{(f_i - e_i)^2}{e_i} = 32.56$
- $R.R. : Q > \chi_{0.05,3}^2 \Leftrightarrow Q > 7.81$ (Tabela 7)
- Rejeita-se H_0 para $\alpha = 0.05$, pelo que a probabilidade de AVCs não é idêntica nas quatro estações do ano.

Testes de bom ajuste

Probabilidades não completamente especificadas

A distribuição não está completamente especificada na hipótese nula para as k classes, havendo a necessidade de estimar parâmetros com base nos dados.

H_0 : as probabilidades das classes provêm de uma distribuição da família...

H_1 : as probabilidades das classes não provêm de uma distribuição da família...

Estatística de teste

$E.T. : Q = \sum_{i=1}^k \frac{(f_i - e_i)^2}{e_i}$ onde f_i são as frequências observadas e $e_i = np_i$

são as frequências esperadas. Se a frequência esperada de uma classe i for pequena ($e_i < 5$), a classe deve ser agrupada com a classe adjacente e o número de classes k reduzido de uma unidade.

Região de rejeição

$R.R. : Q > \chi_{\alpha, gl}^2$ onde $gl = k - 1 - \text{número de parâmetros estimados}$ e α é o nível de significância.

Testes de bom ajuste

Exemplo 2

Julga-se que o número de emails por hora (X) que chegam a uma instituição segue uma distribuição de Poisson. Os seguintes dados foram obtidos durante 100 horas. Teste se o número de emails por hora que chegam à instituição segue uma distribuição de Poisson ($\alpha = 0.05$).

Número de emails/hora (X)	0	1	2	3
Frequência	60	28	7	5

- Número de emails/hora (X) é uma variável categórica ordinal com $k = 4$ classes
- Teste do bom ajuste para testar X segue uma distribuição de Poisson sem λ especificado (probabilidades não completamente especificadas), i.e.,

H_0 : as probabilidades das classes provêm de uma distribuição de Poisson H_1 : $\neg H_0$

- estimar parâmetro λ : $\hat{\lambda} = \bar{x} = \frac{0 \times 60 + 1 \times 28 + 2 \times 7 + 3 \times 5}{100} = 0.57$
- logo $X \sim P(0.57)$ e $p_1 = P(X = 0) = \frac{e^{-0.57} 0.57^0}{0!} = 0.57$,
 $p_2 = P(X = 1) = 0.32$, $p_3 = P(X = 2) = 0.09$ e
 $p_4 = P(X \geq 3) = 1 - (0.57 + 0.32 + 0.09) = 0.02$

Número de emails/hora (X)	0	1	2	3 ou mais	Σ
f_i	60	28	7	5	$100 = n$
p_i	0.57	0.32	0.09	0.02	1
$e_i = np_i$	57	32	9	2	100

- como $e_4 = 2 < 5$ tem de se agrupar classes

Testes de bom ajuste

Exemplo 2

Número de emails/hora (X)	0	1	2 ou mais	Σ
f_i	60	28	12	$100 = n$
p_i	0.57	0.32	0.11	1
$e_i = np_i$	57	32	11	100
$\frac{(f_i - e_i)^2}{e_i}$	0.16	0.50	0.09	$0.75 = Q$

- com o agrupamento, passa-se a ter $k = 3$
- $E.T. : Q = \sum_{i=1}^3 \frac{(f_i - e_i)^2}{e_i} = 0.75$
- $R.R. : Q > \chi_{\alpha, gl}^2$ com
 $gl = k - 1 - \text{número de parâmetros estimados} = 3 - 1 - 1 = 1$, logo
 $Q > \chi_{0.05, 1}^2 \Leftrightarrow Q > 3.84$ (Tabela 7)
- Não se rejeita H_0 para $\alpha = 0.05$, pelo que o número de emails por hora que chegam à instituição poderá seguir uma distribuição de Poisson.

Testes de bom ajuste

Exemplo 3

Recolheu-se uma amostra aleatória de 100 operários de uma grande empresa, tendo-se obtido para o vencimento por hora uma média e um desvio padrão de 132 e 5, respetivamente. Pretende-se testar se o vencimento por hora segue uma distribuição normal ($\alpha = 0.05$) tendo em conta os dados da seguinte tabela:

Vencimento	Nº de operários
$x < 125$	10
$125 \leq x < 130$	20
$130 \leq x < 135$	38
$135 \leq x < 140$	25
$x \geq 140$	7

- Vencimento por hora (X) é uma variável agrupada em $k = 5$ classes
- Teste do bom ajuste para testar X segue uma distribuição normal sem μ e σ especificados (probabilidades não completamente especificadas), i.e.,
 H_0 : as probabilidades das classes provêm de uma distribuição normal H_1 : $\neg H_0$
- estimativas dos parâmetros μ e σ : $\hat{\mu} = \bar{x} = 132$ e $\hat{\sigma} = s = 5$, logo
 $X \sim N(132, 5^2)$ e $Z = \frac{X-132}{5} \sim N(0, 1)$
- $p_1 = P(X < 125) = P(Z < -1.4) = 0.0808$,
 $p_2 = P(125 \leq X < 130) = P(Z < -0.4) - P(Z < -1.4) = 0.2638$,
 $p_3 = P(130 \leq X < 135) = P(Z < 0.6) - P(Z < -0.4) = 0.3811$,
 $p_4 = P(135 \leq X < 140) = P(Z < 1.6) - P(Z < 0.6) = 0.2195$ e
 $p_5 = P(X \geq 140) = P(Z \geq 1.6) = 1 - P(Z < 1.6) = 0.0548$ (Tabela 5)

Testes de bom ajuste

Exemplo 3

Vencimento	f_i	p_i	$e_i = np_i$	$\frac{(f_i - e_i)^2}{e_i}$
$x < 125$	10	0.0808	8.080	0.4562
$125 \leq x < 130$	20	0.2638	26.38	1.5430
$130 \leq x < 135$	38	0.3811	38.11	0.0003
$135 \leq x < 140$	25	0.2195	21.95	0.4238
$x \geq 140$	7	0.0548	5.480	0.4216
$\sum$	$n = 100$	1	100	$Q = 2.845$

- $E.T. : Q = \sum_{i=1}^5 \frac{(f_i - e_i)^2}{e_i} = 2.845$
- $R.R. : Q > \chi^2_{\alpha, gl}$ com
 $gl = k - 1 - \text{número de parâmetros estimados} = 5 - 1 - 2 = 2$, logo
 $Q > \chi^2_{0.05, 2} \Leftrightarrow Q > 5.99$ (Tabela 7)
- Não se rejeita H_0 para $\alpha = 0.05$, pelo que o vencimento por hora poderá seguir uma distribuição normal.

Teste de Independência

Tabela de contingência

Testar a associação entre duas variáveis categóricas A e B com base nas frequências observadas indicadas numa tabela de contingência $a \times b$:

	B_1	B_2	$\dots$	B_b	$n_{i.}$
A_1	f_{11}	f_{12}	$\dots$	f_{1b}	$n_{1.}$
A_2	f_{21}	f_{22}	$\dots$	f_{2b}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
A_a	f_{a1}	f_{a2}	$\dots$	f_{ab}	$n_{a.}$
$n_{.j}$	$n_{.1}$	$n_{.2}$	$\dots$	$n_{.b}$	n

Hipóteses

A hipótese nula H_0 significa que as variáveis categóricas A e B são

independentes: $H_0 : p_{ij} = p_{i.} \times p_{.j} \quad i = 1 \dots a, j = 1 \dots b$
 $H_1 : p_{ij} \neq p_{i.} \times p_{.j} \quad \exists i \in \{1, \dots, a\}, j \in \{1, \dots, b\}$

Teste de independência

Estatística de teste

$E.T. : Q = \sum_{i=1}^a \sum_{j=1}^b \frac{(f_{ij} - e_{ij})^2}{e_{ij}}$ onde f_{ij} são as frequências observadas e

$e_{ij} = \frac{n_{i.} \times n_{.j}}{n}$ são as frequências esperadas.

Região de rejeição

$R.R. : Q > \chi_{\alpha, (a-1)(b-1)}^2$ onde α é o nível de significância.

Exemplo 4

Em 2003, o número de AVCs masculinos no concelho de Braga foram os reportados na tabela, de acordo com a estação do ano e género.

	Primavera	Verão	Outono	Inverno
Masculino	64	81	39	28
Feminino	70	66	41	43

Teste se existe associação entre a estação do ano e o género ($\alpha = 0.05$).

Teste de independência

- Testar a H_0 de que a estação do ano e o género são independentes, i.e.,

$$H_0 : p_{ij} = p_{i.} \times p_{.j} \quad i = 1 \dots 2, j = 1 \dots 4$$

$$H_1 : p_{ij} \neq p_{i.} \times p_{.j} \quad \exists i \in \{1, \dots, 2\}, j \in \{1, \dots, 4\}$$

- frequências marginais

f_{ij}	Primavera	Verão	Outono	Inverno	$n_{i.}$
Masculino	64	81	39	28	212
Feminino	70	66	41	63	240
$n_{.j}$	134	147	80	91	452

- Frequências esperadas

e_{ij}	Primavera	Verão	Outono	Inverno
Masculino	62.850	68.947	37.522	42.681
Feminino	71.150	78.053	42.478	48.319

- $E.T. : Q = \sum_{i=1}^2 \sum_{j=1}^4 \frac{(f_{ij} - e_{ij})^2}{e_{ij}} = 13.63; \quad R.R. : Q > \chi_{0.05,3}^2 \Leftrightarrow Q > 7.81$
- Rejeita-se H_0 para $\alpha = 0.05$, pelo que a estação do ano e o género não são independentes.