


Programação matemática

Modelos elementares, métodos e utilização de folhas de cálculo



FILIPPE PEREIRA E ALVELOS

2023

Conteúdo

1	Introdução	1
I	Modelação de problemas elementares	3
2	Problemas maximização do benefício	4
2.1	Problema de produção por composição	4
2.1.1	Definição	4
2.1.2	Modelo	5
2.1.3	Problemas relacionados	7
2.2	Problema da mochila	8
2.2.1	Definição	8
2.2.2	Modelo	9
2.3	Problema de empacotamento	10
2.3.1	Definição	10
2.3.2	Modelo	11
2.4	Exercícios	13
3	Problemas de minimização do custo	18
3.1	Problema de produção por decomposição	18
3.1.1	Definição	18
3.1.2	Modelo	18
3.2	Problema de cobertura	19
3.2.1	Definição	19
3.2.2	Modelo	20
3.3	Exercícios	23
4	Problemas de ligações	28
4.1	Transportes	28
4.1.1	Definição	28
4.1.2	Modelo	28
4.2	Afectação	31
4.2.1	Definição	31
4.2.2	Modelo	32

4.3	Exercícios	34
5	Problemas em rede	40
5.1	Caminho mais curto	40
5.1.1	Definição	40
5.1.2	Modelo	41
5.2	Escalonamento de projectos	43
5.2.1	Definição	43
5.2.2	Modelo	44
5.3	Exercícios	47
II	Software	52
6	Folhas de cálculo	53
6.1	Visão geral	53
6.2	Produção	54
6.2.1	Introdução do modelo na folha de cálculo	54
6.2.2	Carregamento do modelo no <i>solver</i>	56
6.2.3	Opções	57
6.2.4	Optimização, interpretação e validação	58
6.3	Análise de sensibilidade	62
6.4	Caminho mais curto	64
6.5	Afectação	65
6.6	Exercícios	70
III	Métodos	75
7	Algoritmos Simplex	76
7.1	Conceitos	76
7.1.1	Algoritmos iterativos	76
7.1.2	Conjunto das soluções admissíveis	77
7.1.3	Soluções básicas admissíveis	78
7.1.4	Optimalidade e direcções de melhoria	81
7.2	Algoritmos e resolução gráfica	82
7.2.1	Algoritmo simplex primal	82
7.2.2	Algoritmo simplex dual	87
7.2.3	Resolução gráfica	89
7.3	Exercícios	90
8	Algoritmos de partição e avaliação	94
8.1	Conceitos	94
8.1.1	A complexidade da programação inteira	94
8.1.2	Relaxação linear e limites	95

8.1.3	Partição	96
8.2	Algoritmo	98
8.3	Exemplo	101
8.4	Tópicos adicionais	105
8.5	Exercícios	107

1

Introdução

A optimização lida com problemas em que se pretende escolher uma de várias alternativas possíveis tendo em conta um determinado objectivo. A abordagem primordial para problemas de optimização é a programação matemática (com origem modernas na época da Segunda Guerra Mundial). Em programação matemática, o problema a abordar (que, tipicamente, é uma idealização de um problema mais complexo) é representado matematicamente através de um modelo em que relações dos componentes do problema se traduzem em relações matemáticas (i.e. funções). Com base no modelo e com a utilização de métodos adequados é possível obter a solução óptima, a alternativa que melhor satisfaz o objectivo pretendido.

Existem outras abordagens para o tipo de problemas descrito que, genericamente, se pode designar por problema de decisão. Por exemplo, ainda dentro da optimização, as abordagens heurísticas (e.g. algoritmos genéticos) usam estruturas de dados e funções computacionais para relacionar os componentes do problema. A estatística pode ser usada para, com base em dados históricos, sugerir a alternativa que se espera mais se aproximará de um objectivo. A aprendizagem máquina poderá ser usada quando existem grandes quantidades de dados e as relações entre as componentes do problema são difíceis (ou impossíveis) de expressar analiticamente.

A programação matemática distingue-se destas outras abordagens (embora, também com elas se possa combinar) pela forte fundamentação teórica e pelas contribuições práticas que, ao longo de décadas, tem incorporado nas mais diversas áreas, como, por exemplo, em logística, em telecomunicações, em produção, em gestão de projectos e em gestão florestal.

Este é um texto introdutório que cobre a modelação de problemas de optimização elementares através de programação matemática (Parte I) e a sua resolução com *solvers* através de folhas de cálculo (Parte II). Apresentam-se também os fundamentos dos métodos de resolução mais relevantes (Parte III).

Noutro texto são abordadas técnicas mais avançadas de modelação, apli-

cações adicionais, utilização de linguagens de modelação/programação, optimização com incerteza e optimização com múltiplos objectivos.

Parte I

Modelação de problemas elementares

2

Problemas maximização do benefício

2.1 Problema de produção por composição

2.1.1 Definição

Considera-se um sistema produtivo em que são conhecidas as disponibilidades dos recursos, os parâmetros dos processos de transformação dos recursos (e.g. humanos, materiais, tecnológicos, ambientais) em produtos e o benefício associados aos produtos.

Mais formalmente, considera-se um conjunto de n produtos, representado por J e indexado por j e um conjunto de m recursos representado por I e indexado por i .

Cada produto j tem um benefício unitário de p_j , $j \in J$. O recurso i , $i \in I$ a disponibilidade de b_i unidades. A produção de uma unidade de um produto j implica o consumo de a_{ij} unidades de cada recurso i , $i \in I; j \in J$.

Por exemplo, a produção de 10 unidades do produto 3, implica o consumo de $10a_{13}$ unidades do recurso 1 e o consumo de $10a_{23}$ unidades do recurso 2.

Pretende-se determinar as quantidades a produzir para que o benefício total seja o maior possível, respeitando o processo de transformação e a limitação imposta pela disponibilidade dos recursos ser finita.

Pressupõe-se que o benefício de cada produto é proporcional à quantidade dele produzida (o benefício marginal é constante) e que o benefício total é a soma do benefício com todos os produtos. Da mesma forma, o consumo de um recurso por um produto é proporcional à quantidade dele produzida e o consumo total de um recurso é a soma do consumo com todos os produtos.

Está-se assim perante um problema de programação linear.

Os parâmetros do problema de produção são resumidos no Quadro 2.1.

Quadro 2.1 Parâmetros do problema de produção.

- J conjunto dos produtos;
- I conjunto dos recursos;
- p_j benefício unitário do produto j , $j \in J$, em unidades de benefício/unidade produzida;
- b_i disponibilidade do recurso i , $i \in I$, em unidades de recurso;
- a_{ij} consumo unitário do recurso i pelo produto j , $i \in I; j \in J$, em unidades do recurso i por unidade produzida de j .

Exemplo 2.1. Considere-se uma fábrica que pretende definir as quantidades a produzir de três produtos (em Kg). Cada um dos três produtos tem de ser processado em duas máquinas (M1 e M2) que estão disponíveis durante um período de tempo limitado (expresso em horas). Cada unidade de cada produto tem um tempo de processamento em cada uma das máquinas (expresso em horas). Cada produto é composto por duas matérias-primas (MP1 e MP2) cujas quantidades são expressas em metros e Kg. Na Tabela 2.1 são apresentados os dados relativos a este problema concreto. Assim, por exemplo, a produção de uma unidade de P1 implica consumo de 10h em M1, 9h em M2, 4m de MP1 e 34Kg de MP2.

	a_{ij}	Produtos			Disponibilidade
		P1	P2	P3	
Recursos	M1	10	20	30	112 h
	M2	9	3	5	80 h
	MP1	4	3	1	30 m
	MP2	34	35	17	300Kg
Benefício		25€/un	27€/un	33€/un	

Tabela 2.1: Dados do exemplo do problema de produção (Exemplo 2.1).

□

2.1.2 Modelo

Representam-se as quantidades que se pretende determinar de forma ao benefício total ser máximo por um vector x . Dado representarem as decisões a tomar e não serem constantes (ao contrário os parâmetros definidos acima), os elementos de x são designados por variáveis de decisão. As variáveis de decisão do problema de produção são as apresentadas no Quadro 2.2.

Quadro 2.2 Variáveis de decisão do modelo de programação linear para o problema de produção.

- x_j quantidade a produzir do produto j , $j \in J$.
-

Com base na definição de variáveis de decisão, é possível representar funções que relacionam as quantidades produzidas com o benefício e com o consumo de cada um dos recursos. A função que faz corresponder o benefício total às quantidades produzidas é

$$\sum_{j \in J} p_j x_j$$

e o consumo do recurso i é

$$\sum_{j \in J} a_{ij} x_j$$

O modelo para o problema de produção é apresentado no Quadro 2.3.

Quadro 2.3 Modelo de programação linear para o problema de produção.

$$\text{Maximizar } \sum_{j \in J} p_j x_j \quad (2.1)$$

sujeito a:

$$\sum_{j \in J} a_{ij} x_j \leq b_i, \quad i \in I, \quad (2.2)$$

$$x_j \geq 0, \quad j \in J. \quad (2.3)$$

A expressão (2.1) designa-se por função objectivo e traduz que se pretende que o benefício total seja máximo. As expressões (2.2) designam-se por restrições e forçam a que os consumos dos recursos associados às quantidades produzidas não excedam as suas disponibilidades. As restrições (2.3) definem o domínio das variáveis de decisão e indicam que só se podem produzir quantidades positivas.

Uma solução, x para a qual todas as restrições se verifiquem é uma solução admissível. Uma solução admissível, x , que tome um valor igual ou superior a qualquer outra solução admissível é uma solução óptima.

Exemplo 2.2. O modelo de programação linear do Exemplo 2.1 é apresentado de seguida.

Variáveis de decisão:

- x_1 quantidade a produzir do produto 1;

- x_2 quantidade a produzir do produto 2;
- x_3 quantidade a produzir do produto 3.

Modelo:

Maximizar $25x_1 + 27x_2 + 33x_3$

sujeito a:

$$10x_1 + 20x_2 + 30x_3 \leq 112 \quad [\text{M1}]$$

$$9x_1 + 3x_2 + 5x_3 \leq 80 \quad [\text{M2}]$$

$$4x_1 + 3x_2 + x_3 \leq 30 \quad [\text{MP1}]$$

$$34x_1 + 35x_2 + 17x_3 \leq 300 \quad [\text{MP2}]$$

$$x_1, x_2, x_3 \geq 0$$

Usando um *solver* de programação linear, obtém-se a solução óptima $x_1 = 7.16$, $x_2 = 0$, $x_3 = 1.35$ para um benefício total de 223.55. Foi feito um arredondamento de duas decimais após a optimização. Para esta solução, todo o tempo disponível da máquina M1 é usado (de facto, devido ao arredondamento são gastos 6 minutos para além das 80 horas disponíveis) e toda a quantidade de MP1 é gasta (de facto, devido ao arredondamento sobra 1 cm dos 30 m disponíveis). Sobram 8.81h em M1 e 33.61Kg de MP2. $\square$

2.1.3 Problemas relacionados

No caso dos produtos serem indivisíveis, as restrições (2.3) devem ser substituídas por

$$x_j \geq 0 \text{ e inteiros, } j \in J.$$

passando o modelo a ser um modelo de programação (linear) inteira.

Considera-se agora o caso em que, para cada produto $j, j \in J$, ou se produz uma determinada quantidade, representada por u_j , ou não há produção (notar que quando $u_j = 1$, está-se perante um caso particular em que se produz uma unidade de j ou não há produção de j). Definem-se as seguintes variáveis de decisão:

$$y_j = \begin{cases} 1, & \text{se há produção de } u_j \text{ unidades} \\ 0, & \text{se não há produção} \end{cases}, j \in J. \quad (2.4)$$

Notando que $x_j = u_j y_j, j \in J$, o modelo de programação inteira é dado no Quadro 2.4.

Quadro 2.4 Modelo de programação inteira para o problema de produção binária.

$$\begin{aligned} &\text{Maximizar } \sum_{j \in J} p_j u_j y_j \\ &\text{sujeito a:} \\ &\sum_{j \in J} a_{ij} u_j y_j \leq b_i, \quad i \in I, \\ &y_j \in \{0, 1\}, \quad j \in J. \end{aligned}$$

Exemplo 2.3. Considerem-se os valores $u_1 = u_2 = u_3 = 3$ no Exemplo 2.1. O modelo é

$$\begin{aligned} &\text{Maximizar } 75y_1 + 81y_2 + 99y_3 \\ &\text{sujeito a:} \\ &30y_1 + 60y_2 + 90y_3 \leq 112 \\ &27y_1 + 9y_2 + 15y_3 \leq 80 \\ &12y_1 + 9y_2 + 3y_3 \leq 30 \\ &102y_1 + 105y_2 + 51y_3 \leq 300 \\ &y_1, y_2, y_3 \in \{0, 1\}. \end{aligned}$$

A solução óptima é $y_1 = y_2 = 1$ e $y_3 = 0$ com um benefício total de 156.

□

2.2 Problema da mochila

2.2.1 Definição

Considera-se o problema de seleccionar um conjunto de itens, cada um deles com um benefício e um peso, de forma a maximizar o valor dos itens seleccionados com a restrição de não se ultrapassar um dado limite de peso. Este problema de optimização designa-se por problema da mochila e pode ser visto como um problema de produção com um único recurso em que, para cada produto, ou há produção com um determinado benefício e um determinado consumo do recurso ou não há produção.

Os parâmetros do problema da mochila são apresentados no Quadro 2.5.

Quadro 2.5 Parâmetros do problema da mochila.

- J conjunto dos itens;
 - b limite de peso;
 - p_j benefício do item j , $j \in J$;
 - a_j peso do item j , $j \in J$.
-

2.2.2 Modelo

Definem-se as variáveis de decisão apresentadas no Quadro 2.6. O modelo é dado no Quadro 2.7.

Quadro 2.6 Variáveis de decisão do problema da mochila.

$$x_j = \begin{cases} 1, & \text{se o item } j \text{ é seleccionado} \\ 0, & \text{caso contrário} \end{cases}, j \in J. \quad (2.5)$$

Quadro 2.7 Modelo de programação inteira o problema da mochila.

$$\text{Maximizar } \sum_{j \in J} p_j x_j \quad (2.6)$$

Sujeito a:

$$\sum_{j \in J} a_j x_j \leq b \quad (2.7)$$

$$x_j \in \{0, 1\}, \quad j \in J \quad (2.8)$$

A função objectivo (2.6) traduz a maximização do benefício associado aos itens escolhidos. A restrição (2.7) limita o peso dos itens escolhidos. O domínio das variáveis de decisão é definido por (2.8).

Exemplo 2.4. Considere-se um conjunto de encomendas que se pretende entregar a cinco clientes (C1 a C5). Os veículos existentes permitem a entrega de $100m^3$. O benefício associado a cada encomenda (em €) e o seu volume (em m^3) dados na Tabela 2.2. Pretende-se decidir quais as encomendas a entregar de forma a maximizar o benefício total.

Assumindo que as encomendas são indivisíveis, as variáveis de decisão são:

$$x_j = \begin{cases} 1, & \text{se cliente } j \text{ recebe a encomenda} \\ 0, & \text{caso contrário} \end{cases}, j \in J;$$

	C1	C2	C3	C4	C5
Benefício	23	93	45	67	23
Volume	15	80	43	65	19

Tabela 2.2: Dados do exemplo do problema da mochila (Exemplo 2.4).

O modelo é:

$$\begin{aligned}
 &\text{Maximizar } 23x_1 + 93x_2 + 45x_3 + 67x_4 + 23x_5 \\
 &\text{sujeito a:} \\
 &15x_1 + 80x_2 + 43x_3 + 65x_4 + 19x_5 \leq 100 \\
 &x_1, x_2, x_3, x_4, x_5 \in \{0, 1\}.
 \end{aligned}$$

A solução óptima é $x_1 = x_2 = 1, x_3 = x_4 = x_5 = 0$ com benefício total 116 e 95 unidades de recurso consumidas. $\square$

Note-se que o problema da mochila em que os itens são divisíveis é trivial de resolver já que basta seleccionar os itens com maior benefício por unidade de recurso, ou seja p_j/a_j , até não existir mais capacidade. No máximo, haverá um item parcialmente seleccionado (a existir, será o último considerado).

2.3 Problema de empacotamento

2.3.1 Definição

No problema de empacotamento são conhecidas potenciais formas de constituir grupos de itens. Cada potencial grupo tem um lucro. Pretende-se que o lucro seja máximo tendo em conta que cada item não pode pertencer a mais de um grupo seleccionado. Os parâmetros destes problemas são dados no Quadro 2.8.

Quadro 2.8 Parâmetros dos problemas de empacotamento.

- J conjunto dos potenciais grupos;
- I conjunto dos itens;
- p_j benefício associado a ser seleccionado o grupo j , $j \in J$;

$$a_{ij} = \begin{cases} 1, & \text{se potencial grupo } j \text{ inclui tipo de item } i \\ 0, & \text{caso contrário, } i \in I; j \in J. \end{cases}$$

2.3.2 Modelo

As variáveis de decisão são as apresentadas no Quadro 2.9.

Quadro 2.9 Variáveis de decisão do problema de empacotamento.

$$x_j = \begin{cases} 1, & \text{se grupo } j \text{ é seleccionado} \\ 0, & \text{caso contrário} \end{cases}, j \in J; \quad (2.9)$$

O modelo de programação inteira para o problema de empacotamento é apresentado no Quadro 2.10.

Quadro 2.10 Modelo de programação inteira para o problema de empacotamento.

$$\text{Maximizar } \sum_{j \in J} p_j x_j \quad (2.10)$$

sujeito a:

$$\sum_{j \in J} a_{ij} x_j \leq 1, \quad i \in I, \quad (2.11)$$

$$x_j \in \{0, 1\}, \quad j \in J. \quad (2.12)$$

A função objectivo (2.10) traduz a maximização do benefício associado aos grupos escolhidos. As restrições (2.11) garantem que cada item não faz parte de mais de um grupo. O domínio das variáveis de decisão é definido por (2.12).

Exemplo 2.5. Uma organização de ajuda humanitária está a analisar quais as missões que deve efectuar de um conjunto de 13 missões tendo para tal 10 pessoas disponíveis. Cada potencial missão envolve um conjunto de pessoas e tem um determinado benefício. Essa informação é dada na Tabela 2.1 (1 significa que a pessoa da linha tem de integrar a missão da coluna). Por exemplo, a missão *M01* envolve as pessoas *p09* e *p10* e tem um benefício de 5. Pretende-se determinar as missões que maximizam o benefício total tendo em conta que cada pessoa não pode entrar em mais de uma missão.

As variáveis de decisão são:

$$x_j = \begin{cases} 1, & \text{se missão } j \text{ é escolhida} \\ 0, & \text{caso contrário, } j \in J; \end{cases}$$

	M01	M02	M03	M04	M05	M06	M07	M08	M09	M10	M11	M12	M13
p01							1		1	1			1
p02		1						1	1				1
p03			1						1	1		1	
p04				1	1			1	1				
p05			1			1		1			1		
p06			1			1	1			1			
p07		1		1	1							1	
p08				1	1	1							1
p09	1	1		1							1		
p10	1				1		1					1	
Ben.	5	6	8	8	9	7	7	6	7	8	6	5	6

Tabela 2.1: Dados do exemplo do problema de empacotamento (Exemplo 2.5).

O modelo é:

Minimizar $5x_1 + 6x_2 + \dots + 6x_{13}$

Sujeito a:

$$x_7 + x_9 + x_{10} + x_{13} \leq 1 \quad [\text{p01}]$$

$$x_2 + x_8 + x_9 + x_{13} \leq 1 \quad [\text{p02}]$$

...

$$x_1 + x_5 + x_7 + x_{12} \leq 1 \quad [\text{p10}]$$

$$x_j \in \{0, 1\}, \quad j = 1, \dots, 13$$

□

2.4 Exercícios

Exercício 2.1. Uma fábrica de mobiliário produz estantes, cadeiras em dois modelos (normal e especial) e secretárias. Todas as peças usam o mesmo tipo de madeira nas quantidades dadas na Tabela 2.2. Na mesma tabela é indicado o tempo que demora cada operação de cada peça e ainda o lucro associado a cada unidade produzida. Por exemplo, na produção de uma estante são utilizados $20 m^2$ de madeira, demorando-se duas horas nas operações de corte e polimento e uma hora nas operações de montagem e acabamento.

	Estante	Cadeira N.	Cadeira E.	Secretária
Consumo de madeira (m^2 /un.)	20	3	4	8
Tempo de corte e polimento (horas/un.)	2	0.8	0.5	0.7
Tempo de montagem e acabamento (horas/un.)	1	0.4	0.6	0.5
Lucro (€/unidade)	200	50	70	120

Tabela 2.2: Parâmetros do Exercício 2.1.

A fábrica tem $500m^2$ de madeira em stock, 90 horas disponíveis para o corte e polimento e 60 horas disponíveis para a montagem e acabamento.

Apresente um modelo assumindo que toda a produção é vendida.

Exercício 2.2. Uma empresa de embalagens comercializa uma bebida em quatro tipos de recipientes (garrafas de vidro transparente – VT ou escurecido – VE, pacotes de plástico – PP e pacotes tetra pak – TP), todos com a capacidade unitária de um litro. O lucro da empresa por cada embalagem de sumo vendida é de 1€, 1.5€, 0.75€ e 2€ euros se for vendida em VT, VE, PP e TP, respectivamente.

O departamento logístico da empresa tem capacidade semanal de expedir para as lojas 1000 garrafas (VT e VE em conjunto), 2000 pacotes PP e 2200 TP. Existe uma máquina para embalar a bebida, que funciona 50 horas por semana, e demora 0.5 minutos a embalar cada garrafa VT, 0.75 minutos a embalar cada garrafa VE, 1 minuto a embalar cada garrafa PP e 1.1 minutos a embalar cada garrafa TP. A procura semanal não excede 2500 litros.

Apresente um modelo.

Exercício 2.3. Uma fábrica produz quatro tipos de tinta (normal e plus para interior e exterior) com base em três matérias-primas (A, B e C). Em cada dia, estão disponíveis 4 toneladas de A, 5 toneladas de B e 3 toneladas de C para produzir tinta. A produção de uma tonelada de tinta interior implica o consumo de duas toneladas de A e de uma tonelada de B. A produção de uma tonelada de tinta para exterior implica o consumo de uma tonelada de A e de três toneladas de B. Adicionalmente, uma tonelada de tinta normal requer uma tonelada de C uma tonelada de tinta plus requer duas toneladas de C. O lucro de cada tonelada de tinta normal para interior é de 3000€ e para exterior é de 2500€. O lucro de cada tonelada de tinta plus para interior é de 4000€ e para exterior é de 3250€. Apresente um modelo.

Exercício 2.4. Uma fábrica produz cinco tipos de produtos (A, B, C, D e E) com base em dois processos: polimento e perfuração. O lucro associado a cada um dos produtos é dado na Tabela 2.3.

Produto	A	B	C	D	E
Lucro(€/un.)	550	600	350	400	200

Tabela 2.3: Lucros unitários por produto do Exercício 2.4.

A produção de cada unidade exige um determinado tempo em cada processo, valores que são dados na Tabela 2.4 (em horas).

Produto	A	B	C	D	E
Polimento	12	20	-	25	15
Perfuração	10	8	16	-	-

Tabela 2.4: Consumos unitários por produto do Exercício 2.4.

Adicionalmente, a montagem de cada unidade consome 20 horas.homem. A fábrica tem três máquinas de polir e duas máquinas de perfurar e trabalha seis dias por semana com dois turnos de oito horas por dia. A fábrica tem oito colaboradores dedicados à operação de montagem e cada um deles trabalha um turno por dia. Apresente um modelo que permita determinar quais as quantidades a produzir por semana de forma a maximizar o lucro total.

Exercício 2.5. Uma empresa fabrica calculadoras de quatro tipos básicas, científicas, gráficas modelo Einstein e gráficas modelo Dantzig. Por limitações de recursos humanos apenas podem ser produzidas, no total, 60 calculadoras por dia. O processo produtivo inclui uma máquina, disponível oito horas por dia, que demora 15 minutos a processar uma calculadora básica, 20 minutos uma calculadora científica e 25 minutos a processar uma calculadora gráfica (independentemente do modelo). Todas as calculadoras são inspeccionadas no departamento de qualidade que funciona sete horas por dia. A inspeção de uma calculadora básica demora 5 minutos, de uma calculadora científica 8 minutos, de uma gráfica Einstein 10 minutos e de uma gráfica Dantzig 12 minutos. A inspeção de uma calculadora básica demora 5 minutos, de uma calculadora científica 8 minutos, de uma gráfica Einstein 10 minutos e de uma gráfica Dantzig 12 minutos. Pela mesma ordem, o lucro por cada calculadora é 7€, 9€, 11€ e 17€. Apresente um modelo.

Exercício 2.6. Numa situação de emergência, é necessário decidir para que locais enviar equipas de socorro. Numa primeira análise foram identificados 10 destinos possíveis correspondendo a 10 diferentes zonas. Para cada um desses destinos foi estimado o benefício (numa escala de 0 a 100) da presença de uma equipa de socorro e o custo a ela associado. Esses valores são dados na Tabela 2.5. O orçamento disponível é de 250 U.M. e há 7 equipas disponíveis.

Zona	1	2	3	4	5	6	7	8	9	10
Benefício	90	60	80	50	20	40	95	45	15	30
Custo (U.M.)	100	50	80	40	25	50	80	45	10	20

Tabela 2.5: Dados do Exercício 2.6.

Apresente um modelo para duas alternativas: i) é possível enviar mais do que uma equipa para cada região, sendo o benefício proporcional ao número de equipas enviadas e ii) apenas é possível enviar uma equipa para cada região.

Exercício 2.7. Numa situação de emergência, é necessário formar equipas de socorro. Numa primeira análise foram identificadas possíveis constituições das equipas e o benefício a elas associado. Assim, há três tipos de equipas potenciais todas com um médico e dois auxiliares. As equipas do tipo A têm ainda um enfermeiro, as do tipo B têm ainda dois enfermeiros e as do tipo C têm um auxiliar adicional. Estão disponíveis 10 médicos, 12 enfermeiros e 16 auxiliares. Sabendo que se estima o benefício de cada dos tipos A, B e C em 100, 150 e 90, respectivamente, apresente um modelo que permite decidir quantas equipas de cada tipo devem ser formadas.

Exercício 2.8. Uma empresa pretende vender quatro tipos de cabazes com alimentos frescos: C1 a C4. Cada cabaz tem pão, fruta, vegetais, leite e sumo natural em quantidades diferentes. Pela mesma ordem, a composição dos cabazes é a seguinte:

C1: 200g, 200g, 500g, 500ml e 0 (não tem sumo).

C2: 400g, 200g, 500g, 800ml e 200ml.

C3: 200g, 400g, 800g, 800ml e 500ml.

C4: 400g, 500g, 1Kg, 1l e 1l.

O lucro esperado com por cada tipo de cabaz, de acordo com o seu tipo, é: 10€, 13€, 14€ e 20€. Para o dia em causa estão disponíveis 5Kg de pão, 10Kg de fruta, 14Kg de vegetais, 20 l de leite e 18 l de sumo.

Apresente um modelo.

Exercício 2.9. Considera-se o problema da determinação dos vencedores em leilões combinatórios. Num leilão combinatório existem os objectos leiloados e os compradores. Ao contrário de outro tipo de leilões, cada oferta é feita para um conjunto de (um ou mais) objectos. Cada comprador pode fazer várias ofertas. Depois de todas as ofertas feitas, os objectos são atribuídos simultaneamente de forma ao valor do leilão ser o maior possível, determinando-se assim os vencedores do leilão.

Apresente um modelo para o problema da determinação dos vencedores de um leilão com sete objectos (A a G) para os quais houve as dez ofertas da Tabela 2.6.

Oferta	Objectos	Valor
1	A,B	13
2	A,B,C,D	30
3	C,D,E	25
4	C,D	11
5	E,F	12
6	E,F,G	16
7	A	10
8	B	10
9	A,D,F,G	29
10	B,C,D,E	24

Tabela 2.6: Dados do Exercício 2.9.

Exercício 2.10. Uma agência espacial pretende decidir em que missões investir nos próximos três anos. Existem 8 potenciais missões. Se uma missão for seleccionada, tem de ser totalmente financiada em cada um dos anos. Na tabela 2.7 apresentam-se as missões em causa, o financiamento (em milhares de euros) requerido por cada uma, em cada ano, e o benefício que a agência espacial atribui a cada missão (estimado com base nos ganhos científicos e nos benefícios para a vida na terra, entre outros).

Missão	Ano 1	Ano 2	Ano 3	Benefício
Lisa	8	10	8	74
Athena	1	9	3	75
Ariel	8	9	5	82
Plato	10	15	12	98
Flex	10	8	10	87
Space rider	5	10	5	99
Euclid	8	8	10	76
Juice	2	9	4	65

Tabela 2.7: Dados do Exercício 2.10.

Os orçamentos disponiveis são de 30, 35 e 45 milhares de euros no primeiro, segundo e terceiro anos, respectivamente. Apresente um modelo que permita a maximização do benefício conjunto das missões seleccionadas.

3

Problemas de minimização do custo

3.1 Problema de produção por decomposição

3.1.1 Definição

Considera-se o processamento de produtos para obter os seus componentes. Este processamento pode ser parte de um sistema de produção inversa em que os produtos utilizados são processados e reintegrados no sistema produtivo (e.g. reutilização de componentes electrónicos).

Existem requisitos relativos ao número de unidades desejadas de cada componente. São conhecidos os custos unitários relativos ao processamento de cada produto e pretende-se minimizar o custo total.

Formalmente, considera-se um conjunto de n produtos, representado por J , tendo cada produto j , um custo unitário de processamento, c_j , $j \in J$. O processamento dos produtos resulta num conjunto de m componentes, representado por I , cada um com uma procura de d_i unidades que se pretende satisfazer, $i \in I$.

Os parâmetros do problema de produção são resumidos no Quadro 3.1.

3.1.2 Modelo

As variáveis de decisão do problema de produção são as apresentadas no Quadro 3.2. O modelo de programação linear é dado no Quadro 3.3.

A função objectivo (3.1) traduz que se pretende que o custo seja mínimo. Cada restrição (3.2) assegura o número mínimo de cada um dos componentes. As restrições (3.3) definem o domínio das variáveis de decisão.

Exemplo 3.1. Uma empresa do ramo alimentar tem quatro rações para animais (A, B, C e D) que pretende misturar para a sua alimentação semanal. As rações têm um custo de 2.5€/Kg, 2.1€/Kg, 2€/Kg e 1€/Kg e incluem

Quadro 3.1 Parâmetros do problema de produção inversa.

-
- J conjunto dos produtos;
 - I conjunto dos componentes;
 - c_j custo unitário de processar o produto j , $j \in J$, em unidades de custo/unidade processada;
 - d_i procura do componente i , $i \in I$, em unidades de componente;
 - a_{ij} número de unidades do componente i resultantes do processamento de uma unidade do produto j , $i \in I; j \in J$.
-

Quadro 3.2 Variáveis do problema de produção inversa.

-
- x_j quantidade a processar do produto j , $j \in J$;
-

milho e farelos de soja nas seguintes quantidades: por cada Kg de cada ração as quantidades de milho são 0.5, 0.4, 0.2 e 0.25 e as de quantidade de farelo de soja são 0.4, 0.3, 0.4 e 0.1, para as rações A, B, C e D, respectivamente. Pretende-se que a mistura resultante tenha pelo menos 40 Kg de milho e 30 Kg de farelos de soja. O modelo baseia-se na definição das variáveis de decisão:

x_j - quantidade a comprar da ração j , $j \in J$.

O modelo é:

$$\text{Minimizar } 2.5x_1 + 2.1x_2 + 2x_3 + x_4$$

Sujeito a:

$$0.5x_1 + 0.4x_2 + 0.2x_3 + 0.25x_4 \geq 40 \quad [\text{Milho}]$$

$$0.4x_1 + 0.3x_2 + 0.4x_3 + 0.1x_4 \geq 30 \quad [\text{Farelos}]$$

$$x_j \geq 0, \quad j \in J$$

Usando um *solver* de programação linear, obtém-se a solução ótima $x_1 = 70$, $x_2 = 0$, $x_3 = 0$, $x_4 = 20$ para um custo total de 195€. $\square$

3.2 Problema de cobertura

3.2.1 Definição

O problema de cobertura considera potenciais formas de constituir grupos de itens. Cada potencial grupo tem um custo, pretendendo-se constituir grupos incluam todos os itens com o menor custo. Os parâmetros do problema de cobertura são dados no Quadro 3.4.

Quadro 3.3 Modelo para o problema de produção inversa.

$$\text{Minimizar } \sum_{j \in J} c_j x_j \quad (3.1)$$

sujeito a:

$$\sum_{j \in J} a_{ij} x_j \geq d_i, \quad i \in I \quad (3.2)$$

$$x_j \geq 0, \quad j \in J \quad (3.3)$$

Quadro 3.4 Parâmetros dos problemas de cobertura.

- J conjunto dos potenciais grupos;
- I conjunto dos itens;
- c_j custo associado ao potencial grupo j ser seleccionado, $j \in J$;

$$a_{ij} = \begin{cases} 1, & \text{se potencial grupo } j \text{ inclui tipo de item } i \\ 0, & \text{caso contrário, } i \in I; j \in J. \end{cases}$$

3.2.2 Modelo

As variáveis de decisão do problema de cobertura são as apresentadas no Quadro 3.5.

Quadro 3.5 Variáveis de decisão dos problemas de cobertura.

•

$$x_j = \begin{cases} 1, & \text{se grupo } j \text{ é seleccionado} \\ 0, & \text{caso contrário} \end{cases}, j \in J; \quad (3.4)$$

O modelo de programação inteira para o problema de cobertura é apresentado no Quadro 3.6.

A função objectivo (3.5) traduz a minimização do custo associado aos grupos escolhidos. As restrições (3.6) garantem que cada tipo de item existe em, pelo menos, um grupo. O domínio das variáveis de decisão é definido por (3.7).

Um alternativa para representar o modelo baseia-se em definir os grupos que incluem o tipo de item i , o conjunto $S_i, i \in I$. Dessa forma, as restrições

Quadro 3.6 Modelo de programação inteira para o problema de cobertura.

$$\text{Minimizar } \sum_{j \in J} c_j x_j \quad (3.5)$$

sujeito a:

$$\sum_{j \in J} a_{ij} x_j \geq 1, \quad i \in I, \quad (3.6)$$

$$x_j \in \{0, 1\}, \quad j \in J. \quad (3.7)$$

(3.6) passam a

$$\sum_{j \in S_i} x_j \geq 1, \quad i \in I$$

Exemplo 3.2. Uma empresa de telecomunicações móveis está a instalar uma rede numa nova região. Uma das decisões que a equipa responsável pela implementação da rede tem de tomar diz respeito à localização das antenas. Existem 13 potenciais locais para antenas (A01 a A13) que cobrem as zonas indicadas na Tabela 3.1 (1 significa que a zona da linha é coberta pela antena colocada na localização associada à coluna).

	A01	A02	A03	A04	A05	A06	A07	A08	A09	A10	A11	A12	A13
z01							1		1	1			1
z02		1						1	1				1
z03			1						1	1		1	
z04				1	1			1	1				
z05			1			1		1			1		
z06			1			1	1			1			
z07		1		1	1							1	
z08				1	1	1							1
z09	1	1		1							1		
z10	1				1		1					1	

Tabela 3.1: Dados do exemplo do problema de cobertura (Exemplo 3.2).

As variáveis de decisão são:

•

$$x_j = \begin{cases} 1, & \text{se é instalada uma antena no local } j \\ 0, & \text{caso contrário, } j \in J; \end{cases}$$

O modelo é:

Minimizar $x_1 + x_2 + \dots + x_{13}$

Sujeito a:

$$x_7 + x_9 + x_{10} + x_{13} \geq 1 \quad [\text{Z01}]$$

$$x_2 + x_8 + x_9 + x_{13} \geq 1 \quad [\text{Z02}]$$

...

$$x_1 + x_5 + x_7 + x_{12} \geq 1 \quad [\text{Z10}]$$

$$x_j \in \{0, 1\}, \quad j = 1, \dots, 13$$

Usando um *solver*, obtém-se a solução óptima $x_2 = x_3 = x_5 = x_{13} = 1$ correspondendo a quatro antenas instaladas. $\square$

3.3 Exercícios

Exercício 3.1. Numa determinada fábrica pretende-se produzir 70 Kg de um aço inoxidável com a composição dada na Tabela 3.2. Por exemplo, o aço tem de ter pelo menos 0,15Kg e no máximo 0,35Kg de enxofre (S). Na Tabela 3.3 é dada a composição das cinco ligas que podem ser usadas no fabrico do aço. Por exemplo, por cada Kg usado da liga A, obtêm-se 2 g de carbono, 3 g de manganés, 2 g de fósforo, 1 g de silício 800 g de crómio e 100 g de Níquel.

Elemento	Min (Kg)	Max (Kg)
C	0	0.1
Si	0	1
Mn	0	2
P	0	0.045
S	0.15	0.35
Cr	17	19
Ni	8	10

Tabela 3.2: Quantidades mínimas e máximas dos elementos do Exercício 3.1.

Produto	A	B	C	D	E
C	0.002	0.001	0.001	0.005	0.001
Si	0	0.002	0.001	0.002	0
Mn	0.003	0.001	0.006	0	0
P	0.002	0	0	0.004	0.003
S	0.001	0.003	0.001	0.005	0
Cr	0.8	0.1	0.1	0	0
Ni	0.1	0	0.6	0.1	0.1
Custo (U.M./Kg)	200	100	50	60	60

Tabela 3.3: Composições e custos unitários dos produtos do Exercício 3.1.

Apresente um modelo que permita minimizar o custo total da produção dos 70 Kg de aço inoxidável. Considere que existe um sexto ingrediente a custo zero que não contém nenhum dos elementos referidos e que pode ser adicionado em qualquer quantidade.

Exercício 3.2. Um serviço de emergência pretende adquirir um conjunto de ambulâncias para cobrir 10 zonas de uma cidade. Existem 8 locais em que as ambulâncias podem ser estacionadas. Um local cobre uma zona quando uma ambulância partindo desse local chega a qualquer ponto dessa zona em menos de 10 minutos. Essa informação é dada na Tabela 3.4. Qual o número mínimo de ambulâncias necessário para cobrir todas as zonas?

	A	B	C	D	E	F	G	H
1	1		1	1	1		1	1
2		1		1				1
3			1		1	1		1
4	1		1			1		1
5	1	1	1		1			
6					1	1	1	
7			1	1				1
8	1	1			1			1
9	1			1	1	1	1	
10	1	1			1			

Tabela 3.4: Parâmetros do Exercício 3.2.: célula com 1 significa que a zona da linha é coberta por uma ambulância no local da coluna.

Exercício 3.3. Numa sondagem pretende-se entrevistar pelo menos 200 jovens, 300 adultos e 400 seniores. Por razões operacionais, foi decidido que as entrevistas seriam feitas a todos os elementos de um agregado familiar tendo sido pré-seleccionados cinco tipos de agregados familiares com as seguintes composições:

- A: um adulto e um sénior;
- B: dois jovens e dois adultos;
- C: dois jovens e um sénior;
- D: dois seniores;
- E: dois adultos e um sénior.

Apresente um modelo que minimize o número de agregados familiares seleccionados.

Exercício 3.4. Uma floresta foi dividida em 10 áreas de risco (de 1 a 10) para rápida monitorização de incêndios. Foram também identificados seis pontos (de A a F) onde poderão ser instalados postos de vigilância. Pretende-se que cada uma das áreas de risco seja observável a partir de pelo menos um posto de vigilância. Na Figura 3.1 representa-se esquematicamente a floresta em causa com as dez áreas de risco e as áreas observáveis em cada um dos postos de vigilância. Uma área é observável de um posto quando o seu centro (onde está o seu índice) é coberto pela elipse que corresponde ao posto. Por exemplo, de A é possível observar as áreas de risco 1, 2, 3 e 10.




Figura 3.1: Esquema da floresta do Exercício 3.4. Números representam zonas a serem vigiadas, letras representam áreas abrangidas por postos de vigilância.

- Apresente um modelo matemático que permita determinar os postos a abrir, tendo em conta que se pretende que todas as áreas sejam cobertas com o número de postos.
- Como modelar uma área ter de ser coberta por, pelo menos, dois postos?
- Como modelar haver diferentes custos associados aos postos de vigilância?

Exercício 3.5. Um restaurante está aberto cinco dias por semana (está encerrado às segundas e domingos) e precisa do seguinte número mínimo de colaboradores para cada um desses dias (terça a sábado): 12, 8, 7, 13 e 15. Cada potencial colaborador trabalhará em três dias. Por exemplo, um possível horário para um colaborador consiste em trabalhar à terça, quinta e sábado (folgando à quarta e sexta). Um horário que inclua sexta-feira tem um custo adicional de 10%, um horário que inclua sábado tem um custo adicional de 30% (acumulável com o custo adicional de sexta). Apresente um modelo que, garantindo o número mínimo de colaboradores por dia, minimize o custo total.

Exercício 3.6. O responsável por um centro de atendimento telefônico, que funciona entre as 8:00 e as 23:00 horas, pretende definir os horários de todos os colaboradores para o próximo mês. Cada colaborador trabalha nove horas e tem direito a um período de uma hora para uma refeição que pode ser o das 12:00, 13:00 ou 14:00. Em cada semana, os colaboradores gozam dois dias de folga, um deles ao fim-de-semana. Estimou-se que, em média, cada colaborador atende 12 telefonemas por hora. Os dados da Tabela 3.5 correspondem à estimativa do número de chamadas dada pelo departamento de marketing. A gestão faz questão de manter um excelente nível de serviço (deve haver capacidade para atender todos os telefonemas estimados), mas pretende ter o menor número possível de colaboradores.

	Segunda	Terça	Quarta	Quinta	Sexta	Sábado	Domingo
08:00	159	133	89	115	67	25	53
09:00	160	138	106	133	86	38	65
10:00	179	153	115	148	89	56	80
11:00	193	169	132	163	102	71	93
12:00	175	155	128	152	84	66	73
13:00	166	152	121	132	69	59	59
14:00	147	133	116	120	57	50	46
15:00	135	114	113	110	37	46	41
16:00	120	103	107	100	18	44	40
17:00	128	117	108	105	27	32	38
18:00	138	133	127	123	46	15	21
19:00	144	144	138	135	51	1	1
20:00	137	125	133	116	40	7	2
21:00	126	122	117	113	23	3	3
22:00	110	115	115	112	18	3	1

Tabela 3.5: Estimativa do número de telefonemas recebidos por hora e dia da semana do Exercício 3.6.

Exercício 3.7. Uma determinada empresa de distribuição tem uma frota de veículos para proceder à entrega de encomendas de quatro clientes. A capacidade de cada veículo é de 10 unidades e as encomendas dos clientes são de 5, 4, 3 e 2 unidades. Todos os veículos partem de um mesmo local (depósito), ao qual têm de regressar depois de entregues as encomendas. Associa-se o índice 0 ao depósito e os índices de 1 a 4 aos clientes. As coordenadas no plano das localizações são depósito $(0, 0)$, cliente 1 : $(62, 55)$, cliente 2 : $(40, 86)$, cliente 3 : $(23, 93)$ e cliente 4 : $(41, 47)$. Pretende-se determinar as rotas a efectuar pelos veículos de forma à distância total percorrida ser a menor possível. Considera-se que a distância Euclideana é uma boa aproximação para a distância real.

Exercício 3.8. Uma empresa de distribuição tem n encomendas para entregar e pretende determinar as rotas que os seus veículos devem fazer de forma a entregar todas as encomendas percorrendo a menor distância total (i.e. a soma da distância percorrida em cada rota) possível. Por causa da capacidade dos veículos, cada um só pode visitar no máximo, k clientes. As distâncias entre o local de onde os veículos partem e a onde regressam concluindo a sua rota e cada um dos clientes, bem como entre cada par de clientes, são conhecidas, sendo representadas por c_{ij} , $i = 0, \dots, n$; $j = 0, \dots, n$, em que 0 é o índice do local de início e final da rotas. Assuma que as dimensão do problema permite enumerar todas as rotas possíveis. Apresente um modelo geral e ilustre-o com dados por si arbitrados.

Exercício 3.9. O problema da dieta foi um dos primeiros problemas abordados por técnicas de optimização na década de 1940. Neste problema é dado um conjunto de alimentos cuja composição em termos de nutrientes é conhecida. Pretende-se determinar a dieta (i.e. as quantidades a ingerir de cada alimento) de menor custo respeitando níveis mínimos de nutrientes. As entradas são os alimentos e as saídas os nutrientes. A medida global do desempenho é o custo (associado às entradas / alimentos). Definindo a notação que achar adequada, apresente um modelo de programação matemática para o problema da dieta.

4

Problemas de ligações

4.1 Transportes

4.1.1 Definição

Considera-se um problema em que há duas entidades, designadas por origens e destinos, entre as quais se pretende enviar quantidades de um produto com o menor custo possível. A quantidade que sai de cada origem não pode exceder a sua oferta. Cada origem tem uma procura que tem de ser satisfeita. O custo de transporte entre cada origem e cada destino é proporcional à quantidade transportada.

Os parâmetros do problema de produção são dados no Quadro 4.1.

Quadro 4.1 Parâmetros do problema de transportes.

- I conjunto das origens;
 - J conjunto dos destinos;
 - c_{ij} custo unitário de transporte entre a origem i e o destino $j, i \in I, j \in J$;
 - a_i oferta, i.e. quantidade disponível, da origem $i, i \in I$;
 - b_j procura, i.e. quantidade requerida, do destino $j, j \in J$.
-

4.1.2 Modelo

As variáveis de decisão do modelo para o problema de transportes são as apresentadas no Quadro 4.2.

Quadro 4.2 Variáveis de decisão do problema de transportes.

- x_{ij} quantidade a transportar de i para $j, i \in I, j \in J$;
-

O modelo de programação linear é apresentado no Quadro 4.3.

Quadro 4.3 Modelo de programação linear para o problema de transportes.

$$\text{Minimizar } \sum_{i \in I} \sum_{j=1}^m c_{ij} x_{ij} \quad (4.1)$$

Sujeito a:

$$\sum_{j=1}^m x_{ij} \leq a_i, \quad i \in I \quad (4.2)$$

$$\sum_{i \in I} x_{ij} = b_j, \quad j \in J \quad (4.3)$$

$$x_{ij} \geq 0, \quad i \in I; j \in J \quad (4.4)$$

A função objectivo (4.1) diz respeito à minimização do custo total. As restrições (4.2) asseguram que, de cada origem, não saem mais unidades do que as lá existentes. As restrições (4.3) asseguram que o número de unidades que chega a cada destino é o pretendido, i.e. a procura é satisfeita.

No caso dos produtos a transportar serem indivisíveis, as restrições (4.4) podem ser substituídas por:

$$x_{ij} \geq 0 \text{ e inteiros}, \quad i \in I, j \in J \quad .$$

É de salientar que, mesmo sem definir as variáveis como inteiras, ao contrário do que acontece com o modelo geral de programação inteira, o modelo para o problema de transportes (4.1-4.4), com ofertas e procuras inteiras, tem sempre uma solução óptima inteira (e os algoritmos retornam uma solução óptima inteira mesmo se existirem soluções óptimas alternativas fraccionárias). Desta forma, o problema de transportes pode ser resolvido com algoritmos para programação linear que são mais eficientes do que os algoritmos existentes para programação inteira.

Exemplo 4.1. No planeamento do próximo ano lectivo, uma autarquia pretende decidir onde serão preparadas as refeições para as cantinas de dez escolas do ensino secundário. Três dessas escolas (E1, E2 e E3) têm a possibilidade de preparar refeições para as próprias ou qualquer outra escola. Existe ainda outra local (L) em que é possível preparar refeições mas não para as escolas E4, E8 e E9. O custo de transporte por refeição entre os

locais onde as refeições podem ser preparadas e cada escola, o número máximo de refeições que pode ser preparado e o número de refeições necessário em cada escola são dados na Tabela 4.1.

Escola	C1	C2	C3	L	#Refeições
E1	0	0,7	0,2	0,1	150
E2	0,6	0	0,1	0,9	600
E3	0,9	0,9	0	0,4	675
E4	0,5	0,5	0,1	-	525
E5	0,6	0,8	0,2	0,7	225
E6	0,4	0,4	0,8	0,7	75
E7	0,3	0,8	0,2	0,7	225
E8	0,3	0,2	0,1	-	675
E9	0,2	0,6	0,3	-	600
E10	0,2	0,5	0,5	0,3	150
Capacidade	1100	1500	1600	2000	

Tabela 4.1: Dados do Exemplo 4.1.

As variáveis de decisão são:

- x_{ij} número de refeições preparadas no local j para serem consumidas no local i , $i = 1, \dots, 10$, $j = 1, 2, 3, 4$.

O modelo é:

Minimizar $0.7x_{12} + 0.2x_{13} + \dots + Mx_{94} + \dots + 0.5x_{10,3} + 0.3x_{10,4}$

Sujeito a:

$$x_{11} + x_{12} + x_{13} + x_{14} = 150 \quad [\text{E01}]$$

$$x_{21} + x_{22} + x_{23} + x_{24} = 600 \quad [\text{E02}]$$

...

$$x_{9,1} + x_{9,2} + x_{9,3} + x_{9,4} = 600, \quad [\text{E09}]$$

$$x_{10,1} + x_{10,2} + x_{10,3} + x_{10,4} = 150 \quad [\text{E10}]$$

$$x_{11} + x_{21} + \dots + x_{10,1} \leq 1100 \quad [\text{C1}]$$

$$x_{12} + x_{22} + \dots + x_{10,2} \leq 1500 \quad [\text{C2}]$$

$$x_{13} + x_{23} + \dots + x_{10,3} \leq 1600 \quad [\text{C3}]$$

$$x_{14} + x_{24} + \dots + x_{10,4} \leq 2000 \quad [\text{L}]$$

$$x_{ij} \geq 0 \text{ e inteiros, } i = 1, \dots, 10; j = 1, \dots, 4$$

A constante M na função objectivo corresponde a um valor muito elevado em comparação com os outros custos unitários, por exemplo duas ordens de grandeza acima (neste exemplo, poderia ser $M = 100$). Esta constante (dependente do problema) é também usada em Investigação Operacional

noutros problemas e contextos e é usualmente designada por “grande M ”. A sua função é forçar a que as variáveis que têm coeficiente M na função objectivo tomem o valor 0 numa solução óptima (já que o seu custo é muito maior do que o das outras variáveis e se pretende minimizar o custo total). Uma variável com coeficiente M ter um valor positivo numa solução óptima significa que o valor de M não é suficientemente elevado ou que o problema é impossível (é preciso recorrer a um transporte impossível para fazer o transporte de todas as unidades). O valor de M não deve ser exageradamente elevado por tal poder implicar dificuldades numéricas.

A impossibilidade de haver transporte entre uma origem e um destino pode também ser modelada i) não definindo a variável de decisão correspondente no modelo, ii) incluindo uma restrição forçando a que essa variável seja zero. $\square$

Diferentes problemas práticos podem ser formulados como problemas de transportes, não correspondendo necessariamente ao transporte de bens físicos. A título exemplificativo, um problema em que se pretende decidir a quantidade a produzir de vários produtos em cada uma de várias máquinas (cada máquina pode produzir qualquer produto), existindo uma medida da adequação de cada máquina a cada produto, pode ser formulado como um problema de transportes. As máquinas são as origens e a sua capacidade a oferta, os produtos são os destinos e as quantidades que têm de ser produzida a procura, as adequações correspondem aos custos. Outro exemplo, em que o transporte é temporal, é descrito no Exercício 4.11.

4.2 Afectação

4.2.1 Definição

Num problema de afectação tem-se dois conjuntos e pretendem-se fazer associações entre um elemento de um conjunto e um elemento do outro. Cada associação tem um custo e pretende-se minimizar o custo total. Este problema pode ser modelado como um caso particular do modelo de transportes, considerando-se que as origens e os destinos correspondem aos dois conjuntos e que têm oferta e procura de uma unidade. O transporte de uma unidade entre uma origem e um destino corresponde ao estabelecimento dessa associação.

Um problema de afectação pode também descrito como o problema de associar n agentes a n tarefas. Cada agente executa uma e só uma tarefa e cada tarefa é executada por um e um só um agente. A tarefa j ser executada pelo agente i corresponde a um custo de c_{ij} . O problema de afectação consiste em seleccionar os pares tarefa/agente que minimizam o custo total.

Os parâmetros do problema de afectação são apresentados no Quadro 4.4.

Quadro 4.4 Parâmetros do problema de afectação.

- n número de agentes e de tarefas;
- I conjunto dos agentes, $I = \{1, \dots, n\}$;
- J conjunto das tarefas, $J = \{1, \dots, n\}$;
- c_{ij} custo de associar agente i à tarefa $j, i \in I, j \in J$;

4.2.2 Modelo

As variáveis de decisão do modelo para o problema de afectação são as apresentadas no Quadro 4.5.

Quadro 4.5 Variáveis de decisão do problema de afectação.

•

$$x_j = \begin{cases} 1, & \text{se agente } i \text{ executa a tarefa } i \\ 0, & \text{caso contrário} \end{cases}, i \in I; j \in J.$$

O modelo de programação inteira é apresentado no Quadro 4.6.

Quadro 4.6 Modelo de programação inteira para o problema de afectação.

$$\text{Minimizar } \sum_{i \in I} \sum_{j \in J} c_{ij} x_{ij} \quad (4.5)$$

Sujeito a:

$$\sum_{j \in J} x_{ij} = 1, \quad i \in I \quad (4.6)$$

$$\sum_{i \in I} x_{ij} = 1, \quad j \in J \quad (4.7)$$

$$x_{ij} \in \{0, 1\}, \quad i \in I; j \in J \quad (4.8)$$

A função objectivo (4.5) diz respeito à minimização do custo total. As restrições (4.6) asseguram que cada agente executa uma e só uma tarefa. As restrições (4.7) asseguram que cada tarefa é executada por um e só um agente. As restrições (4.8) definem o domínio das variáveis de decisão.

O problema de afectação, tal como o problema de transportes (ver capítulo 4.1), tem a propriedade da integralidade. Assim, obtém-se igualmente uma solução óptima inteira se as restrições (4.8) forem substituídas por

$$x_{ij} \geq 0, \quad i = 1, \dots, 10; j = 1, \dots, 10.$$

Exemplo 4.2. Num serviço de um hospital pretende-se fazer a escala de 10 enfermeiros para 10 turnos críticos. Cada enfermeiro deve trabalhar exactamente em um turno e em cada turno deve estar presente exactamente um enfermeiro. Na Tabela 4.2 são apresentadas as preferências de cada enfermeiro em relação a cada turno numa escala de 1 a 10 em que 1 corresponde à preferência máxima. Pretende-se determinar qual o turno que cada enfermeiro deve efectuar.

	E1	E2	E3	E4	E5	E6	E7	E8	E9	E10
T1	1	1	1	3	5	3	5	1	1	2
T2	3	2	2	7	9	9	6	2	3	1
T3	2	10	3	1	3	2	7	4	2	3
T4	8	4	4	4	6	7	1	5	4	5
T5	9	5	5	2	4	6	2	9	5	4
T6	4	3	6	5	7	5	3	10	6	8
T7	5	6	7	8	10	4	8	6	10	7
T8	7	7	8	9	1	10	9	8	9	6
T9	6	8	9	10	2	8	10	7	7	10
T10	10	9	10	6	8	1	4	3	8	9

Tabela 4.2: Parâmetros do Exemplo 4.2.

As variáveis de decisão são:

$$x_{ij} = \begin{cases} 1, & \text{se o enfermeiro } j \text{ faz o turno } i \\ 0, & \text{caso contrário} \end{cases}, i = 1, \dots, 10; j = 1, \dots, 10.$$

O modelo é:

Minimizar $x_{11} + x_{12} + x_{13} + 3x_{14} + \dots + 6x_{10,8} + 10x_{10,9} + 9x_{10,10}$

Sujeito a:

$$x_{11} + x_{12} + \dots + x_{1,10} = 1 \quad [\text{T01}]$$

$$x_{21} + x_{22} + \dots + x_{2,10} = 1 \quad [\text{T02}]$$

...

$$x_{10,1} + x_{10,2} + \dots + x_{10,10} = 1 \quad [\text{T10}]$$

$$x_{11} + x_{21} + \dots + x_{10,1} = 1 \quad [\text{E01}]$$

$$x_{12} + x_{22} + \dots + x_{10,2} = 1 \quad [\text{E02}]$$

...

$$x_{1,10} + x_{2,10} + \dots + x_{10,10} = 1 \quad [\text{E10}]$$

$$x_{ij} \in \{0, 1\}, \quad i = 1, \dots, 10; j = 1, \dots, 10$$

Usando um *solver*, obtém-se uma solução óptima que corresponde às associações E1-T9, E2-T6, E3-T1, E4-T5, E5-T8, E6-T7, E7-T4, E8-T10, E9-T3, E10-T2 com uma preferência global de 24.



4.3 Exercícios

Exercício 4.1. Uma empresa pretende transportar um determinado produto de quatro fábricas para três armazéns. Nas fábricas (A, B, C e D) estão existem 50, 30 e 40 e 50 unidades do produto, respectivamente. Nos armazéns (1, 2 e 3) são necessárias 15, 25 e 50 unidades, respectivamente. Na Tabela 4.3 apresentam-se os custos de transportar uma unidade entre cada fábrica e cada armazém.

	1	2	3
A	8	5	3
B	9	5	4
C	3	9	5
D	8	8	2

Tabela 4.3: Parâmetros do Exercício 4.1.

- Apresente uma solução para este problema e o seu custo.
- Apresente um modelo que permita determinar as quantidades a enviar de cada fábrica para cada armazém forma a minimizar o custo total de transporte.

Exercício 4.2. Uma fábrica necessita de duas, três e cinco unidades de três matérias-primas (representadas por A, B e C) para a produção do próximo mês. Foram estudados quatro fornecedores (representados por F1 a F4) tendo sido negociado com cada fornecedor o custo unitário de cada matéria-prima. Esses custos unitários são dados na Tabela 4.4.

	F1	F2	F3	F4
A	4	8	8	1
B	4	1	3	7
C	7	9	9	2

Tabela 4.4: Parâmetros do Exercício 4.2.

Para manter a diversidade de fornecedores, a fábrica não pretende comprar mais de três unidades (considerando todas as matérias-primas) a cada um dos fornecedores.

- Apresente uma solução para este problema e o seu custo.

- b) Apresente um modelo que permita determinar o menor custo para a fábrica.

Exercício 4.3. Numa determinada fábrica é necessário alocar seis subprodutos (A a F) a seis linhas de produção. Para proceder a essa alocação, foi estimada a produtividade (em número de peças por hora) de cada uma das seis linhas de produção para cada um dos subprodutos. Esses valores são dados na Tabela 4.5. A produtividade total é a soma das produtividades em cada máquina. Determine a que linhas de produção devem ser alocados os subprodutos. Apresente um modelo programação inteira.

	A	B	C	D	E	F
LP1	20	40	51	21	51	33
LP2	65	95	21	88	63	68
LP3	66	44	34	75	10	75
LP4	31	97	90	48	98	27
LP5	64	21	93	96	13	33
LP6	89	5	24	9	41	63

Tabela 4.5: Parâmetros do Exercício 4.3.

Exercício 4.4. Para o acompanhamento da propagação de uma epidemia, a OMS (Organização Mundial de Saúde) preparou equipas de quatro tipos (T1 a T4) para enviar para seis países. Foram formadas 5 equipas de cada tipo e definido um número mínimo de equipas a serem enviadas para cada país. Essa informação é dada na Tabela 4.6. Na mesma tabela é dado o grau de adequação de cada tipo de equipa a cada país. Um valor mais alto significa uma maior adequação. Assim, para qualquer país, é preferível enviar, por exemplo, uma equipa do tipo 4 a uma equipa do tipo 3.

	A	B	C	D	E	F
T1	11	13	24	21	30	42
T2	21	19	37	43	40	56
T3	31	26	41	57	62	58
T4	47	43	55	69	64	71
#min	3	3	3	2	2	1

Tabela 4.6: Parâmetros do Exercício 4.4.

Exercício 4.5. Uma empresa de valorização e tratamento de resíduos sólidos pretende proceder à recolha de resíduos de 12 locais e transportá-los para quatro estações de tratamento. Cada estação de tratamento tem capacidade para receber 20 toneladas. Na Tabela 4.7 é dada a quantidade (em toneladas) existentes nos 12 locais e as coordenadas que definem a sua localização (uma unidade corresponde a um Km). A coordenadas das quatro estações são (2,6), (5,5), (5,8) e (10,15). Pretende-se minimizar a distância (euclidiana, em Km) total percorrida sabendo que cada veículo tem capacidade para transportar uma tonelada em cada viagem que efectuar.

	1	2	3	4	5	6	7	8	9	10	11	12
x	10	18	4	4	14	1	0	15	0	20	5	8
y	2	5	8	3	5	1	18	14	10	6	8	11
Quant.	5	6	3	5	7	9	2	12	15	1	4	5

Tabela 4.7: Parâmetros do Exercício 4.5.

Apresente um modelo.

Exercício 4.6. Seis navios de carga estão disponíveis para transportar seis cargas para seis portos. Cada navio apenas tem capacidade para transportar uma carga pretende-se que cada porto apenas receba um navio. Devido às diferenças entres os navios os portos, o custo da viagem depende do navio e do porto a que se destina. Esses custos são dados na Tabela 4.8.

	1	2	3	4	5	6
A	14	12	19	12	12	11
B	16	17	12	20	14	14
C	15	18	20	10	17	16
D	18	16	19	10	13	13
E	19	11	13	9	12	8
F	20	16	12	12	15	20

Tabela 4.8: Parâmetros do Exercício 4.6.

Apresente um modelo.

Exercício 4.7. Numa escola pretende-se atribuir 10 horários a 10 professores. Cada professor deve ficar com um horário e cada horário deve ser alocado a um professor. Na Tabela 4.9 são dadas as preferências de cada professor por cada horário (o horário mais desejado tem preferência 10).

	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10
P1	8	9	6	1	2	7	3	4	5	10
P2	9	7	2	4	8	1	3	6	5	10
P3	5	1	8	6	2	3	9	7	10	4
P4	5	8	1	2	4	6	7	9	10	3
P5	3	1	10	7	6	5	2	4	9	8
P6	10	1	2	9	3	8	4	6	5	7
P7	3	4	1	2	5	10	8	9	7	6
P8	2	1	9	3	6	8	5	7	10	4
P9	7	1	4	8	9	5	6	2	3	10
P10	10	9	8	7	4	3	2	1	5	6

Tabela 4.9: Parâmetros do Exercício 4.7.

Exercício 4.8. Os responsáveis pela vacinação de uma região país pretendem vacinar a população de dez zonas. Represente a população da zona j por $b_j, j = 1, \dots, 10$. Existem quatro empresas capazes de fornecer as vacinas e transportar as vacinas para as zonas em questão. Represente por $a_i, i = 1, 2, 3, 4$, o limite ao número de vacinas que a empresa i pode vender. O preço de compra de uma vacina à empresa i é c_i e o custo de transporte de uma vacina comprada à empresa i para a zona j é de c_{ij} . Apresente um modelo.

Exercício 4.9. Numa fábrica, as operações de armazenamento e recolha são feitas de forma automática por um AGV (automated guided vehicle). O AGV está estacionado junto à entrada do armazém onde chegaram n objectos para armazenar. Existem também outros n objectos para recolher do local onde estão armazenados para a entrada do armazém. As distâncias entre a entrada e cada local onde os objectos têm de ser armazenados e recolhidos, bem como as distâncias entre todos os locais de armazenamento e de recolha, são conhecidas por serem, para um dado layout de armazém, facilmente calculáveis. Representam-se por d_{ij} , em que i é um local e j outro. Pretende-se que o AGV armazene os n objectos e recolha os outros n objectos tendo em conta que a sua capacidade é de um objecto, ou seja, o AGV terá de fazer um conjunto de n viagens, cada uma partindo da entrada para um local de armazenamento, daí para um local de recolha, regressando depois à entrada. Pretende-se minimizar a distância total percorrida pelo AGV.

Exercício 4.10. Num departamento de uma universidade pretendem-se distribuir as horas de seis UC por dez docentes. Cada docente pode leccionar entre 6 e 8 horas. A carga horária das UC 1 e 2 é de 10 horas, a carga horária das UC 3 e 4 é de 12 horas e a das UC 5 e 6 é de 14 horas. Na tabela 4.10 é apresentada a informação sobre a adequação de cada docente a cada UC: 'A' significa que o docente é muito habilitado para leccionar a UC, 'B' significa o docente pode leccionar a UC mas esta as suas competências nucleares são noutra área, 'C' significa que o docente só deve dar a UC em último caso. Considere que o primeiro objectivo é que as horas 'A' seja o maior possível, seguido do objectivo número de horas 'B' ser o maior possível e duas abordagens:

- Descreva um procedimento em que se utilizam dois modelos consecutivamente para obter quantas horas a cada UC devem ser leccionadas por cada docente.
- Utiliza-se apenas um modelo para obter quantas horas a cada UC devem ser leccionadas por cada docente.

	UC1	UC2	UC3	UC4	UC5	UC6
D1	B	C	C	C	A	A
D2	C	A	A	C	A	A
D3	C	B	A	A	C	A
D4	B	C	A	A	B	A
D5	B	B	A	A	C	B
D6	A	A	A	C	C	C
D7	C	A	B	B	A	A
D8	A	B	B	A	C	B
D9	C	C	B	B	C	B
D10	B	C	C	B	B	A

Tabela 4.10: Parâmetros do Exercício 4.10.

Exercício 4.11. Pretende-se fazer o planeamento de produção para seis meses. Os valores da procura resultam de uma aplicação de um método de previsão e os valores dos custos (que são por unidade produzida/armazenada) do sistema de custeio da fábrica. A procura de um mês pode ser satisfeita por unidades produzidas no próprio mês ou em qualquer mês anterior.

- a) Formule este problema como um problema de transportes no tempo. Defina claramente a que correspondem as origens, as ofertas, os destinos, as procuras e os custos.
- b) Apresente um modelo para o problema concreto com os dados da Tabela 4.11.

Mês	1	2	3	4	5	6
Procura	10	15	20	18	14	8
Custo prod.	5	7	4	5	10	2
Custo armazen.	1	2	2	1	3	-

Tabela 4.11: Dados do Exercício 4.11.

Exercício 4.12. Descreva como pode transformar um modelo de transportes num modelo de afectação.

5

Problemas em rede

5.1 Caminho mais curto

5.1.1 Definição

O problema do caminho mais curto define-se numa rede em que associado a cada arco existe um parâmetro que se designa por comprimento. Pretende-se, partindo de um nodo, chegar a outro nodo, percorrendo um conjunto de arcos consecutivos (i.e. um caminho) de tal forma que a soma dos seus comprimentos seja a menor possível.

A título ilustrativo, considera-se a parte da rede de metro de Londres da Figura 5.1 ¹. Entre cada par de estações da mesma linha estão indicados os tempos de percorrer o percurso a pé. Por exemplo, entre Piccadilly Circus (cruzamento da linha azul escura e linha castanha) e Leicester Square, o tempo do percurso a pé é de 6 minutos. O problema prático de obter do caminho mais rápido entre, por exemplo, Baker Street e St. James Park, pode ser formulado como um problema de caminho mais curto em que os comprimentos dos arcos são os tempos. Note-se que que é necessário considerar que as ligações podem ser percorridos em ambas as direcções: existe o arco ij e também o arco ji .

¹<https://content.tfl.gov.uk/walking-tube-map.pdf>



Figura 5.1: Parte da rede de metro de Londres com tempo de percurso a pé entre estações.

Os parâmetros do problema do caminho mais curto são apresentados no Quadro 5.1.

Quadro 5.1 Parâmetros do problema de caminho mais curto.

- n número de nodos;
- m número de arcos;
- N conjunto de nodos;
- A conjunto de arcos;
- c_{ij} comprimento do arco ij , $\forall ij \in A$;
- o origem do caminho;
- d destino do caminho.

5.1.2 Modelo

As variáveis de decisão do modelo para o problema do caminho mais curto são as apresentadas no Quadro 5.2.

Quadro 5.2 Variáveis de decisão do problema do caminho mais curto.

•

$$x_{ij} = \begin{cases} 1, & \text{se arco } ij \text{ faz parte do caminho mais curto} \\ 0, & \text{caso contrário} \end{cases}, \forall ij \in A;$$

Para os arcos formarem um caminho têm de respeitar, em todos os nodos, que se o nodo fizer parte do caminho têm de ser seleccionados dois arcos: um de entrada e um de saída. Se o nodo não fizer parte do caminho, não pode ter arcos a entrar nem a sair. Os nodos de origem e destino do caminho são excepções: na origem, não entra nenhum arco e sai um arco; no destino não sai nenhum arco e entra um.

O modelo de programação inteira é apresentado no Quadro 5.3.

Quadro 5.3 Modelo para o problema do caminho mais curto.

$$\text{Minimizar } \sum_{ij \in A} c_{ij} x_{ij} \quad (5.1)$$

sujeito a:

$$\sum_{j:oj \in A} x_{oj} = 1 \quad (5.2)$$

$$\sum_{j:ij \in A} x_{ij} - \sum_{j:ji \in A} x_{ji} = 0, \quad \forall i \in N \setminus \{o, d\} \quad (5.3)$$

$$- \sum_{i:id \in A} x_{id} = -1 \quad (5.4)$$

$$x_{ij} \in \{0, 1\}, \quad \forall ij \in A \quad (5.5)$$

A função objectivo (5.1) minimiza o comprimento do caminho. As restrições (5.2) e (5.4) forçam a que o caminho comece com um e só um arco e termine com um e só um arco. As restrições (5.3) garantem a estrutura do caminho nos nodos intermédios: para cada um desses nodos, se um arco de entrada é seleccionado, um arco de saída também é e vice-versa; se não for seleccionado um arco de entrada também não é seleccionado um arco de saída. Tal como nos problemas de transportes (secção 4.1) e de afectação (secção 4.2), o problema do caminho mais curto tem a propriedade da integralidade: se as restrições de domínio (5.5) forem relaxadas, i.e. passarem a $0 \leq x_{ij} \leq 1$ (ou apenas $x_{ij} \geq 0$ já que $x_{ij} \leq 1$ está assegurado pelas restantes restrições), a solução óptima continua a ser binária.

Exemplo 5.1. Pretende-se determinar o caminho mais curto entre 1 e 6 na rede da Figura 5.2. Os valores junto aos arcos correspondem aos seus comprimentos.

As variáveis de decisão x_{ij} correspondem ao arco ij fazer parte do caminho ou não: $x_{ij} = 1$ se arco ij faz parte do caminho mais curto, $x_{ij} = 0$ caso contrário. O conjunto dos arcos da rede A , é $\{(1, 2), (1, 3), (2, 3), (2, 4), (3, 4),$




Figura 5.2: Dados do Exemplo 5.1.

$(3, 5), (4, 5), (4, 6), (5, 6)\}$. O modelo é

$$\text{Min } 7x_{12} + 12x_{13} + x_{23} + \dots + 11x_{56}$$

sujeito a:

$$x_{12} + x_{13} = 1$$

$$x_{23} + x_{24} - x_{12} = 0$$

$$x_{34} + x_{35} - x_{13} - x_{23} = 0$$

$$x_{45} + x_{46} - x_{24} - x_{34} = 0$$

$$x_{56} - x_{35} - x_{45} = 0$$

$$-x_{46} - x_{56} = -1$$

$$x_{ij} \in \{0, 1\}, \quad \forall ij \in A$$

□

5.2 Escalonamento de projectos

5.2.1 Definição

O problema de escalonamento de projectos básico define-se com base num conjunto de actividades de duração conhecida, algumas das quais com relações de precedência temporais. A relação de precedência mais comum é a que estabelece que uma actividade B só pode começar quando uma actividade A terminar. Pretende-se determinar os momentos de início de cada actividade de forma ao projecto terminar (i.e. todas as actividades estarem concluídas) o mais cedo possível. Nesta versão do problema, não se consideram recursos associados à realização das actividades. Assim, o único impedimento às actividades serem realizadas todas em simultâneo são as relações de precedência.

Para facilitar a apresentação do modelo, considera-se que existem duas actividades fictícias: uma que corresponde ao início do projeto e que precede

todas as actividades sem antecessoras (índice 0) e outra que corresponde ao final do projecto e que sucede a todas as actividades sem sucessoras (índice $n + 1$, em que n é o número de actividades). Estas duas actividades têm duração 0. Os parâmetros do problema de escalonamento são os indicados no Quadro 5.4.

Quadro 5.4 Parâmetros do problema de escalonamento de projectos.

- J conjunto das actividades;
 - p_j duração da actividade $j, j \in J$;
 - A conjunto das relações de precedência. Cada elemento deste conjunto é um par ij em que i precede j .
-

5.2.2 Modelo

As variáveis de decisão do modelo para o problema de escalonamento de projectos são as apresentadas no Quadro 5.5.

Quadro 5.5 Variáveis de decisão do modelo para o problema de escalonamento de projectos.

- x_j instante em que começa a actividade $j, j = 0, \dots, n + 1$.
-

O modelo é apresentado no Quadro 5.6.

Quadro 5.6 Modelo para o problema de escalonamento de projectos.

$$\text{Minimizar } x_{n+1} \tag{5.6}$$

Sujeito a:

$$x_j \geq x_i + p_i, \quad \forall ij \in A \tag{5.7}$$

$$x_j \geq 0, \quad j = 0, \dots, n + 1 \tag{5.8}$$

A função objectivo (5.6) corresponde à minimização do instante de início da tarefa que representa a conclusão do projecto. As restrições (5.7) garantem o cumprimento das relações de precedência: se i precede j então j só pode começar quando i terminar, o que acontece p_i unidades de tempo depois de i ter começado.

Exemplo 5.2. Um projecto sobre a aplicação de optimização a incêndios florestais é constituído pelas seguintes tarefas:

1. Revisão da literatura sobre otimização e simulação;
2. Revisão da literatura sobre modelos de propagação de fogo;
3. Concepção de modelos de otimização baseados em programação linear e inteira;
4. Concepção de modelos de otimização baseados em meta-heurísticas;
5. Concepção de modelos físicos de propagação do fogo;
6. Concepção de modelos de simulação de propagação do fogo;
7. Integração e implementação computacional dos modelos de 3 e 5;
8. Integração e implementação computacional dos modelos de 3 e 6 no problema de gestão de combustíveis;
9. Integração e implementação computacional dos modelos de 4 e 5 no problema de supressão do fogo;
10. Integração e implementação computacional dos modelos de 4 e 6 no problema de supressão do fogo;
11. Desenvolvimento de um protótipo que inclua todos os modelos desenvolvidos.

As durações das tarefas (em meses) são dadas na Tabela 5.1 e a rede da Figura 5.3 representa as relações de precedência. Por exemplo, as tarefas 3, 4 e 5 só podem começar quando a tarefa 1 estiver concluída e a tarefa 11 só pode ser iniciada quando as tarefas de 7 a 10 tiverem terminado.

Tarefa	1	2	3	4	5	6	7	8	9	10	11
Duração	4	6	4	6	7	9	8	6	4	4	6

Tabela 5.1: Parâmetros do Exemplo 5.2.

As variáveis de decisão x_j correspondem ao instante em que se inicia a




Figura 5.3: Relações de precedência do Exemplo 5.2.

tarefa $j, j = 1, \dots, 12$. O modelo é

Minimizar x_{12}

Sujeito a:

$$x_1 \geq 0$$

$$x_2 \geq 0$$

$$x_3 \geq x_1 + 4$$

$$x_5 \geq x_1 + 4$$

$$x_4 \geq x_1 + 4$$

$$x_6 \geq x_2 + 6$$

...

$$x_{11} \geq x_7 + 8$$

$$x_{11} \geq x_8 + 6$$

$$x_{11} \geq x_9 + 4$$

$$x_{11} \geq x_{10} + 4$$

$$x_{12} \geq x_{11} + 6$$

$$x_j \geq 0, \quad j = 1, \dots, 12$$

□

Obtém-se um modelo alternativo ao apresentado associando-se a duração da actividade de origem a cada arco e determinando-se o caminho mais longo entre 0 e $n + 1$. Trata-se do caminho mais longo e não do caminho mais curto, porque só se pode iniciar uma actividade depois de todas as suas precedentes terem terminado, ou seja $x_j = \text{Max}\{x_i + p_i, \forall i, j \in A\}$.

5.3 Exercícios

Exercício 5.1. Um aspecto essencial da gestão de redes de telecomunicações é a forma como o tráfego é encaminhado na rede, i.e. quais os nodos e arcos que as mensagens atravessam desde o nodo onde têm origem até ao nodo a que se destinam. Entre muitos protocolos e variantes, uma forma de o fazer é usar apenas um caminho para cada mensagem. O gestor de rede tem a possibilidade de configurar os pesos dos arcos da rede para privilegiar determinados arcos em função de outros (por exemplo, por suportarem uma maior largura de banda). O gestor da rede representada na Figura 5.4 atribuiu os pesos indicados junto aos arcos.




Figura 5.4: Rede do exercício 5.1.

Sabendo que o protocolo usado encaminha o tráfego pelo caminho mais curto:

- Apresente um modelo que permita obter o caminho mais curto entre 1 e 6.
- Apresente um modelo que, dada uma origem, o , e um destino, d , permita obter o caminho mais curto entre ambos na rede em causa.

Exercício 5.2. Uma medida muito utilizada na análise de redes sociais é centralidade de intermediação (*betweenness centrality*). Esta medida permite quantificar a relevância de um nodo (um actor na terminologia das redes sociais) na rede em causa, que pode ser, por exemplo, de contactos ou de amizades em plataformas sociais. A centralidade de intermediação de um nodo é dada pela razão entre o número de caminhos mais curtos que incluem o nodo e o número total de caminhos mais curtos entre todos os pares de nodos.




Figura 5.5: Uma rede social: nodos representam famílias de elite na Renascença florentina, arcos representam casamentos entre membros de duas famílias.

Relativamente à rede da Figura 5.5 ²:

- Apresente um modelo para obter o caminho mais curto entre 2 e 15.
- Apresente um modelo para obter os nodos que fazem parte do caminho mais curto entre 2 e 15.
- Descreva o procedimento, baseado no cálculo individual dos caminhos mais curtos, para obter a centralidade de intermediação de todos os nodos.

²Padgett, J. F., and Ansell, C. K. (1993). Robust Action and the Rise of the Medici, 1400-1434. *American journal of sociology*, 98(6), 1259-1319.

Exercício 5.3. Pretende-se obter o caminho mais fiável numa rede em que é conhecida a fiabilidade de cada arco (i.e. a probabilidade do arco não falhar). Representa-se a fiabilidade do arco ij por $p_{ij}, \forall ij \in A$. A fiabilidade de um caminho é o produto das fiabilidades dos arcos que o compõem. A utilização directa de um modelo não é viável por a função da fiabilidade em função dos arcos seleccionados ser não linear. Definindo formalmente as variáveis de decisão $x_{ij} = 1$ se arco ij é seleccionado para o caminho e $x_{ij} = 0$ caso contrário, a fiabilidade de um caminho é dada pela expressão não linear por $\prod_{ij \in A} p_{ij} x_{ij}$. No entanto, é possível efectuar uma transformação para um problema equivalente, tendo em conta que um caminho que maximize a fiabilidade também maximiza o logaritmo da fiabilidade. Ou seja, $\text{Max} \prod_{ij \in A} p_{ij} x_{ij}$ é equivalente a

$$\text{Minimizar} \sum_{ij \in A} (-\log(p_{ij})) x_{ij}$$

Apresente um modelo para determinar o caminho mais fiável entre 1 e 10 da rede da Figura 5.6.




Figura 5.6: Exemplo de uma rede.

Exercício 5.4. Uma empresa de *software* pretende desenvolver uma nova aplicação que envolve a programação de 7 módulos (representados pelas letras de A a G para manter o sigilo). As relações de precedência entre os módulos bem como a sua duração (em semanas) são apresentados na Tabela II.

Módulo	Duração(semanas)	Módulos precedentes
A	3	–
B	5	–
C	4	A
D	8	A,B
E	10	B
F	10	C,D
G	7	D,E

Tabela 5.2: Parâmetros do Exercício II.

- Apresente um modelo que permita obter a duração mínima do projecto com variáveis de decisão associadas a tempos.
- Apresente um modelo que permita obter a duração mínima do projecto com variáveis de decisão associadas à definição do caminho crítico (caminho composto pelas actividades que definem a duração do projecto).

Exercício 5.5. A produção de um produto envolve 10 operações. Existem dois tipos de precedência relevantes no processo produtivo: precedência fim-início, em que uma operação só pode começar depois de outra terminar e início-início, em que uma operação só pode depois de outra também começar. A Tabela 5.3 indica a duração e o tipos de precedências entre as operações.

Operação	Duração(horas)	Precedentes F-I	Precedentes I-I
1	5	2	-
2	3	-	-
3	2	1	-
4	3	3	-
5	4	1	-
6	8	-	4
7	5	8	4
8	2	1	3
9	2	6,7,10	-
10	3	8,5	7

Tabela 5.3: Parâmetros do Exercício II.

Apresente um modelo que permita obter a duração mínima do projecto.

Exercício 5.6. Indique o número de variáveis de decisão, o número de restrições e o número de coeficientes não nulos das variáveis de decisão nas restrições de um modelo para o problema do caminho mais curto numa rede com n nodos e m arcos.

Exercício 5.7. Considere uma rede em que todos os comprimentos dos arcos são positivos. Em que circunstâncias o modelo para determinar o caminho mais curto não é directamente adaptável para o problema de determinar o caminho mais longo?

Parte II

Software

6

Folhas de cálculo

6.1 Visão geral

As folhas de cálculo comuns dispõem de um suplemento (*add-in*) que permite de a resolução de modelos de programação linear e inteira através do método simplex e do método de partição e avaliação, respectivamente. No *Microsoft Excel* o suplemento designa-se por *solver* e está acessível em *Data->Analyze* (se não estiver, terá de ser instalado de forma gratuita).

Neste texto, usa-se o *solver* para ilustrar a utilização deste tipo de suplementos, tendo consciência das suas limitações em termos de eficiência do motor de optimização (i.e. a implementação dos métodos de optimização) e de dimensão dos problemas que podem ser resolvidos¹.

É possível, mantendo as vantagens da interface ser uma folha de cálculo (fácil utilização, clareza do modelo, integração com outras ferramentas de escritório), usar um motor de optimização mais potente e sem limitações de dimensão através do software *open source OpenSolver*².

A optimização de um modelo numa folha de cálculo pode ser dividida em quatro passos. No primeiro passo, o modelo é introduzido na folha de cálculo. Tal corresponde a definir células para os parâmetros e para as variáveis de decisão e introduzir noutras células funções que relacionam as variáveis de decisão e os parâmetros. No segundo passo, o modelo é carregado para o *solver* através da sua caixa de diálogo, sendo indicadas quais as células que correspondem a quê, o sentido da optimização e o domínio das variáveis. No terceiro passo escolhem-se as opções da optimização (numa utilização básica, poder-se-á manter os valores por omissão). No quarto passo procede-se à optimização do modelo, interpretação e validação do resultado obtido. Adicionalmente, em programação linear, é possível aceder a um relatório

¹Na versão gratuita, o problema a ser resolvido não pode ter mais de 200 variáveis de decisão e 100 restrições - excluindo limites e domínios das variáveis de decisão.

²<https://opensolver.org>. Um modelo introduzido no *solver*, por exemplo numa fase de prototipagem, é carregado sem alterações pelo *OpenSolver*.

de análise de sensibilidade, com informação relativa ao comportamento da solução perante variações dos parâmetros do modelo.

6.2 Produção

6.2.1 Introdução do modelo na folha de cálculo

Nas secções seguintes exemplifica-se a aplicação do *solver* com o modelo para o problema de produção do Exemplo 2.1 (página 5) que agora se reescreve. Variáveis de decisão:

- x_j quantidade a produzir do produto j , $j = 1, 2, 3$.

Modelo:

$$\text{Maximizar } z = 25x_1 + 27x_2 + 33x_3$$

Sujeito a:

$$10x_1 + 20x_2 + 30x_3 \leq 112 \quad [\text{M1}]$$

$$9x_1 + 3x_2 + 5x_3 \leq 80 \quad [\text{M2}]$$

$$4x_1 + 3x_2 + x_3 \leq 30 \quad [\text{MP1}]$$

$$34x_1 + 35x_2 + 17x_3 \leq 300 \quad [\text{MP2}]$$

$$x_1, x_2, x_3 \geq 0$$

Este modelo também pode ser representado matricialmente:

$$\text{Max } z = \begin{bmatrix} 25 & 27 & 33 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

Sujeito a:

$$\begin{bmatrix} 10 & 20 & 30 \\ 9 & 3 & 5 \\ 4 & 3 & 1 \\ 34 & 35 & 17 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \leq \begin{bmatrix} 112 \\ 80 \\ 30 \\ 300 \end{bmatrix}$$

$$x \geq 0$$

ou, usando notação mais geral:

$$\max z = px$$

s.a:

$$Ax \leq b;$$

$$x \geq 0.$$

Na Figura 6.1 mostra-se a definição das células das variáveis de decisão (fundo amarelo, células C3:E3) e os parâmetros (células com valores em

fundo branco: coeficientes das variáveis na função objectivo e nas restrições, e termos independentes.). Tipicamente, é vantajoso introduzir o modelo por vectores e matrizes como identificados na Figura 6.2.

	A	B	C	D	E	F	G	H
1								
2			P1	P2	P3			
3								
4						LHS		RHS
5		M1	10	20	30	0	<=	112
6		M2	9	3	5	0	<=	80
7		MP1	4	3	1	0	<=	30
8		MP2	34	35	17	0	<=	300
9						z		
10		Benefício	25	27	33	0		

Figura 6.1: Variáveis de decisão e parâmetros do modelo do exemplo.

	A	B	C	D	E	F	G	H
1								
2								
3		x						
4						Ax		b
5		A	10	20	30		<=	112
6			9	3	5		<=	80
7			4	3	1		<=	30
8			34	35	17		<=	300
9						z		
10		p	25	27	33			

Figura 6.2: Variáveis de decisão e parâmetros do modelo do exemplo - identificação dos vectores, matriz e escalar.

Na Figura 6.3 mostra-se a introdução das fórmulas que relacionam variáveis de decisão e os parâmetros nas células com o lado esquerdo das restrições (fundo azul, células F5:F8, fórmula da figura é a da célula F5) e na célula da função objectivo (fundo verde, célula F10). Note-se que a organização das células (variáveis de decisão associadas a colunas e restrições associadas a linhas) e o uso de referências absolutas (com \$ como na figuras ou atribuindo nomes às células) facilita em muito a introdução do modelo já que permite fazer *copy-paste* de fórmulas entre células (na prática “arrastar” células).

A forma de carregar restrições é por comparação entre o valor de células, nomeadamente entre o lado esquerdo das restrições, LHS, de *left-hand side*, (Ax) e o seu lado direito, RHS, de *right-hand side*, (b). Assim, faz sentido colocar as células com o lado esquerdo alinhadas com as células dos termos independentes.

A utilização da função *SUMPRODUCT* (*SOMARPRODUTO* na versão portuguesa) é indispensável pois permite a representação na folha de cálculo dos lados esquerdos das restrições e da função objectivo de forma eficiente.

Esta função recebe conjuntos de células com a mesma forma e dimensão como argumentos (no exemplo e no caso da função objectivo os argumentos são os dois conjuntos de células C3:E3 e C10:E10) e retorna a soma dos produtos das células na mesma posição dos diferentes argumentos (no exemplo e no caso da função objectivo retorna $C3 \cdot C10 + D3 \cdot D10 + E3 \cdot E10$, o que tendo em conta o conteúdo e significado das células corresponde à função objectivo do modelo, i.e. $25x_1 + 27x_2 + 33x_3$). Olhando para os dois conjuntos de células (argumentos) como sendo vectores, a função *SUMPRODUCT* corresponde ao produto interno dos dois vectores. Em termos vectoriais a função calcula $A_i x$, ou seja o produto interno do vector dos coeficientes das variáveis de decisão na i -ésima restrição (A_i) pelo vector das variáveis de decisão.

	A	B	C	D	E	F	G	H
1								
2			P1	P2	P3			
3								
4						LHS		RHS
5		M1	10	20	30	=SUMPRODUCT(\$C\$3:\$E\$3;C5:E5)	<=	112
6		M2	9	3	5	=SUMPRODUCT(\$C\$3:\$E\$3;C6:E6)	<=	80
7		MP1	4	3	1	=SUMPRODUCT(\$C\$3:\$E\$3;C7:E7)	<=	30
8		MP2	34	35	17	=SUMPRODUCT(\$C\$3:\$E\$3;C8:E8)	<=	300
9						z		
10		Beneficio	25	27	33	=SUMPRODUCT(\$C\$3:\$E\$3;C10:E10)		
11								

Figura 6.3: Fórmulas dos lados esquerdos das restrições e função objectivo.

6.2.2 Carregamento do modelo no *solver*

Depois de preparada a folha de cálculo, o modelo é carregado no *solver* através da caixa de diálogo que se abre premindo *Data* e depois *Solver* (se o botão *Solver* não estiver disponível é necessário instalar esse suplemento (*add-in*). Como regra geral, nos campos a preencher, devem ser usadas referências para células. Em situações excepcionais poderá ser prático usar constantes, mas em caso algum deverão ser usadas fórmulas.

A caixa de diálogo do *solver* é reproduzida na 6.4. Seguindo a ordem de cima para baixo, deve-se:

- Inserir a referência para a célula da função objectivo (no exemplo F10).
- Seleccionar o sentido da optimização (no exemplo, Max).
- Inserir as referências para as células com as variáveis de decisão (no exemplo, C3:E3).
- Premir o botão *Add* para aceder à caixa de diálogo que permite inserir as restrições (representada na Figura 6.5). Esta inserção é feita


através das referências para as células com os lados esquerdos, sentido das restrições e referências para os termos independentes. Por rapidez, clareza e facilidade de correcção de eventuais erros, as restrições devem ser agrupadas em vez de inseridas uma a uma. Na Figura 6.6 representa-se a inserção das quatro restrições do exemplo. Note-se que o menor ou igual das células G5:G8 da folha de cálculo não têm significado para o *solver* - foram colocados apenas para tornar o modelo mais explícito. As restrições, incluindo o seu sentido, são introduzidas como acabou de ser descrito.

- Também na caixa de diálogo *Add constraint* inserir restrições de integralidade (geral ou binária) caso existam.
- Indicar que todas as variáveis são não negativas.
- Seleccionar *simplex LP* como método de resolução (existindo ou não variáveis binárias ou inteiras gerais).

6.2.3 Opções

Na Figura 6.7 é apresentada a caixa de diálogo das opções do *solver*. Uma restrição é considerada satisfeita pelo *solver* se a diferença entre o lado esquerdo e o termo independente é maior do que o valor da *Constraint Precision* (em restrições de menor ou igual). Quando seleccionada a opção *Automatic Scaling*, o *solver* tenta reduzir as diferenças de magnitude entre os parâmetros do problema para reduzir erros numéricos. Se seleccionada a opção *Show Iteration Results*, após cada iteração simplex, a solução é mostrada na folha de cálculo e uma caixa de diálogo permite interromper a optimização. A opção *Ignore Integer constraints* conduz à resolução da relaxação linear. O *solver* pára a optimização e retorna a melhor solução obtida até ao momento quando:

- O gap relativo é inferior a *Integer Optimality*;
- Decorreram *Max Time* segundos desde o início da optimização;
- Foram efectuadas *Iterations* iterações simplex;
- Foram resolvidos *Max Subproblems* nodos da árvore de pesquisa;
- Foram obtidas *Max Feasible Solutions* soluções inteiras;

Figura 6.4: Caixa de diálogo do *solver*.

6.2.4 Optimização, interpretação e validação

A optimização é iniciada premindo o botão *Solve*.

O tempo que a optimização demora depende de vários factores. Antes de mais do tipo de problema: se não tiver variáveis inteiras, a optimização termina imediatamente ou após alguns segundos (dada a eficiência do algoritmo simplex); se o problema tiver variáveis inteiras, não é fácil prever o tempo que demorará a ser resolvido (exceptuando os casos dos problemas cuja solução óptima da relaxação linear é inteira). De facto, problemas difíceis poderão demorar várias horas ou mesmo não serem resolúveis. Tal deve-se à inerente dificuldade da programação inteira e não necessariamente à dimensão do problema ou à falta de poder computacional. É de notar que motores de optimização de estado-da-arte (como o *cplex* ou o *gurobi*)




Figura 6.5: Caixa de diálogo para adição de uma restrição.





Figura 6.6: Exemplo de inserção de restrições.

têm um desempenho muito superior ao *solver*, dado o arsenal de componentes que incluem no método de partição e avaliação derivados de resultados teóricos e experimentais. Em qualquer caso, premindo a tecla "ESC" a optimização pode ser interrompida e obtida a solução incumbente. Para reduzir o tempo de optimização *a priori* podem ser definidos critérios de paragem mais apertados (com as opções já descritas).

A janela que aparece quando a optimização termina de forma “natural” (i.e., com a solução óptima ou com a solução incumbente porque um dos critérios de paragem foi satisfeito) é representada na Figura 6.8. O *solver* coloca a solução obtida nas células das variáveis de decisão.

Em programação linear e inteira, a função objectivo e os lados esquerdos das restrições têm de ser lineares, i.e. serem a soma de produtos de variáveis por constantes (não pode haver produtos de variáveis, variáveis ao quadrado, raíze quadradas de variáveis...). Assim, ao contrário de células com constantes do modelo, as células que lhes correspondem não podem usar funções como IF ou MAX (que são não lineares). Por exemplo, se quiséssemos que a maior quantidade produzida de um produto não pudesse exceder um determinado valor k , poderíamos introduzir uma restrição “ $\text{MAX}(\text{C3:E3}) \leq k$ ”. Esta restrição, embora formalmente correcta, conduz a uma modelo não linear e a janela do resultado da optimização será o apresentado na Figura 6.9. Este aspecto reforça a importância de ter o modelo matemático explícito matematicamente antes de o introduzir na folha de cálculo. Como será descrito posteriormente, a programação inteira permite ultrapassar algumas

Figura 6.7: Caixa de diálogo das opções do *solver*.

destas limitações ao modelar relações lógicas e máximos de funções através da inclusão de restrições e variáveis adicionais.

Outros resultados possíveis são o problema ser impossível ou ilimitado, o que, usualmente, são consequência de o modelo ter sido mal introduzido. No caso do modelo ser impossível, é possível aceder a um relatório que indica as restrições violadas.

É de salientar que, no caso de ter sido detectado que o modelo é não linear, impossível ou ilimitado, a solução apresentada na folha de cálculo não tem significado.

Em modelos com alguma complexidade, mais sujeitos a erros na construção e introdução do modelo, a validação da solução é um aspecto importante. A verificação que as variáveis respeitam o seu domínio (notar que se não estiverem a ser mostradas casas decimais, uma célula pode parecer ter um valor inteiro sem tal acontecer), e que o valor do lado esquerdo das restrições e função objectivo apresentam valores razoáveis são também





Figura 6.8: Optimização obteve solução.

Figura 6.9: Janela de resultado quando *solver* detecta que modelo não é linear.

aconselhados.

No caso de modelos de alguma complexidade em que não se está a obter o resultado pretendido, depois de verificado o modelo matemático, os grupos de restrições podem ser inseridos sequencialmente, otimizando o modelo após a introdução de cada grupo, tentando-se identificar a causa do problema (e.g. problema ser impossível).

Outra forma de identificar erros num modelo é colocar valores nas variáveis de decisão (i.e. considerar uma solução) e verificar a razoabilidade das restrições e função objectivo.

6.3 Análise de sensibilidade

Em programação linear (mas não em programação inteira, nem em programação inteira mista), após uma otimização com sucesso é possível aceder a um relatório de análise de sensibilidade (que aparece numa nova folha) como o apresentado na Figura 6.10 que corresponde ao exemplo.

	A	B	C	D	E	F	G	H
1								
2	Variable Cells							
3				Final	Reduced	Objective	Allowable	Allowable
4		Cell	Name	Value	Cost	Coefficient	Increase	Decrease
5	\$C\$3	P1		7,16	0	25	107	6,14
6	\$D\$3	P2		0	-3,91	27	3,91	1E+30
7	\$E\$3	P3		1,35	0	33	42	8,6
8								
9	Constraints							
10				Final	Shadow	Constraint	Allowable	Allowable
11		Cell	Name	Value	Price	R.H. Side	Increase	Decrease
12	\$F\$5	M1 LHS		112	0,97	112	88	37
13	\$F\$6	M2 LHS		71,2	0	80	1E+30	8,8
14	\$F\$7	MP1 LHS		30	3,82	30	4,34	26,27
15	\$F\$8	MP2 LHS		266,44	0	300	1E+30	33,56

Figura 6.10: Análise de sensibilidade.

É importante notar que as análises feitas apenas são válidas para alterações num coeficiente. Caso as alterações envolvam mais do que um coeficiente, é necessário fazer as alterações correspondentes no modelo e reoptimizar.

O significado dos valores apresentados relativos às variáveis é dado de seguida.

- *Final Value* Valor da variável na solução óptima.
- *Reduced Cost* O custo reduzido pode ser interpretado como o valor que é necessário subtrair ao coeficiente de uma variável para, numa solução óptima, ter um valor positivo. Assim, variáveis com valores positivos têm custo reduzido zero (no exemplo, P1 e P3). No exemplo, o custo reduzido de P2 é -3.91 , haverá produção de P2 na solução óptima se o seu coeficiente na função objectivo passar a $27 + 3.91 = 30.91$. Para variáveis com valor nulo o custo reduzido também pode ser visto como a variação marginal do valor da função objectivo em função da variável. No exemplo, a função objectivo passa a ter o valor de $223.49 - 3.91 = 219.58$ se a variável x_2 for forçada a tomar o valor 1, que corresponde a dizer que é necessário produzir uma unidade de P2³.

³Pode ser verificado introduzindo a restrição $x_2 = 1$ e optimizando.

Custos reduzidos nulos em variáveis nulas indicam a existência de soluções óptimas alternativas. Obter-se-á uma solução óptima alternativa aumentando infinitesimalmente o coeficiente da função objectivo dessa variável.

- *Objective Coefficient* Coeficiente da função objectivo.
- *Allowable Increase and Decrease* Permite o cálculo do intervalo do coeficiente da função objectivo dentro do qual a solução se mantém óptima. Por exemplo, a solução permanece óptima qualquer que seja o valor do coeficiente de P1 no intervalo com limite inferior $25 - 6.14$ e limite superior $25 + 107$, ou seja o intervalo $[18.86, 132]$. Reforça-se que esta análise apenas é válida para a variação de apenas um dos coeficientes.

A interpretação dos valores relativamente às restrições é dado de seguida.

- *Final Value* Valor do lado esquerdo das restrições.
- *Shadow Price* Os valores dos preços-sombra correspondem à variação marginal do valor da função objectivo em função da variação do termo independente. Por exemplo, a função objectivo aumenta 0.97 se houver mais uma hora de disponibilidade na máquina M1. Naturalmente, para restrições com folga (M2 e MP2) o preço sombra é zero. Esta análise apenas é válida para a variação de apenas um dos termos independentes.
- *Constraint R.H. Side* Termos independentes das restrições.
- *Allowable Increase and Decrease* Permitem o cálculo do intervalo dos termos independentes não alteram os preços-sombra. Por exemplo, o valor do preço-sombra de M1 é válido no intervalo com limite inferior $112 - 37$ e limite superior $112 + 88$, ou seja o intervalo $[75, 200]$. Este intervalo corresponde ao intervalo em que o conjunto de produtos produzidos (P1 e P3) não se altera (embora as quantidades produzidas se alterem - as disponibilidades dos recursos alteram-se). Reforça-se que esta análise apenas é válida para a variação de apenas um dos termos independentes.

A análise de sensibilidade está directamente relacionada com o quadro óptimo do simplex. As variáveis básicas são as que têm valores positivos⁴ e aquelas que estão associadas a restrições com folga (o termo independente menos o lado esquerdo é o valor da variável de folga). No exemplo, como o problema tem quatro restrições, as variáveis básicas são quatro: P1, P3 e as variáveis de folga das restrições M2 e MP2. Os (simétricos⁵ dos) cus-

⁴A análise de soluções degeneradas, em que há variáveis básicas com valor zero, complica sem enriquecer a análise presente.

⁵Devido à convenção para os sinais da linha da função objectivo usada neste texto.

tos reduzidos e os preços-sombra correspondem aos coeficientes da linha da função objectivo do quadro simplex como representado de seguida.

	x	s	
x_B	-custos reduzidos preços sombra		z

6.4 Caminho mais curto

Apresenta-se um outro exemplo de aplicação do *solver* com o modelo do Exemplo 5.1 que agora se reescreve. Na Figura 6.11 apresenta-se a rede na qual se pretende determinar o caminho mais curto entre os nodos 1 e 6.




Figura 6.11: Rede do Exemplo 5.1.

O modelo é:

$$\text{Min } z = 7x_{12} + 12x_{13} + x_{23} + \dots + 11x_{56}$$

Sujeito a:

$$x_{12} + x_{13} = 1$$

$$x_{23} + x_{24} - x_{12} = 0$$

$$x_{34} + x_{35} - x_{13} - x_{23} = 0$$

$$x_{45} + x_{46} - x_{24} - x_{34} = 0$$

$$x_{56} - x_{35} - x_{45} = 0$$

$$-x_{46} - x_{56} = -1$$

$$x_{ij} \in \{0, 1\}, \quad \forall ij \in A$$

Representa-se o modelo na Figura 6.12 após introduzir os parâmetros, definir o nome “VD” (Formulas -> Define Name) para o conjunto das células com as variáveis de decisão (C4:K4) e introduzir as fórmulas para os lados esquerdos e função objectivo.

A matriz A (coeficientes das variáveis de decisão nas restrições) tem uma estrutura particular que deriva de ser uma representação de uma rede (de

facto, em terminologia de redes tem uma designação própria - matriz de adjacência nodo-arco). Cada coluna está associada a um arco e tem dois elementos não nulos: um +1 na linha do nodo onde começa o arco e um -1 na linha em que acaba o arco. A relaxação linear de qualquer problema cuja matriz A tenha esta estrutura tem uma solução óptima inteira (se os termos independentes forem inteiros).

Na Figura 6.13 apresenta-se a caixa de diálogo do *solver* e na Figura 6.14 a folha após a optimização. As células com valor 1 foram destacadas usando a formatação condicional (Home -> Conditional Formatting). A solução óptima corresponde assim ao caminho 1-4-6 com comprimento 25.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1															
2		arco	12	13	23	24	34	35	45	46	56				
3		VD													
4															
5		FO	7	12	4	10	6	3	6	8	11		=SUMPRODUCT(VD;C5:K5)		
6															
7		nodo 1	1	1									=SUMPRODUCT(VD;C7:K7)	=	1
8		nodo 2	-1		1	1							=SUMPRODUCT(VD;C8:K8)	=	0
9		nodo 3		-1	-1		1	1					=SUMPRODUCT(VD;C9:K9)	=	0
10		nodo 4				-1	-1		1	1			=SUMPRODUCT(VD;C10:K10)	=	0
11		nodo 5						-1	-1		1		=SUMPRODUCT(VD;C11:K11)	=	0
12		nodo 6								-1	-1		=SUMPRODUCT(VD;C12:K12)	=	-1

Figura 6.12: Introdução do modelo.

6.5 Afectação

Qualquer modelo matemático pode ser representado de forma geral e introduzido numa folha de cálculo como descrito e exemplificado nas secções anteriores em que as variáveis de decisão são associadas a colunas e as restrições a linhas.

Quando os modelos têm estrutura, i.e. quando os coeficientes das variáveis de decisão nas restrições não são arbitrários, pode haver vantagem em explorá-la para maior rapidez e clareza na introdução do modelo.

Considera-se o Exemplo 4.2 em que as variáveis de decisão, x_{ij} , indicam se o enfermeiro j faz o turno i ou não. A função objectivo traduz o objectivo da soma das preferências dos enfermeiros tomar o menor valor possível (lembra-se que um valor menor corresponde a uma maior preferência).




Figura 6.13: Carregamento do modelo.

Relembra-se o modelo:

Minimizar $z = x_{11} + x_{12} + x_{13} + 3x_{14} + \dots + 6x_{10,8} + 10x_{10,9} + 9x_{10,10}$

Sujeito a:

$$x_{11} + x_{12} + \dots + x_{1,10} = 1 \quad [\text{T01}]$$

$$x_{21} + x_{22} + \dots + x_{2,10} = 1 \quad [\text{T02}]$$

...

$$x_{10,1} + x_{10,2} + \dots + x_{10,10} = 1 \quad [\text{T10}]$$

$$x_{11} + x_{21} + \dots + x_{10,1} = 1 \quad [\text{E01}]$$

$$x_{12} + x_{22} + \dots + x_{10,2} = 1 \quad [\text{E02}]$$

...

$$x_{1,10} + x_{2,10} + \dots + x_{10,10} = 1 \quad [\text{E10}]$$

$$x_{ij} \in \{0, 1\}, \quad i = 1, \dots, 10; j = 1, \dots, 10$$

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1															
2		arco	12	13	23	24	34	35	45	46	56				
3		VD	1	0	0	1	0	0	0	1	0				
4															
5		FO	7	12	4	10	6	3	6	8	11		25		
6															
7		nodo 1	1	1									1	=	1
8		nodo 2	-1		1	1							0	=	0
9		nodo 3		-1	-1		1	1					0	=	0
10		nodo 4				-1	-1		1	1			0	=	0
11		nodo 5						-1	-1		1		0	=	0
12		nodo 6								-1	-1		-1	=	-1

Figura 6.14: Folha com a solução óptima obtida pelo *solver*.

Se se representar as variáveis de decisão como um vector, como nos exemplos anteriores, ter-se-á uma matriz dos coeficientes das variáveis de decisão nas restrições (matriz A) com 100 colunas e 20 linhas - 2000 células. Por outro lado, se se representar as variáveis de decisão como uma matriz e se tirar proveito da estrutura do modelo para definir as restrições, a matriz A não é necessária. Dispondo as variáveis de decisão numa matriz 10 por 10 em que as linhas estão associadas aos turnos e as colunas aos enfermeiros, o que as restrições indicam é que soma das células de cada linha e de cada coluna tem de ser um. Esta forma de introduzir o modelo é mostrada na Figura 6.15. A caixa de diálogo do *solver* na Figura 6.16 e a solução óptima na Figura 6.17.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z									
	E1	E2	E3	E4	E5	E6	E7	E8	E9	E10							E1	E2	E3	E4	E5	E6	E7	E8	E9	E10									
1																	1	1	1	3	5	3	5	1	1	2									
2	T1												=SUM(C3:I3) =SUM(C4:I4) =SUM(C5:I5) =SUM(C6:I6) =SUM(C7:I7) =SUM(C8:I8) =SUM(C9:I9) =SUM(C10:I10) =SUM(C11:I11) =SUM(C12:I12)	=	1																				
3	T2													=	1		3	2	7	9	6	2	3	1											
4	T3													=	1		2	10	3	1	3	2	7	4	2	3									
5	T4													=	1		8	4	4	6	7	1	5	4	5										
6	T5													=	1		9	5	5	2	4	6	2	9	5	4									
7	T6													=	1		4	3	6	5	7	5	3	10	6	8									
8	T7													=	1		5	6	7	8	10	4	8	6	10	7									
9	T8													=	1		7	7	8	9	1	10	9	8	9	6									
10	T9													=	1		6	8	9	10	2	8	10	7	7	10									
11	T10													=	1		10	9	10	6	8	1	4	3	8	9									
12																																			
13		=SUM(C3:C12)	=SUM(D3:D12)	=SUM(E3:E12)	=SUM(F3:F12)	=SUM(G3:G12)	=SUM(H3:H12)	=SUM(I3:I12)	=SUM(J3:J12)	=SUM(K3:K12)	=SUM(L3:L12)																								
14		=	=	=	=	=	=	=	=	=	=																								
15		1	1	1	1	1	1	1	1	1	1																								

Figura 6.15: Introdução de um modelo com estrutura no *solver*.




Figura 6.16: Carregamento do modelo com estrutura.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	
1																												
2			E1	E2	E3	E4	E5	E6	E7	E8	E9	E10							E1	E2	E3	E4	E5	E6	E7	E8	E9	E10
3		T1	0	0	1	0	0	0	0	0	0	0		1	=	1		1	1	1	3	5	3	5	1	1	2	
4		T2	0	0	0	0	0	0	0	0	0	0		1	=	1		3	2	2	7	9	9	6	2	3	1	
5		T3	0	0	0	0	0	0	0	0	0	1	0		1	=	1		2	10	3	1	3	2	7	4	2	3
6		T4	0	0	0	0	0	0	0	1	0	0	0		1	=	1		8	4	4	4	6	7	1	5	4	5
7		T5	0	0	0	1	0	0	0	0	0	0	0		1	=	1		9	5	5	2	4	6	2	9	5	4
8		T6	0	1	0	0	0	0	0	0	0	0	0		1	=	1		4	3	6	5	7	5	3	10	6	8
9		T7	0	0	0	0	0	0	1	0	0	0	0		1	=	1		5	6	7	8	10	4	8	6	10	7
10		T8	0	0	0	0	1	0	0	0	0	0	0		1	=	1		7	7	8	9	1	10	9	8	9	6
11		T9	1	0	0	0	0	0	0	0	0	0	0		1	=	1		6	8	9	10	2	8	10	7	7	10
12		T10	0	0	0	0	0	0	0	0	1	0	0		1	=	1		10	9	10	6	8	1	4	3	8	9
13																												
14			1	1	1	1	1	1	1	1	1	1		24														
15			=	=	=	=	=	=	=	=	=	=																
16			1	1	1	1	1	1	1	1	1	1																
17																												

Figura 6.17: Folha com a solução óptima obtida pelo *solver*.

6.6 Exercícios

Exercício 6.1. Uma empresa fabrica 3 tipos de produtos (P1, P2 e P3) com recurso ao trabalho de dois colaboradores. Para a semana em causa, o primeiro colaborador (C1) tem uma disponibilidade de 48 horas e o segundo (C2) de 56 horas. Cada unidade P1, P2 e P3 necessitam de 2, 1 e 2 horas de C1 e 2, 3 e 5 horas de C2, respectivamente. Estima-se um lucro de 5, 7 e 12 U.M. para cada produto (pela mesma ordem que a usada anteriormente).

- a) Apresente um modelo de programação matemática.
- b) Descreva como introduziria o modelo da alínea anterior numa folha de cálculo, indicando claramente:
 1. As células correspondentes às variáveis de decisão;
 2. As fórmulas a usar nas células relativas às restrições;
 3. A fórmula a usar na célula relativa à função objectivo. indique:
 4. O que colocar em “Set Objective” na caixa de diálogo do *solver*.
 5. O que colocar em “Subject to the Constraints” na caixa de diálogo do *solver*.

Exercício 6.2. Uma empresa pretende transportar um determinado produto de três armazéns onde está disponível (A, B e C) para quatro clientes (1, 2, 3 e 4). Os custos unitários de transporte entre cada armazém e cada cliente são dados na tabela abaixo. As quantidades disponíveis nos armazéns são 34, 123 e 75 e as quantidades requeridas pelos clientes são 30, 35, 64 e 23.

- a) Apresente um modelo de programação matemática.
- b) Descreva como introduziria o modelo da alínea anterior numa folha de cálculo, indicando claramente:
 1. As células correspondentes às variáveis de decisão;
 2. As fórmulas a usar nas células relativas às restrições;
 3. A fórmula a usar na célula relativa à função objectivo.
 4. O que colocar em “Set Objective” na caixa de diálogo do *solver*.
 5. O que colocar em “Subject to the Constraints” na caixa de diálogo do *solver*.

Exercício 6.3. Obtenha a solução óptima dos seguintes problemas através da utilização do *solver*:

- Problema da mochila do Exemplo 2.4 (ver página 10).
- Problema de empacotamento do Exemplo 2.5 (ver página 12).
- Problema de produção inversa do Exemplo 3.1 (ver página 19).
- Problema de cobertura do Exemplo 3.2 (ver página 22).
- Problema de transportes do Exemplo 4.1 (ver página 31).
- Problema de escalonamento de projectos do Exemplo 5.2 (ver página 46).

Exercício 6.4. A Figura 6.18 mostra um modelo para o problema de transportes como introduzido no *excel* e a correspondente caixa de diálogo do *solver*. A solução apresentada é uma solução óptima.

	A	B	C	D	E	F	G
1							
2		3	4	6	2		
3		2	5	1	4		
4		1	9	8	9		
5		4	3	5	8		
6							
7		0	0	0	100	100	100
8		0	0	80	40	120	120
9		90	0	0	40	130	130
10		0	110	30	0	140	140
11		90	110	110	180		
12		90	110	110	180		1370

Solver Parameters

Set Target Cell:

Equal To: ☐ Max ☒ Min ☐ Value of:

By Changing Cells:

Subject to the Constraints:

Figura 6.18: Folha de cálculo de caixa de diálogo do *solver* do Exercício 6.4.

- Apresente o modelo de programação linear definindo claramente as variáveis de decisão.
- Indique as fórmulas que foram inseridas nas células F7 a F10, B11 a E11 e G12.

Exercício 6.5. Na Figura 6.19 apresenta-se uma folha de cálculo para inserção do modelo de programação linear representado.

$$\text{Max } z = 6x_1 + 3x_2 + 2x_3$$

s.a:

$$x_1 - x_2 + x_3 \leq 40$$

$$2x_1 + x_2 + x_3 \leq 10$$

$$x_1 + x_3 \leq 20$$

$$x_1, x_2, x_3 \geq 0$$

	A	B	C	D	E	F	G	H
1								
2								
3								
4							<=	
5							<=	
6							<=	
7								
8								

Figura 6.19: Folha de cálculo do Exercício 6.5.

Relativamente a cada conjunto de células referido abaixo, indique a que é que dizem respeito (por exemplo, variáveis de decisão, função objectivo, ...) e quais os valores ou fórmulas que nele devem ser inseridos (ou se podem ser deixadas vazias).

- B2:D2.
- B4:D6.
- F4:F6.
- H4:H6.
- B8:D8.
- F8.

Exercício 6.6. Considere um modelo para um problema de produção com três produtos (A, B e C) e cinco recursos (R1 a R5). O relatório de análise de sensibilidade é apresentado na Figura 6.20.

- Indique as variáveis básicas e o seu valor.
- Indique os coeficientes da linha da função objectivo num quadro óptimo.

Exercício 6.7. Considere um modelo para um problema de produção com seis produtos. O objectivo é maximizar o lucro total e as restrições estão relacionadas com não ultrapassar a disponibilidade de seis recursos. O relatório de análise de sensibilidade é apresentado na Figura 6.21.

		Final	Reduced	Objective	Allowable	Allowable
Cell	Name	Value	Cost	Coefficient	Increase	Decrease
\$D\$3	A	0.85	0.00	10.00	10.00	0.40
\$E\$3	B	1.92	0.00	12.00	0.50	6.00
\$F\$3	C	0.00	-3.38	14.00	3.38	1.00E+30

		Final	Shadow	Constraint	Allowable	Allowable
Cell	Name	Value	Price	R.H. Side	Increase	Decrease
\$H\$5	R1	4.69	0.00	13.00	1.00E+30	8.31
\$H\$6	R2	7.46	0.00	14.00	1.00E+30	6.54
\$H\$7	R3	10.23	0.00	11.00	1.00E+30	0.77
\$H\$8	R4	13.00	2.31	13.00	0.91	5.00
\$H\$9	R5	10.00	0.15	10.00	6.25	2.20

Figura 6.20: Relatório de análise de sensibilidade do Exercício 6.6.

Variable Cells

		Final	Reduced	Objective	Allowable	Allowable
Cell	Name	Value	Cost	Coefficient	Increase	Decrease
\$G\$8	P1	0.0	-84.7	60.0	84.7	1E+30
\$H\$8	P2	0.0	-20.5	141.0	20.5	1E+30
\$I\$8	P3	0.5	0.0	148.0	110.7	1.5
\$J\$8	P4	0.0	-78.6	47.0	78.6	1E+30
\$K\$8	P5	0.0	-0.7	127.0	0.7	1E+30
\$L\$8	P6	1.6	0.0	194.0	2618.0	2.4

Constraints

		Final	Shadow	Constraint	Allowable	Allowable
Cell	Name	Value	Price	R.H. Side	Increase	Decrease
\$M\$9	R1	30.0	4.5	30.0	11.8	28.4
\$M\$10	R2	11.5	0.0	22.0	1E+30	10.5
\$M\$11	R3	2.5	0.0	44.0	1E+30	41.5
\$M\$12	R4	37.8	0.0	54.0	1E+30	16.2
\$M\$13	R5	33.0	7.2	33.0	18.6	9.3
\$M\$14	R6	219.9	0.0	500.0	1E+30	280.1

Figura 6.21: Relatório de análise de sensibilidade do Exercício 6.7.

- Indique as quantidades produzidas e o lucro total.
- Considere que o lucro unitário de P3 aumenta 100 unidades. Qual a solução ótima? Qual o novo lucro ótimo?

- c) É possível saber qual o novo lucro óptimo se o lucro associado ao produto 1 aumentar 100 unidades?
- d) De quanto tem de aumentar o lucro unitário do produto P2, para compensar produzi-lo?
- e) Se fosse possível aumentar 10 unidades à disponibilidade de um dos recursos, qual escolheria? Qual o novo lucro óptimo?
- f) Considere que a disponibilidade de R1 passa a ser 10 em vez de 30. A solução óptima altera-se? Qual o seu novo lucro total? Quais são os produtos produzidos nesse caso? Justifique as respostas de forma sucinta.

Parte III

Métodos

7

Algoritmos Simplex

Neste capítulo, estudam-se métodos para obter soluções óptimas de modelos de programação linear (simplex) e programação inteira (mista) (partição e avaliação).

7.1 Conceitos

7.1.1 Algoritmos iterativos

O modelo de programação linear (PL) geral (que apenas tem variáveis contínuas) representado no Quadro 7.1 não é resolúvel de forma analítica (como é, por exemplo, uma equação de segundo grau, em que a solução se obtém através de uma fórmula fechada).

Quadro 7.1 Modelo de PL geral.

Maximizar $p_1x_1 + p_2x_2 + \dots + p_jx_j + \dots + p_nx_n$

sujeito a:

$$a_{11}x_1 + a_{12}x_2 + \dots + a_{1j}x_j + \dots + a_{1n}x_n \leq b_1$$

$\vdots$

$$a_{i1}x_1 + a_{i2}x_2 + \dots + a_{ij}x_j + \dots + a_{in}x_n \leq b_i$$

$\vdots$

$$a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mj}x_j + \dots + a_{mn}x_n \leq b_m$$

$$x_j \geq 0, j = 1, \dots, n$$

Para se obter uma solução óptima de um modelo de PL geral utilizam-se métodos iterativos. Os dois principais tipos de métodos iterativos são os métodos simplex e os métodos de ponto interior. Neste texto, abordam-se

apenas os métodos simplex que são, para a grande generalidade dos modelos, os mais eficientes e estão implementados em, virtualmente, todo o software de PL¹.

O Algoritmo 7.1 corresponde a um método iterativo geral. A representação das soluções através de $\bar{x}$ e $\hat{x}$ diferencia-as de variáveis. Após a inicialização, em que se considera uma primeira solução, em cada execução das instruções do ciclo *While*, i.e. em cada iteração, obtém-se uma nova solução, $\hat{x}$, que passa a ser a solução actual $\bar{x}$. O ciclo termina quando um critério de paragem for satisfeito. Tipicamente, o critério de paragem está relacionado com a solução actual, e.g. ser óptima, mas tal não é obrigatório. Por exemplo, o critério de paragem pode estar associado a ser atingido um limite de tempo ou um número máximo de iterações.

Algoritmo 7.1: Algoritmo iterativo genérico.

Data: modelo de optimização;

Result: solução;

obter solução inicial $\bar{x}$;

while *critério de paragem não se verifica* **do**

 obter nova solução $\hat{x}$;

$\bar{x} = \hat{x}$;

Antes de descrever o algoritmo simplex, apresentam-se, nas próximas secções, as propriedades e resultados que o suportam.

7.1.2 Conjunto das soluções admissíveis

Uma solução é admissível se verifica todas as restrições do modelo de PL:

$$\sum_{j=1}^n a_{ij}x_j \leq b_i, \quad i = 1, \dots, m,$$

$$x_j \geq 0, \quad j = 1, \dots, n,$$

em que

- n número de variáveis de decisão;
- m número de restrições;
- x_j j -ésima variável de decisão, $j = 1, \dots, n$;
- a_{ij} coeficiente da j -ésima variável de decisão na i -ésima restrição, $i = 1, \dots, m$, $j = 1, \dots, n$;

¹O algoritmo simplex foi concebido por George Dantzig, o “pai” da PL, em 1947. Os primeiros algoritmos de ponto interior para PL devem-se a N. Karmarkar em 1984. Nalguns modelos, particularmente modelos esparsos de grande dimensão, os métodos de ponto interior competem com os algoritmos simplex em termos de eficiência. Outro algoritmo para PL é o algoritmo do elipsóide de L. Khachiyan em 1979 que é de grande importância teórica por ter demonstrado, pela primeira vez, que a PL é resolúvel em tempo polinomial.

- b_i termo independente da i -ésima restrição, $i = 1, \dots, m$.

A título exemplificativo, considera-se um modelo de PL com as restrições:

$$\begin{aligned} 2x_1 &\leq 3 \\ x_1 + x_2 &\leq 2 \\ x_1 + 2x_2 &\leq 3 \\ x_1, x_2 &\geq 0. \end{aligned}$$

Por exemplo, a solução $x_1 = x_2 = 0$ é uma solução admissível, já que respeita todas as restrições. O mesmo não se passa com a solução $x_1 = 2, x_2 = 0$ que não respeita a primeira restrição.

A representação gráfica deste modelo, onde cada ponto corresponde a uma solução (x_1, x_2) , é apresentada na Figura 7.1. A região sombreada corresponde ao conjunto das soluções admissíveis.




Figura 7.1: Região das soluções admissíveis do exemplo.

Considerando que existe pelo menos uma solução admissível², o conjunto das soluções admissíveis é um polítopo convexo limitado³, o que resulta de ser a intersecção de um conjunto de semi-espacos.

No exemplo, em que apenas há duas variáveis de decisão e portanto o conjunto das soluções admissíveis pode ser representada no plano, o conjunto das soluções admissíveis é um polígono convexo resultante da intersecção de um conjunto de semi-planos.

7.1.3 Soluções básicas admissíveis

Sendo um polítopo, o conjunto das soluções admissíveis inclui um número finito de vértices⁴. A importância dos vértices do conjunto das soluções admissíveis provém do teorema fundamental da PL: existindo uma solução

²O caso em que o conjunto das soluções admissíveis é vazio é abordado Exercício 7.7.

³O caso em que o polítopo é ilimitado é abordado no Exercício 7.7.

⁴Também designados, de forma equivalente por se tratar de um polítopo convexo, por pontos extremos.

óptima finita⁵, há pelo menos uma solução óptima que corresponde a um vértice da região das soluções admissíveis.

A importância do teorema fundamental da PL é que restringe o número de soluções candidatas a serem soluções óptimas aos vértices do conjunto das soluções admissíveis.

Na Figura 7.2 assinalam-se os cinco vértices do modelo do exemplo. O teorema fundamental da PL traduz-se em, qualquer que seja a função objetivo, uma das soluções, de A a E, ser óptima.

Por exemplo, se a função objectivo for $\text{Max } z = x_2$, a solução óptima é o vértice B, $x_1 = 0, x_2 = 3/2$; se a função objectivo for $\text{Max } z = 2x_1 + 3x_2$, a solução óptima é o vértice C, $x_1 = 1, x_2 = 1$; se a função objectivo for $\text{Min } z = x_1 + x_2$, a solução óptima é o vértice A, $x_1 = 0, x_2 = 0$.

Se existirem soluções óptimas alternativas, duas delas correspondem a vértices. Por exemplo, se a função objectivo for $\text{Max } z = x_1 + 2x_2$, todas as soluções da aresta BC, que inclui os vértices B e C, são óptimas.




Figura 7.2: Vértices da região das soluções admissíveis do exemplo.

Para caracterizar algebricamente os vértices, transformam-se as inequações em equações por introdução de variáveis adicionais não negativas, designadas por variáveis de folga, $s_i \geq 0, i = 1, \dots, m$, uma para cada restrição.

$$\begin{aligned} \sum_{j=1}^n a_{ij}x_j + s_i &= b_i, \quad i = 1, \dots, m, \\ x_j &\geq 0, \quad j = 1, \dots, n, \\ s_i &\geq 0, \quad i = 1, \dots, m. \end{aligned}$$

A qualquer solução admissível no modelo original, corresponde uma solução admissível no modelo com variáveis de folga em que as variáveis de decisão têm o mesmo valor.

⁵Pode não existir uma solução óptima finita se o modelo for impossível (i.e., não existir nenhuma solução admissível) ou se for possível aumentar o valor da função objectivo indefinidamente mantendo a admissibilidade das soluções (o que implica a região das soluções admissíveis ser ilimitada).

No exemplo, introduzem-se as variáveis de folga s_1, s_2 e s_3 :

$$\begin{aligned} 2x_1 + s_1 &= 3 \\ x_1 + x_2 + s_2 &= 2 \\ x_1 + 2x_2 + s_3 &= 3 \\ x_1, x_2, s_1, s_2, s_3 &\geq 0. \end{aligned}$$

Uma variável de folga valer 0 significa que a restrição a que está associada é respeitada na igualdade, a restrição diz-se activa. Uma variável de folga pode ser vista como uma distância ao hiperplano associada à “sua” restrição. O sinal indica se a solução faz parte do semi-espço em que a restrição é respeitada (sinal positivo) ou do semi-espço em que tal não acontece (sinal negativo). As variáveis de decisão podem ser vistas como variáveis de folga das restrições de não negatividade.

Em geral, um vértice caracteriza-se por ter $n - m$ restrições activas, logo $m - n$ variáveis com valor zero. A solução que lhe está associada obtém-se resolvendo o sistema de m equações a m incógnitas. A duas dimensões, um vértice corresponde à intersecção das duas rectas que definem as restrições activas. Um vértice é assim caracterizado por duas variáveis serem zero. Na Tabela 7.1 caracterizam-se os vértices do exemplo.

Vértice	Restrições activas	Variáveis com valor 0
A	$x_1 = 0, x_2 = 0$	x_1, x_2
B	$x_1 = 0, x_1 + 2x_2 + s_3 = 3$	x_1, s_3
C	$x_1 + x_2 + s_2 = 2, x_1 + 2x_2 + s_3 = 3$	s_2, s_3
D	$2x_2 = 3, x_1 + x_2 + s_2 = 2$	s_1, s_2
E	$x_2 = 0, 2x_2 = 3$	x_2, s_1

Tabela 7.1: Restrições activas e variáveis com valor 0 nos vértices do exemplo.

Para obter a solução associada a um vértice, resolve-se o sistema de três equações a três incógnitas. Por exemplo, no vértice C, obtém-se a solução $x_1 = 1, x_2 = 1, s_1 = 1, s_2 = 0, s_3 = 0$. Ainda por exemplo, no vértice D obtém-se a solução $x_1 = 3/2, x_2 = 0, s_1 = 0, s_2 = 1/2, s_3 = 3/2$.

Em PL, é comum designarem-se os vértices por soluções básicas admissíveis. Num modelo com n variáveis e m equações⁶, uma solução básica admissível tem $n - m$ variáveis com valor zero designadas por variáveis não básicas e as restantes m variáveis formam uma base e dizem-se básicas. O valor das variáveis básicas é determinado através da resolução de um sistema de m equações a m incógnitas. A solução básica é admissível se todas as variáveis básicas tiverem um valor não negativo. Se o sistema de equações resultar numa solução com variáveis com valores negativos, a solução diz-se básica

⁶Considera-se, sem aprofundamento do tópico, que são linearmente independentes.

não admissível⁷ já que, embora a solução corresponda a uma intersecção de hiperplanos, não pertence ao conjunto das soluções admissíveis. No exemplo, a base (x_1, s_1, s_3) é uma base não admissível, já que $x_2 = 0$ e $s_2 = 0$ resulta na solução básica não admissível $x_1 = 2, x_2 = 0, s_1 = -1, s_2 = 0, s_3 = 1$. Outra base não admissível é (x_1, s_1, s_2) , já que anulando x_2 e s_3 , obtém-se $x_1 = 3, s_1 = -3, s_2 = -1$.

Dada esta caracterização das soluções básicas admissíveis, dado que uma delas é ótima de acordo com o teorema fundamental da PL⁸ e dado que o número de soluções básicas admissíveis é finito, em teoria, é possível obter uma solução ótima calculando o valor de todas as soluções básicas admissíveis, já que estas podem ser enumeradas com base nas combinações de n variáveis tomadas em grupos de m . No entanto, o número de combinações, dado por $n!/((n-m)!m!)$, é demasiado elevado para este procedimento ser viável. Por exemplo, para $n = 100$ e $m = 10$, o número de combinações é $1.7E13$; para $n = 200$, o número de combinações excede os limites numéricos de uma folha de cálculo normal. A idade do universo não chegaria para obter a solução ótima de modelos com algumas centenas de variáveis e restrições.

7.1.4 Optimalidade e direcções de melhoria

Devido do conjunto das soluções admissíveis ser um polítopo convexo⁹ e da função objectivo ser linear, a ausência de direcções de melhoria admissíveis (direcções segundo as quais existem soluções admissíveis e o valor da função objectivo aumenta) é condição suficiente para a optimalidade de uma solução básica admissível.

A importância desta condição é que uma solução ótima local, isto é, uma solução não pior do que as soluções admissíveis que a rodeiam é também solução global, i.e. não é pior do que qualquer solução admissível.

No exemplo, para mostrar que D é uma solução ótima, basta mostrar que a função objectivo não melhora na direcção de D para C e na direcção de D para E. A optimalidade de D pode ser comprovada sem usar informação relativa a A ou B. Note-se ainda que a verificação da optimalidade não requer o cálculo de soluções básicas admissíveis, mas apenas da variação do valor da função objectivo nas direcções associadas às arestas.

O algoritmo simplex baseia-se em, dada uma solução básica admissível, verificar a sua optimalidade e, caso não se verifique, identificar uma direcção de melhoria admissível que conduz, de forma eficiente, a uma nova solução básica admissível com melhor valor.

Embora a direcção de maior melhoria seja, por definição, o gradiente, o algoritmo simplex selecciona uma direcção de melhoria associada a uma

⁷O sistema de equações pode ainda ser impossível ou ter um número infinito de soluções.

⁸Assumindo que existe uma solução ótima finita.

⁹Que se assume limitado para simplicidade de exposição.

aresta. Note-se que se não houver direcções de melhoria associadas a arestas, não há direcções de melhoria admissíveis. A escolha de uma direcção de melhoria associada a uma aresta, em vez de uma associada a uma direcção para interior da região das soluções admissíveis, permite obter uma solução básica admissível (logo candidata a ser óptima) melhor do que a actual de forma computacionalmente muito eficiente, estando garantida a convergência do algoritmo para uma solução óptima ¹⁰.

Numa determinada solução básica admissível, a direcção associada a uma aresta define-se pelo aumento do valor de uma variável não básica, permanecendo com valor 0 as restantes variáveis não básicas. Depois de identificada uma aresta associada a uma direcção de melhoria, a nova base é caracterizada por uma variável não básica passar a básica (a associada à restrição que deixou de estar activa) e por uma variável básica passar a não básica (a associada à restrição que passou a activa).

No exemplo, considere-se a base $\{s_1, s_2, s_3\}$ a que corresponde a solução básica admissível $x_1 = 0, x_2 = 0, s_1 = 3, s_2 = 2, s_3 = 3$. Uma aresta é caracterizada pelo aumento de x_1 e a outra pelo aumento de x_2 . Considere-se a função objectivo, $\text{Max } z = 3x_1 + x_2$. O gradiente da função objectivo é $(3, 1)$. Ambas as direcções associadas às arestas são de melhoria (os coeficientes das variáveis na função objectivo são positivos). Optando-se por escolher a aresta com maior melhoria marginal, a variável x_1 é adicionada à base. O aumento de x_1 é limitado por s_1 através de $2x_1 + s_1 = 3$, se $x_1 > 3/2$, s_1 fica negativo e sai-se da região das soluções admissíveis. Assim, a entrada de x_1 na base implica a saída de s_1 da base, percorrendo-se a aresta $(0, 0) - (3/2, 0)$. A base admissível da próxima iteração é $\{x_1, s_2, s_3\}$.

7.2 Algoritmos e resolução gráfica

7.2.1 Algoritmo simplex primal

Depois de apresentados e discutidos os principais conceitos associados ao algoritmo simplex, são apresentados os seus passos genéricos no Algoritmo 7.2. Este algoritmo designa-se por simplex primal, diferenciando-se do algoritmo simplex dual que, simplificada, é usado quando a obtenção de uma solução básica admissível não é directa e que será descrito na secção seguinte.

Partindo de uma solução básica admissível e, num conjunto finito de iterações, cada uma associada a uma solução básica admissível, o algoritmo simplex obtém uma solução óptima.

¹⁰Exclui-se a degenerescência e as questões de eficiência e convergência por ela levantadas que, nas implementações actuais, terão pouca relevância para o utilizador normal.

Algoritmo 7.2: Algoritmo simplex.

Data: modelo de PL;
Result: solução ótima;
obter solução básica admissível $\bar{x}$;
while *existir uma direcção de melhoria admissível em $\bar{x}$* ; **do**
 seleccionar uma direcção de melhoria $\hat{d}$;
 $\hat{x}$ é a solução básica admissível que se obtém partindo de $\bar{x}$ na
 direcção $\hat{d}$;
 $\bar{x} = \hat{x}$;

Sendo um algoritmo iterativo, o primeiro passo do algoritmo simplex, é a obtenção de uma solução inicial. Assume-se que a solução nula é admissível e que portanto a base inicial é (s_1, s_2, s_3) .

Resolvendo o sistema de equações para $x_1 = x_2 = 0$, obtém-se $s_1 = 3, s_2 = 2, s_3 = 3$. O seguinte quadro, designado por quadro simplex, é uma representação do modelo na solução solução básica admissível $x_1 = 0, x_2 = 0, s_1 = 3, s_2 = 2, s_3 = 3$.

	x_1	x_2	s_1	s_2	s_3	
s_1	2	0	1	0	0	3
s_2	1	1	0	1	0	2
s_3	1	2	0	0	1	3
z	-3	-1	0	0	0	0

Neste quadro, as colunas, com excepção da primeira e da última, correspondem às variáveis de decisão; as linhas, com excepção da primeira, correspondem às restrições e à função objectivo. Cada valor corresponde ao coeficiente da variável de decisão da coluna na restrição da linha ou ao simétrico¹¹ do coeficiente da variável de decisão da coluna na função objectivo. A última coluna tem os termos independentes e o valor da função objectivo.

As variáveis que não aparecem na primeira coluna têm valor zero (x_1 e x_2). Cada uma das restantes variáveis (s_1, s_2 e s_3) está associada a uma linha conforme indicado na primeira coluna. A coluna de cada uma dessas variáveis tem um coeficiente 1 na “sua” linha e coeficiente 0 nas restantes. Assim, dado que $x_1 = x_2 = 0$, com base neste quadro, é imediato concluir $s_1 = 3, s_2 = 2, s_3 = 3$ e $z = 0$.

Os coeficientes da linha da função objectivo das variáveis não básicas correspondem ao simétrico da variação marginal (por unidade) da função objectivo na direcção da aresta da “sua” restrição. No exemplo, as variáveis não básicas x_1 e x_2 têm coeficientes -3 e -1 na linha da função objectivo, logo existem duas direcções admissíveis de aumento da função objectivo e a solução não é ótima.

¹¹A função objectivo é representada por $\text{Max } -3x_1 - x_2 = 0$.

A direcção seleccionada é aquela com maior aumento marginal, ou seja é a direcção do aumento do x_1 (sendo x_2 constante). Dado que $x_2 = 0$, o sistema de equações é

$$2x_1 + s_1 = 3$$

$$x_1 + s_2 = 2$$

$$x_1 + s_3 = 3$$

Como se pretende uma solução admissível (i.e. $s_1, s_2, s_3 \geq 0$), o aumento de x_1 é limitado pelo mínimo de $\{3/2, 2, 3\}$, portanto, na solução da próxima iteração $x_1 = 3/2$ e $s_1 = 0$.

Representa-se graficamente, na Figura 7.3, o gradiente da função objectivo, duas rectas de nível e a direcção de melhoria associada à aresta $(0,0)-(3/2,0)$. A solução $\bar{x}$ é a solução básica admissível inicial e a solução $\hat{x}$ a solução básica admissível resultante do movimento através da direcção $\hat{d}$.




Figura 7.3: Solução inicial com representação da mudança de base.

Definida a nova base, pela entrada de x_1 e saída de s_1 , calcula-se o novo quadro simplex (i.e. a nova solução e a representação do modelo em função da nova base. Nesse quadro, as três primeiras linhas das colunas das variáveis x_1, s_2 e s_3 formam a matriz identidade, e essas colunas têm coeficiente 0 na linha da função objectivo.

Representa-se de novo o quadro simplex, mas agora assinalando a carregado a coluna da variável que deixa de ser zero (x_1) por ter o coeficiente mais negativo na linha da função objectivo, indicando as razões entre os termos independentes e os coeficientes da coluna do x_1 e que e assinalando a linha da variável com menor razão, que portanto passa a não básica (a variável s_1).

	x_1	x_2	s_1	s_2	s_3	
s_1	2	0	1	0	0	3 (3/2)
s_2	1	1	0	1	0	2 (2)
s_3	1	2	0	0	1	3 (3)
z	-3	-1	0	0	0	0

A coluna da variável que passa a básica (no exemplo, x_1) e a linha da variável que passa a não básica (no exemplo, s_1) designam-se por coluna pivot e linha pivot, respectivamente. O elemento do cruzamento da linha pivot com a coluna pivot é o elemento pivot (no exemplo, tem o valor 2).

As operações a efectuar para associar o novo quadro corresponder à nova solução básica admissível são: substituir a linha pivot pela linha que se obtém dividindo todos os seus elementos pelo elemento pivot; para cada uma das restantes linhas, multiplicar a linha pivot por uma constante de forma a que, quando somada à outra linha, o elemento da coluna pivot seja zero.

No exemplo, representando por Li^n a i -ésima linha nova e por Li^a a i -ésima linha actual, as operações são $L1^n = L1^a/2$, $L2^n = -L1^a/2 + L2^a$, $L3^n = -L1^a/2 + L3^a$ e $L4^n = 3L1^a/2 + L4^a$. O quadro correspondente é:

	x_1	x_2	s_1	s_2	s_3	
x_1	1	0	1/2	0	0	3/2 (∞)
s_2	0	1	-1/2	1	0	1/2 (1/2)
s_3	0	2	-1/2	0	1	3/2 (3/4)
z	0	-1	3/2	0	0	9/2

Como se pode verificar na Figura 7.4, a solução $x_1 = 3/2, x_2 = 0$ não é óptima porque a função objectivo aumenta na direcção em que x_1 permanece constante e x_2 aumenta (que corresponde à aresta vertical). O aumento de x_2 é limitado pela restrição $x_1 + x_2 \leq 2$, passando $x_1 = 3/2, x_2 = 1/2$ com valor $z = 5$ a ser a solução actual.




Figura 7.4: Segunda solução do algoritmo simplex.

Dado haver uma aresta segundo a qual a função objectivo melhora (aumento de x_2), a solução não é óptima. O aumento de x_2 é limitado por s_2 , logo o quadro seguinte é:

	x_1	x_2	s_1	s_2	s_3	
x_1	1	0	1/2	0	0	3/2
x_2	0	1	-1/2	1	0	1/2
s_3	0	0	1/2	-2	1	1/2
z	0	0	1	5/2	0	5

Este quadro corresponde a uma solução óptima, já que não há coeficientes negativos na linha da função objectivo. Assim, a solução $x_1 = 3/2, x_2 = 1/2$ é uma solução óptima: não existe nenhuma solução admissível com um valor de z superior como se pode também constatar graficamente na Figura 7.5. Em duas iterações (três soluções), obteve-se uma solução óptima.




Figura 7.5: Terceira solução do algoritmo simplex.

O Algoritmo 7.3 descreve os algoritmo simplex em termos de critérios e cálculos.

Algoritmo 7.3: Algoritmo simplex.

Data: modelo de PL;

Result: solução óptima;

construir quadro inicial para a origem;

while *houver coeficientes negativos na linha da função objectivo* **do**
 seleccionar variável que entra na base (a que tiver o coeficiente
 na linha da função objectivo mais negativo);
 seleccionar variável que sai da base (a que tiver a menor razão
 entre termos independentes e coeficientes da coluna da variável
 que entra na base, considerado apenas os positivos);
 actualizar quadro para nova base através, para cada linha, da
 multiplicação da linha pivot por uma constante e soma com a
 linha de forma a que a coluna da nova variável básica tenha um
 1 na “sua” linha e 0 nas restantes.

Para concluir esta secção, apresenta-se um exemplo adicional da aplicação do algoritmo simplex. Considera-se o modelo:

$$\text{Maximizar } z = 10x_1 + 9x_2$$

Sujeito a:

$$5x_1 + 4x_2 \leq 200$$

$$4x_1 + 6x_2 \leq 230$$

$$2x_1 + x_2 \leq 70$$

$$x_1, x_2 \geq 0.$$

O primeiro quadro, já com a variável que entra na base e a que sai da base

identificadas, é:

	$\mathbf{x_1}$	x_2	s_1	s_2	s_3		
s_1	5	4	1	0	0	200	(200/5)
s_2	4	6	0	1	0	230	(230/4)
s_3	2	1	0	0	1	70	(70/2)
z	-10	-9	0	0	0	0	

O segundo quadro resulta das operações:

- $L3^n = L3^a/2$
- $L1^n = (-5/2)L3^a + L1$
- $L2^n = -2L3^a + L2$
- $L4^n = 5L3^a + L4$

	x_1	$\mathbf{x_2}$	s_1	s_2	s_3		
s_1	0	3/2	1	0	-5/2	25	(50/3)
s_2	0	4	0	1	-2	90	(90/4)
x_1	1	1/2	0	0	1/2	35	(35/(1/2))
z	0	-4	0	0	5	350	

Após uma iteração, não apresentada, obtém-se o quadro simplex óptimo:

	x_1	x_2	s_1	s_2	s_3	
x_2	0	1	-6/21	5/14	0	25
s_3	0	0	-4/7	3/14	1	5
x_1	1	0	3/7	-2/7	0	20
z	0	0	12/7	5/14	0	425

7.2.2 Algoritmo simplex dual

Na apresentação do algoritmo simplex efectuada, considerou-se que o modelo tinha uma solução admissível e que a solução nula era uma solução admissível. Frequentemente, esse pressuposto não se verifica e portanto a obtenção de uma solução básica admissível não é directa. Nessas situações pode aplicar-se também um algoritmo simplex (em cada iteração também se consideram soluções básicas) com regras que procuram a admissibilidade da solução e que se designa por simplex dual.

Considere-se o seguinte modelo:

$$\text{Minimizar } z = 2x_1 + x_3$$

Sujeito a:

$$x_1 + x_2 - x_3 \geq 5$$

$$x_1 - 2x_2 + 4x_3 \geq 8$$

$$x_1, x_2, x_3 \geq 0.$$

Minimizar uma função é equivalente a maximizar a função simétrica, logo a função objectivo pode ser substituída por

$$\text{Maximizar } -z = -2x_1 - x_3$$

Como as restrições são de maior ou igual, associa-se uma variável de excesso com coeficiente -1 a cada restrição, transformando-a numa igualdade:

$$\begin{aligned} -x_1 - x_2 + x_3 + t_1 &= -5 \\ -x_1 + 2x_2 - 4x_3 + t_2 &= -8 \\ x_1, x_2, x_3, t_1, t_2 &\geq 0. \end{aligned}$$

O quadro simplex abaixo corresponde a uma solução básica (três variáveis não básicas, x_1, x_2 e x_3 e duas variáveis básicas, t_1 e t_2). No entanto, esta solução não é admissível porque há variáveis com valores negativos.

	x_1	x_2	x_3	t_1	t_2	
t_1	-1	-1	1	1	0	-5
t_2	-1	2	-4	0	1	-8
$-z$	2	0	1	0	0	0

O algoritmo simplex dual procura, através de direcções que diminuam o menos possível o valor da função objectivo, atingir uma solução admissível. A primeira solução admissível encontrada é uma solução óptima.

A mudança de base faz-se escolhendo para sair da base a variável que mais está afastada da admissibilidade, ou seja a que tem o valor mais negativo. No exemplo, a variável t_3 . A variável que entra na base é aquela que tem a menor razão em módulo entre o coeficiente da linha da função objectivo e o coeficiente da linha pivot, excluindo as variáveis que têm coeficiente positivo ou nulo na linha pivot. Se não houver nenhuma variável com coeficiente negativo na linha pivot, o problema é impossível.

Identificando a coluna e linha pivot, o quadro simplex é o seguinte:

	x_1	x_2	x_3	t_1	t_2	
t_1	-1	-1	1	1	0	-5
t_2	-1	2	-4	0	1	-8
$-z$	2	0	1	0	0	0
	(2/1)		(1/4)			

Depois de uma iteração, cujo quadro não é apresentado, o quadro óptimo é:

	x_1	x_2	x_3	t_1	t_2	
x_2	5/2	1	0	-2	-1/2	14
x_3	3/2	0	1	-1	-1/2	9
$-z$	1/2	0	0	1	1/2	-9

Assim, a solução óptima é $x_1 = 0, x_2 = 14, x_3 = 9$ com valor $z = 9$.

7.2.3 Resolução gráfica

Nesta secção detalha-se como se pode resolver problemas com apenas duas variáveis de decisão de forma directa e manualmente utilizando a representação gráfica. Note-se que a extensão do procedimento para modelos de grande dimensão não é praticável.

Na Figura 7.6 representa-se o primeiro quadrante (já que o domínio das variáveis é $x_1 \geq 0$ e $x_2 \geq 0$), as rectas associadas a cada uma das três inequações e, a sombreado, a região das soluções admissíveis que é dada pela intersecção dos semi-planos definidos pelas cinco inequações¹².

Para resolver o problema, i.e. obter uma solução óptima, é necessário considerar também a função objectivo. Cada valor de z corresponde a uma recta na representação gráfica.

Na Figura 7.6, apresentam-se a tracejado negro, três rectas da função objectivo para valores de z ¹³.

Cada uma dessas rectas é uma recta de nível: todos os pontos que dela fazem parte têm o mesmo valor z . Como pode ser observado na Figura 7.6, estas rectas de nível são paralelas. De facto, para a função objectivo genérica, $z = c_1x_1 + c_2x_2$, tem-se $x_2 = z/c_2 - (c_1/c_2)x_1$ e o declive é o mesmo, dado por $-c_1/c_2$, qualquer que seja o valor de z . No caso do exemplo, o declive da função objectivo é -3 .

Para obter uma solução óptima, podem considerar-se diferentes rectas de nível e identificar a solução da região das soluções admissíveis que faz parte daquela com maior valor. Nenhum ponto da recta $z = 3$ corresponde a uma solução óptima, já que há uma recta de nível com maior valor de z que também tem soluções admissíveis. Nenhum ponto da recta $z = 6$ corresponde a uma solução óptima já que não existe nenhuma solução admissível que pertença a essa recta. Seguindo este raciocínio conclui-se que a solução óptima faz parte da recta de nível que passa pelo ponto de intersecção das rectas $x_1 + x_2 = 2$ e $2x_1 = 3$ (a tracejado azul na Figura 7.6). Assim, a solução óptima é $x_1 = 1, x_2 = 1/2$ com o valor $z = 5$.

¹²Para representar a região das soluções admissíveis manualmente primeiro identifica-se o semi-plano associada a cada restrição. Para tal pode usar-se a equação da recta ou unirem-se dois pontos pertencentes a ela pertencentes. Da primeira forma, a recta da terceira restrição, por exemplo, é $x_2 = 3/2 - (1/2)x_1$, tendo portanto um declive de $-1/2$ e intersectando o eixo das ordenadas no ponto $(0, 3/2)$. Da segunda forma, mantendo o exemplo da terceira restrição, igualando x_1 a 0, obtém-se $x_2 = 3/2$, logo o ponto $(0, 3/2)$ faz parte da recta. Igualando x_2 a 0, obtém-se $x_1 = 3$, logo o ponto $(3, 0)$ faz parte da recta. Unindo esses dois pontos obtém-se a recta da restrição. Depois de traçada a recta, importa identificar o semi-plano de que fazem parte as soluções que respeitam a restrição. Tal pode ser feito, considerando um ponto arbitrário que não faça parte da recta e avaliando se verifica ou não a restrição. Por exemplo, $(0, 0)$ verifica a restrição $x_1 + 2x_2 \leq 3$ (já que $0 \leq 3$ é verdade), logo o semi-plano que verifica a restrição é o inferior à recta.

¹³Escolhidos tendo em conta a simplicidade da sua representação, outros valores de z podiam ter sido escolhidos.




Figura 7.6: Representação gráfica de um modelo de PL.

7.3 Exercícios

Exercício 7.1. Considere o seguinte modelo de PL.

$$\text{Maximizar } z = 8x_1 + 5x_2$$

Sujeito a:

$$2x_1 + x_2 \leq 500$$

$$x_1 \leq 150$$

$$x_2 \leq 250$$

$$x_1, x_2 \geq 0.$$

- Obtenha uma solução ótima através do algoritmo simplex.
- Assinale na representação gráfica o ponto a que corresponde cada um dos quadros simplex.

Exercício 7.2. Considere o seguinte modelo de PL.

$$\text{Maximizar } z = 8x_1 + 5x_2$$

Sujeito a:

$$4x_1 + 3x_2 \leq 12$$

$$2x_1 + 3x_2 \leq 9$$

$$x_1, x_2 \geq 0.$$

- Obtenha uma solução ótima através do algoritmo simplex.
- Assinale na representação gráfica o ponto a que corresponde cada um dos quadros simplex.

Exercício 7.3. Considere o seguinte modelo de PL.

$$\text{Maximizar } z = x_1 + 2x_2$$

Sujeito a:

$$-4x_1 + x_2 \leq 4$$

$$2x_1 - 3x_2 \leq 6$$

$$x_1, x_2 \geq 0.$$

Mostre que o modelo não tem uma solução ótima finita:

- a) Através da representação gráfica.
- b) Através do algoritmo simplex.

Exercício 7.4. Considere o seguinte modelo de PL.

$$\text{Minimizar } z = -3x_1 + 2x_2 - 4x_3$$

Sujeito a:

$$2x_1 - x_2 + 3x_3 \leq 60$$

$$3x_1 + 3x_2 - 5x_3 \leq 40$$

$$x_1, x_2, x_3 \geq 0.$$

Sabendo que minimizar uma função objectivo é equivalente a maximizar a função simétrica, obtenha uma solução ótima.

Exercício 7.5. Através de uma iteração adicional ao algoritmo simplex, mostre que o modelo seguinte tem soluções ótimas alternativas.

$$\text{Maximizar } z = 2x_1 + 2x_2$$

Sujeito a:

$$2x_1 \leq 3$$

$$x_1 + x_2 \leq 2$$

$$x_1 + 2x_2 \leq 3$$

$$x_1, x_2 \geq 0.$$

Exercício 7.6. Considere o modelo de PL:

$$\text{Minimizar } z = 3x_1 + 2x_2$$

Sujeito a:

$$x_1 - x_2 \geq 1$$

$$x_1 \geq 2$$

$$x_1 + x_2 \geq 3$$

$$x_1, x_2 \geq 0.$$

- a) Obtenha uma solução óptima através do algoritmo simplex dual.
- b) Assinale na representação gráfica o ponto a que corresponde cada um dos quadros simplex.

Exercício 7.7. Considere as restrições de um modelo de PL:

$$\begin{aligned}x_1 - x_2 &\geq 1 \\x_1 + x_2 &\geq 3 \\2x_1 + x_2 &\leq 4 \\x_1, x_2 &\geq 0.\end{aligned}$$

Mostre que o conjunto das soluções admissíveis é vazio e portanto, qualquer que seja a função objectivo, o modelo é impossível:

- a) Através da representação gráfica.
- b) Através de um algoritmo simplex, notando que, dado um quadro simplex, com variáveis negativas e coeficientes da linha da função objectivo negativos, pode ser efectuada uma iteração do simplex primal ou do simplex dual.

Exercício 7.8. Considere o modelo de PL:

$$\begin{aligned}\text{Maximizar } z &= x_1 + 4x_2 + 4x_3 + 6x_4 \\ \text{Sujeito a:} \\ 2x_1 + 8x_2 + 4x_3 + 6x_4 &= 10 \\ x_1 + x_2 + x_3 + x_4 &\leq 2 \\ x_1, x_2, x_3, x_4 &\geq 0.\end{aligned}$$

Sabendo que a restrição de igualdade

$$\begin{aligned}\sum_{j=1}^n a_{ij}x_j &= b_i \\ x_j &\geq 0, \quad j = 1, \dots, n\end{aligned}$$

é equivalente às duas inequações

$$\begin{aligned}\sum_{j=1}^n a_{ij}x_j &\leq b_i \\ \sum_{j=1}^n a_{ij}x_j &\geq b_i \\ x_j &\geq 0, \quad j = 1, \dots, n,\end{aligned}$$

obtenha uma solução óptima.

Exercício 7.9. Sabendo que uma variável livre x é equivalente à subtração de duas variáveis não negativas:

$$\begin{aligned}x &= x^+ - x^- \\ x^+, x^- &\geq 0,\end{aligned}$$

obtenha uma solução óptima para o modelo de PL abaixo:

- a) Através da representação gráfica.
- b) Através de um algoritmo simplex.

Maximizar $z = -2x_1 + x_2$

Sujeito a:

$$x_1 \leq 2$$

$$x_1 \geq -1$$

$$x_2 \leq 3$$

$$x_2 \geq -4$$

$$x_1, x_2 \text{ livres}$$

8

Algoritmos de Partição e Avaliação

8.1 Conceitos

8.1.1 A complexidade da programação inteira

Ao contrário do que acontece em PL, em programação inteira (PI), não é conhecida nenhuma forma eficiente de verificar se uma solução admissível é ótima e, se não for, não é conhecida forma eficiente de obter uma solução melhor. Assim, ao contrário do que acontece em PL, não é conhecido nenhum algoritmo eficiente que obtenha uma solução ótima para o modelo geral de PI¹.

Em qualquer caso, o conhecimento existente traduz-se em implementações de algoritmos que permitem, em geral, a resolução de problemas de média dimensão em tempos aceitáveis. Embora o software de estado-da-arte utilize a combinação de diversos métodos, o algoritmo de partição e avaliação está no centro de, virtualmente, todos os métodos exactos, i.e. que obtêm uma solução ótima, para PI.

Dado que um método iterativo não é aplicável pelas razões expostas, em PI, é necessário, explícita ou implicitamente, considerar todas as soluções admissíveis para provar a optimalidade de uma delas.

Note-se que, dado o número de soluções ser finito, em PI, teoricamente é possível enumerar todas as soluções e identificar uma solução ótima por ter um valor não pior do que todas as outras soluções admissíveis. Exemplificando com um modelo de programação binária com n variáveis, tal envolveria testar a admissibilidade e avaliar 2^n soluções, sendo fácil de comprovar que mesmo para valores de n relativamente pequenos, esse procedimento

¹Na terminologia da teoria da complexidade, a PL pertence ao conjunto de problemas P, para os quais existem algoritmos polinomiais, i.e. eficientes, e a PI pertence ao conjunto dos problemas NP-difíceis, para os quais não são conhecidos algoritmos polinomiais.

envolveria um tempo computacional fora do alcance dos computadores baseados nos princípios clássicos por mais que a sua tecnologia evolua.

8.1.2 Relaxação linear e limites

A relaxação linear de um modelo de PI consiste no problema que se obtém ignorando restrições de integralidade das variáveis de decisão. A título exemplificativo, considere-se o modelo

$$\text{Maximizar } z = 4x_1 + 9x_2 \quad (8.1)$$

Sujeito a:

$$2x_1 + x_2 \leq 6 \quad (8.2)$$

$$2x_1 + 3x_2 \leq 9 \quad (8.3)$$

$$x_1, x_2 \geq 0 \text{ e inteiros.} \quad (8.4)$$

A relaxação linear resulta da substituição das restrições de domínio (8.4) por $x_1, x_2 \geq 0$. Na Figura 8.1 estão representados os conjuntos das soluções admissíveis do modelo de PI (pontos pretos) e da sua relaxação linear (região sombreada).




Figura 8.1: Região das soluções admissíveis do exemplo.

Como já referido, não existe um algoritmo eficiente para obter uma solução ótima do modelo de PI (o seu conjunto de soluções admissíveis é não convexo). No entanto, existe um algoritmo eficiente, o algoritmo simplex, para resolver a sua relaxação linear.

Se a solução óptima da relaxação linear for inteira, essa solução é também óptima do modelo de PI, já que a sua região das soluções admissíveis inclui o conjunto das soluções admissíveis do modelo de PI.

No exemplo, a solução óptima da relaxação linear do modelo (8.1-8.4) é $x_1 = 0$ e $x_2 = 3$. Esta solução é óptima do modelo de PI porque se houvesse uma solução inteira melhor do que esta, seria admissível na relaxação linear e portanto seria a solução óptima da relaxação linear, o que não acontece. Neste exemplo, como a solução óptima da relaxação linear é inteira, resolveu-se o modelo de PI sem se considerar explicitamente todas as soluções admissíveis.

Considere-se agora o caso em que a solução óptima da relaxação linear é fraccionária. Um aspecto central do método de partição e avaliação é a utilização do valor óptimo da relaxação linear como um limite superior para o valor da solução óptima inteira. O valor da função objectivo fornece um limite superior (em maximização) para o valor óptimo do modelo de PI. Representando por z_{RL}^* o valor óptimo da relaxação linear e por z_{SI} o valor de uma qualquer solução inteira, verifica-se $z_{SI} \leq z_{RL}^*$. No exemplo, em vez de 8.1, considere-se a função objectivo

$$\text{Maximizar } z = 4x_1 + 3x_2.$$

A solução óptima da relaxação linear é $x_1 = 2.25; x_2 = 1.5$ com valor 13.5, i.e., $z_{RL}^* = 13.5$. Assim, não existe nenhuma solução inteira com valor superior a 13.5. A utilidade deste limite é que se for conhecida uma solução inteira com valor 13, o limite dado pela relaxação linear permite assegurar que essa solução é óptima².

A relaxação linear pode ainda ser impossível, caso que em que o modelo de PI é também impossível. Se a relaxação linear não tiver solução óptima finita, o mesmo acontece com o problema inteiro.

8.1.3 Partição

Outro aspecto central do método de partição e avaliação é a sucessiva melhoria da aproximação dada pela relaxação linear em subregiões das soluções admissíveis que podem conter a solução óptima inteira. No exemplo, dado que a solução óptima da relaxação linear é fraccionária, $x_1 = 2.25; x_2 = 1.5$, obtém-se uma melhor aproximação ao excluírem-se todas as soluções em que $2 < x_1 < 3$, como representado na Figura 8.2. Note-se que outras aproximações são possíveis, nomeadamente aquela em que se excluem as soluções em que $1 < x_2 < 2$ que é representada na Figura 8.3. Para resolver de forma eficiente o modelo resultante desta melhor aproximação, consideram-se dois

²Embora o limite seja 13.5, dado que os coeficientes das variáveis de decisão na função objectivo, são inteiros, não existem soluções inteiras com valores fraccionários e portanto o limite pode ser reduzido para 13.

submodelos (ou subproblemas na terminologia mais usual do método de partição e avaliação): num deles adiciona-se ao modelo original a restrição $x_1 \geq 3$ (subproblema *SP1* e no outro adiciona-se ao modelo original a restrição $x_1 \leq 2$ (*SP2*). A solução óptima do modelo de PI é a que tiver maior valor de entre as duas soluções óptimas inteiras de *SP1* e *SP2*. Embora se tenha passado a ter dois subproblemas, é de notar que não foi excluída nenhuma solução inteira admissível e a relaxação linear de cada um deles é uma melhor aproximação do conjunto das soluções inteiras admissíveis, sendo portanto mais provável a obtenção de uma solução inteira.




Figura 8.2: Região das soluções admissíveis da relaxação linear excluindo as soluções $2 < x_1 < 3$.

A aplicação do método de partição e avaliação pode ser representada numa árvore, designada por árvore de pesquisa, como a da Figura 8.4, obtida após a resolução da relaxação linear. Com exceções que serão descritas posteriormente, se um nodo tem uma solução fraccionária, é escolhida uma variável com valor fraccionário (designada por variável de partição), $x_j = f$, e criados dois novos nodos cada um correspondendo a um subproblema resultante da adição de uma restrição (designada por restrição de partição). Num dos nodos a restrição de partição é $x_j \leq \lfloor f \rfloor$ e no outro $x_j \geq \lceil f \rceil$ ³. O melhor valor que se pode obter num nodo descendente é dado pelo valor óptimo do ascendente. Na Figura 8.4, junto a cada nodo representa-se o limite superior antes da sua resolução e, caso já tenha sido resolvido, o valor

³A função $\lfloor f \rfloor$ designa-se por *chão* e retorna o maior inteiro menor ou igual a f . A função $\lceil f \rceil$ designa-se por *tecto* e retorna o menor inteiro maior ou igual a f .




Figura 8.3: Região das soluções admissíveis da relaxação linear excluindo as soluções $1 < x_2 < 2$.

da função objectivo e das variáveis de decisão da solução óptima.




Figura 8.4: Árvore de partição e avaliação do exemplo após resolução da relaxação linear.

8.2 Algoritmo

Como descrito anteriormente, se a solução óptima da relaxação linear for fraccionária, são criados dois subproblemas. Para obter a solução óptima inteira, é necessário resolver pelo menos um deles. No exemplo, resolve-se o *SP1*. Este subproblema tem apenas uma solução admissível que é $x_1 = 3, x_2 = 0$ com valor 12. A árvore de pesquisa actualizada é apresentada na Figura 8.5. A solução óptima de *SP1* designa-se por incumbente por ser a melhor solução obtida até ao momento e o seu valor representa-se por

z_{INC} , assim $z_{INC} = z_{SP1} = 12$.




Figura 8.5: Árvore de partição e avaliação do exemplo após resolução de $SP1$.

A solução óptima de $SP2$ é $x_1 = 2, x_2 = 1.67$ com valor $z_{SP2} = 13$. Dado que esta solução não é inteira e um dos seus descendentes pode ter um valor melhor do que a incumbente, é necessária uma nova partição que é efectuada na única variável fraccionária, x_2 , como representado na Figura 8.6.




Figura 8.6: Árvore de partição e avaliação do exemplo após resolução $SP2$.

A solução óptima de $SP3$ é fraccionária, $x_1 = 1.5, x_2 = 2$, com valor $z_{SP3} = 12$. Dado que $z_{SP3} \leq z_{INC}$, não é possível obter soluções melhores do que a incumbente nos nodos descendentes e assim, devido a esta avaliação de limites, o nodo $SP3$ é abandonado. A solução óptima de $SP4$ é inteira, $x_1 = 2, x_2 = 1$, com valor $z_{SP4} = 11$ e portanto o nodo não gera descendentes. Dado que $z_{SP4} \leq z_{INC}$, a incumbente não é actualizada. Como não existem mais nodos por resolver, a solução incumbente é óptima.

A árvore de pesquisa final é apresentada na Figura 8.7.

De forma geral, em cada iteração do método de partição e avaliação existe um lista de subproblemas por resolver, L . Cada subproblema $SP \in L$ tem um limite superior, z_{SP}^{LIM} dado pelo valor da solução óptima do subproblema ascendente, z_{SPa}^* em que SPa é o subproblema ascendente de SP . Um




Figura 8.7: Árvore de partição e avaliação final do exemplo.

limite global para o valor da solução ótima inteira é o maior dos limites dos subproblemas em aberto: $z^{LIM} = \max_{SP \in L} \{z_{SP}^{LIM}\}$. Por outro lado, uma solução ótima inteira nunca terá um valor inferior ao da incumbente. Assim, o valor da solução ótima do modelo de PI, z^{OPT} verifica $z_{INC} \leq z^{OPT} \leq z^{LIM}$.

Estas relações permitem ter uma medida da distância da solução incumbente à solução ótima no *pior caso*. Essa medida designa-se por intervalo (*gap*) de optimalidade. O intervalo de optimalidade absoluto é dado por

$$gap_{ABS} = z^{LIM} - z_{INC}.$$

O intervalo de optimalidade relativo é dado por:

$$gap_{REL} = (z^{LIM} - z_{INC})/z^{LIM}.$$

No exemplo, após a resolução do nodo $SP1$, $gap_{ABS} = 13 - 12 = 1$ e $gap_{REL} = 1/13 = 7.7\%$. Note-se que uma solução ótima pode estar associado um intervalo de optimalidade elevado por o limite ser de fraca qualidade. No exemplo, como se comprovou após reduzir o limite superior, a solução com valor 12 é ótima. O intervalo de optimalidade é essencial como critério de paragem para problemas de difícil resolução.

Por exemplo, com base no intervalo de optimalidade pode concluir-se que é aceitável uma solução obtida por arredondamento. Tal poderá acontecer em modelos em que as variáveis de decisão correspondam a quantidades inteiras de valores elevados mas será raro em modelos com variáveis binárias.

No exemplo, substituindo os termos independentes por 60 e 90 a solução ótima é $x_1 = 22.5$ e $x_2 = 15$ com valor 135. A ótima inteira tem valor 134.

A solução arredondada ($x_1 = 22$ e $x_2 = 15$) tem valor 133 logo o intervalo de optimalidade relativo é 1.4% que pode ser aceitável para a aplicação em causa. Voltando ao exemplo original, arredondando a solução óptima da relaxação linear ($x_1 = 2.25, x_2 = 1.5$, obtém-se a solução inteira $x_1 = 2; x_2 = 2$ que não é admissível no modelo de PI ou $x_1 = 2$ e $x_2 = 1$ com valor $z = 11$ que tem um intervalo de optimalidade 18.5% dificilmente aceitável qualquer que seja a aplicação.

O Algoritmo 8.1 corresponde ao método de partição e avaliação. Para maior clareza, não se consideram modelos sem solução óptima finita que são detectados quando a relaxação linear é resolvida.

Para uma completa definição do método de partição e avaliação resta definir critérios para seleccionar a variável de partição e para seleccionar o próximo nodo a ser resolvido. Em ambos os casos, existem métodos elaborados que aceleram significativamente o método. Aqui sugere-se a selecção da variável com a parte fraccionária mais próxima de 0.5 para variável de partição.

Relativamente à estratégia de pesquisa da árvore, consideram-se três: profundidade, largura e melhor limite. Na estratégia de pesquisa em profundidade, o próximo nodo a ser resolvido é o que tem um maior nível, i.e. aquele tem mais restrições de partição. Na estratégia de pesquisa em largura, o próximo nodo a ser resolvido é o que tem um menor nível, i.e. aquele tem menos restrições de partição. Na estratégia melhor limite é seleccionado o nodo com um limite mais elevado. Em geral, estratégia melhor limite é a que produz melhores resultados. Em caso de empate a escolha do nodo é feita arbitrariamente, podendo-se optar primeiro por nodos cuja última restrição de partição é de maior ou igual.

8.3 Exemplo

Considera-se o seguinte modelo de PI (binária).

$$\text{Maximizar } z = 100x_1 + 72x_2 + 23x_3 + 96x_4 \quad (8.5)$$

Sujeito a:

$$31x_1 + 32x_2 + 14x_3 + 38x_4 \leq 100 \quad (8.6)$$

$$32x_1 + 31x_2 + 34x_3 + 39x_4 \leq 100 \quad (8.7)$$

$$32x_1 + 40x_2 + 18x_3 + 32x_4 \leq 100 \quad (8.8)$$

$$x_1, x_2, x_3, x_4 \in \{0, 1\}. \quad (8.9)$$

Na Figura 8.8 apresenta-se a árvore de pesquisa correspondente à resolução deste modelo pelo método de partição e avaliação. Na Tabela 8.1 apresenta-se a aplicação passo a passo.

Algoritmo 8.1: Algoritmo de partição e avaliação genérico.

Data: modelo de PI;
Result: solução;
inicializar lista de subproblemas em aberto, L , com relaxação linear;
inicializar limite superior: $z^{LIM} = \infty$;
inicializar valor da incumbente: $z_{INC} = -\infty$;
while L não está vazia e intervalos de optimalidade não são
suficientemente pequenos **do**
 seleccionar subproblema SP da lista L de acordo com critério de
 pesquisa;
 if $z_{SP}^{LIM} \geq z_{INC}$ **then**
 optimizar SP ;
 if SP não é impossível **then**
 if $z_{SP}^* > z_{INC}$ **then**
 if x_{SP}^* inteira **then**
 actualizar incumbente, $z_{INC} = z_{SP}^*$, $x_{INC} = x_{SP}^*$;
 else
 /* partição */
 seleccionar variável de partição;
 criar descendentes com $z_{SP}^{LIM} = z_{SP}^*$;
 adicionar descendentes a L ;
 actualizar intervalos de optimalidade;
 else
 /* SP abandonado por limite após ter sido
 resolvido */
 ;
 else
 /* SP abandonado por ser impossível */
 ;
 else
 /* SP abandonado por limite antes de ser resolvido
 */
 ;
 retirar SP de L ;




Figura 8.8: Árvore de pesquisa do exemplo.

SP por resolver	SP resolvido	$(x_1, x_2, x_3, x_4, z_{SP})$	z_{INC}	z_{LM}	Análise / Novos SP	gap_{ABS}	gap_{REL}
{RL}	RL	(1, 0, 9, 0, 1, 260.8)	$-\infty$	260	{SP1, SP2}	∞	100%
{SP1, SP2}	SP1	(1, 1, 0, 0.875, 256)	$-\infty$	260	{SP3, SP4}	∞	100%
{SP2, SP3, SP4}	SP2	(1, 0, 0, 9, 1, 215.62)	$-\infty$	256	{SP5, SP6}	∞	100%
{SP3, SP4, SP5, SP6}	SP4	(1, 1, 1, 0, 195)	195	256	Incumbente	61	23.8%
{SP3, SP5, SP6}	SP3	(0.9, 1, 0, 1, 255.5)	195	255	{SP7, SP8}	60	23.5%
{SP5, SP6, SP7, SP8}	SP7	-	195	255	Impossível	60	23.5%
{SP5, SP6, SP8}	SP8	(0, 1, 0, 9, 1, 188.29)	195	215	Abandonado	20	9.3%
{SP5, SP6}	SP6	(1, 0, 0, 1, 196)	196	215	Incumbente	19	8.8%
{SP5}	SP5	(1, 0, 1, 0.872, 206.69)	196	206	{SP9, SP10}	10	4.9%
{SP9, SP10}	SP10	(1, 0, 1, 0, 123)	196	206	Abandonado	10	4.9%
{SP9}	SP9	(0.8, 0, 1, 1, 203.38)	196	203	{SP11, SP12}	7	3.4%
{SP11, SP12}	SP11	-	196	203	Impossível	7	3.4%
{SP12}	SP12	(0, 0, 1, 1, 119)	196	196	Abandonado	7	3.4%
{}					Incumbente é ótima	0	0%

Tabela 8.1: Tabela com a aplicação passo a passo do método de partição e avaliação ao exemplo.

8.4 Tópicos adicionais

A eficiência do software para PI em muitos modelos com aplicação prática deriva da combinação do método de partição e avaliação com outras abordagens, em particular com métodos designados por planos de corte. De facto, a designação comum para o método implementado nos software de estado-da-arte passou a ser *branch-and-cut* (partição e cortes), substituindo a designação clássica *branch-and-bound* (partição e avaliação).

Um plano de corte (também designado por corte ou desigualdade válida) é uma restrição que exclui a solução óptima da relaxação linear sem excluir nenhuma solução inteira candidata a óptima. Considere-se a primeira restrição do modelo da subsecção 8.3, a restrição 8.6:

$$31x_1 + 32x_2 + 14x_3 + 38x_4 \leq 100.$$

Como a soma dos coeficientes das variáveis x_1, x_2 e x_4 (com valor 101) é superior ao valor do termo independente (100), no máximo duas variáveis poderão tomar o valor um, o que se traduz na restrição

$$x_1 + x_2 + x_4 \leq 2.$$

Esta restrição elimina a solução óptima da relaxação linear ($x_1 = 1, x_2 = 0.9, x_3 = 0, x_4 = 1$ não verifica $x_1 + x_2 + x_4 \leq 2$) e, assim, a sua inclusão no modelo permite uma melhor aproximação ao conjunto das soluções admissíveis inteiras. De facto a relaxação linear com este corte passa a ter valor 215.62 o que melhora consideravelmente o limite superior e consequentemente o gap.

Existem diversas famílias de planos de corte, sendo os mais efectivos dependentes da estrutura do modelo. Por exemplo, os cortes da família do aqui apresentado (*cortes de cobertura*) derivam-se para restrições menor ou igual em que todas as variáveis são binárias e têm coeficientes positivos.

O método de partição e cortes consiste assim na utilização de restrições adicionais na resolução das relaxações lineares associadas aos nodos da árvore de pesquisa do método de partição e avaliação. Aspectos mais avançados (como a discussão de famílias de cortes, a utilização de cortes *a priori* ou baseada na resolução de problemas de separação, a exploração de cortes locais - cortes válidos em partes da árvore de pesquisa) não fazem parte do âmbito deste texto.

Como exemplificado, a inclusão de cortes no método partição e avaliação permite a melhoria dos limites superiores (i.e. ter limites superiores mais baixos).

As implementações do método de partição e avaliação (e cortes) actuais incorporam também métodos heurísticos. Uma heurística é procedimento que visa a obtenção de uma solução de qualidade sem provar a sua optimalidade. No contexto do método de partição e avaliação, a utilização de

heurísticas tem como objectivo melhorar a qualidade da solução incumbente (e consequentemente o limite inferior). Embora haja evidência que a utilização de heurísticas no método de partição e avaliação (e cortes) não aumenta significativamente a sua eficiência na obtenção de uma solução óptima, a utilização de heurísticas permite frequentemente a obtenção de soluções de qualidade rapidamente o que, em termos práticos, pode ser decisivo. Em muitos modelos, a solução óptima inteira é obtida muito rapidamente, sendo a maior parte do tempo de resolução despendido a provar a sua optimalidade (i.e. a resolver nodos da árvore de pesquisa para melhorar o limite superior e assim fechar o gap). Tirando partido desta observação, o método de partição e avaliação (e cortes) pode ser usado como uma heurística ao limitar-se o seu tempo de resolução.

Descrevem-se sucintamente três tipos de heurísticas usadas no método de partição e avaliação (e cortes): arredondamento, mergulho e de melhoria. Como o nome indica, uma heurística de arredondamento, arredonda para inteiros as variáveis de decisão com valor fraccionário. Em geral, uma heurística não garante a obtenção de uma solução admissível, tal é particularmente claro nas heurísticas de arredondamento. Por exemplo, com o arredondamento da solução óptima da relaxação linear do exemplo, $x_1 = 1, x_2 = 0.9, x_3 = 0, x_4 = 1$, obtém-se a solução $x_1 = 1, x_2 = 1, x_3 = 0, x_4 = 1$ que não é admissível. Numa heurística de mergulho após resolvida a relaxação linear, algumas variáveis são fixadas e é resolvido o problema resultante. Este processo repete-se até ser obtida uma solução inteira. Uma heurística de mergulho particularmente útil para obter soluções admissíveis é a *feasibility pump*. As heurísticas de melhoria pesquisam a vizinhança (conjunto de soluções com pequenas diferenças em relação à solução em causa) da solução incumbente, e eventualmente de outras soluções. Esta pesquisa pode ser baseada em pesquisa local (ou, de forma mais geral, uma metaheurística) ou através do próprio método de partição e avaliação (e cortes) ao considerarem-se problemas de menor dimensão (já que algumas variáveis são fixadas).

Por fim, salienta-se que, embora se tenha apresentado o método de partição e avaliação para PI, a extensão da versão base para problemas de programação inteira mista é directa.

8.5 Exercícios

Exercício 8.1. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 4x_1 - 2x_2 + 7x_3 + -x_4$$

Sujeito a:

$$x_1 + 5x_3 \leq 10$$

$$x_1 + x_2 - x_3 \leq 1$$

$$6x_1 - 5x_2 \leq 0$$

$$-x_1 + 2x_3 - 2x_4 \leq 3$$

$$x_j \geq 0 \text{ e inteiro, } j = 1, \dots, 4.$$

Através da **utilização de software** para a resolução dos problemas dos nodos da árvore de pesquisa do método de partição e avaliação, obtenha a solução óptima com cada uma das seguintes estratégias de pesquisa:

- a) profundidade;
- b) largura;
- c) melhor limite.

Selecione para variável de partição aquela que tiver uma parte fraccionária mais próxima de 0.5. Em caso de empate na selecção do nodo, escolha aquele cuja última restrição é de maior ou igual.

Exercício 8.2. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 3x_1 + 4x_2$$

Sujeito a:

$$2x_1 + x_2 \leq 6$$

$$2x_1 + 3x_2 \leq 9$$

$$x_1, x_2 \geq 0 \text{ e inteiros.}$$

Através da **representação gráfica** para a resolução dos problemas dos nodos da árvore de pesquisa do método de partição e avaliação, obtenha a solução óptima com cada uma das seguintes estratégias de pesquisa:

- a) profundidade;
- b) largura;
- c) melhor limite.

Selecione para variável de partição aquela que tiver uma parte fraccionária mais próxima de 0.5. Em caso de empate na selecção do nodo, escolha aquele cuja última restrição é de maior ou igual.

Exercício 8.3. A dado momento da aplicação do método de partição e avaliação a um problema de PI obteve-se a árvore de pesquisa da Figura 8.9.




Figura 8.9: Árvore de pesquisa do método de partição e avaliação do Exercício 8.3.

- Qual foi a estratégia de pesquisa seguida? Justifique sucintamente.
- A pesquisa feita até ao momento é suficiente para identificar a solução ótima do problema? Em caso afirmativo, indique o seu valor. Caso contrário, indique o intervalo mais apertado em que se encontra o valor da solução ótima.
- Repita a questão anterior mas considerando que se resolveram os sub-problemas A e B e que ambos têm valor ótimo 12.1.

Exercício 8.4. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 7x_1 + 4x_2 + 2x_3 + 9x_4 + 3x_5$$

Sujeito a:

$$2x_1 + 7x_2 + 7x_3 + 10x_4 + 5x_5 \leq 30$$

$$x_1 + 10x_2 + 4x_3 + 7x_4 + 10x_5 \leq 20$$

$$3x_1 + 3x_2 + 2x_3 + 5x_4 + 3x_5 \leq 20$$

$$0 \leq x_j \leq 2 \text{ e inteiro, } j = 1, \dots, 5.$$

Na Figura 8.10 apresenta-se a árvore de pesquisa a dado momento da aplicação do método de partição e avaliação. Junto aos nodos que já foram resolvidos indica-se a sua solução óptima com a notação $(z, x_1, x_2, x_3, x_4, x_5)$. No nodo SP_5 foi encontrada uma solução inteira.

- Quais os intervalos de optimalidade absoluto e relativo após a resolução do nodo SP_5 ?
- Através das resoluções dos subproblemas com software, mostre que a solução incumbente é óptima.




Figura 8.10: Árvore de partição e avaliação do Exercício 8.4.

Exercício 8.5. Considere o seguinte problema de PI:

$$\text{Maximizar } z = 15x_1 + 12x_2 + 4x_3 + 2x_4$$

Sujeito a:

$$8x_1 + 5x_2 + 3x_3 + 2x_4 \leq 10$$

$$x_1, x_2, x_3, x_4 \in \{0, 1\}.$$

Na Figura 8.11 e Tabela 8.2 está a informação gerada até ao momento na resolução do modelo pelo método de partição e avaliação.




Figura 8.11: Árvore de partição e avaliação do Exercício 8.5.

Nodo	z	x_1	x_2	x_3	x_4
RL	21.375	0.625	1	0	0
SP_1	18	0	1	1	1
SP_2	19.8	1	0.4	0	0
SP_3	17.667	1	0	0.667	0
SP_4	?	?	?	?	?

Tabela 8.2: Tabela do Exercício 8.5.

- Apresente o modelo de PL associado ao nodo SP_4 .
- O problema de PI encontra-se resolvido? Se sim, indique a solução ótima. Se não, indique (i) um intervalo no qual se encontra o valor da solução ótima, (ii) a existir(em), qual ou quais os nodos que devem gerar descendentes e (iii) a existir(em), qual ou quais os nodos que devem ser resolvidos.

Exercício 8.6. A dado momento da aplicação do método de partição e avaliação a um problema de PI com cinco variáveis de decisão binárias obteve-se a árvore de pesquisa da Figura 8.12.

Na Tabela 8.3 seguinte são dadas as soluções óptimas e os seus valores para os quatro nodos já otimizados.




Figura 8.12: Árvore de pesquisa do método de partição e avaliação do Exercício 8.6.

Nodo	z	x_1	x_2	x_3	x_4	x_5
A	38	1	1	0	1	1
B	42	1	1	1	0	1
C	44	1	1	1	0.5	1
D	?	?	?	?	?	?
E	43.7	1	1	0.7	1	1

Tabela 8.3: Tabela do Exercício 8.6.

- Indique as correspondências entre os nodos da Figura 8.6 os nodos da Tabela 8.3.
- Quais os intervalos de optimalidade absoluto e relativo?

Exercício 8.7. As Figuras 8.13, 8.14 e 8.15 representam a aplicação (parcial) do método de partição e avaliação a problemas de PI. Os nodos que já foram resolvidos e não são impossíveis nem actualizaram a incumbente, têm soluções óptimas fraccionárias. Os nodos com $z=?$ ainda não foram resolvidos. Para cada problema indique:

- Os intervalos de optimalidade absoluto e relativo.
- Os nodos que devem gerar descendentes e os que devem ser abandonados.

c) Se os nodos com $z=?$ devem ser resolvidos.




Figura 8.13: Árvore de pesquisa do método de partição e avaliação do Exercício 8.7a.




Figura 8.14: Árvore de pesquisa do método de partição e avaliação do Exercício 8.7b.




Figura 8.15: Árvore de pesquisa do método de partição e avaliação do Exercício 8.7c.

Exercício 8.8. A dado momento da aplicação do método de partição e avaliação a um problema de PI obteve-se a árvore de pesquisa da Figura 8.16.




Figura 8.16: Árvore de pesquisa do método de partição e avaliação do Exercício 8.8.

Apresente uma tabela com uma sequência de passos da aplicação do método de partição e avaliação possível (semelhante à Tabela 8.1).

Exercício 8.9. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 100x_1 + 72x_2 + 23x_3 + 45x_4$$

Sujeito a:

$$9x_1 + 9x_2 + 3x_3 + 7x_4 \leq 10$$

$$x_1 + 5x_2 + 7x_3 + 7x_4 \leq 10$$

$$8x_1 + 9x_2 + 10x_3 + x_4 \leq 10$$

$$x_j \in \{0, 1\}, j = 1, \dots, 4.$$

Confirme que para demonstrar que a solução $x_1 = 1, x_2 = x_3 = x_4 = 0$ é ótima apenas é necessário resolver, para além da relaxação linear, nodos da árvore de pesquisa com restrições de partição de menor ou igual. Utilize software para a resolução dos subproblemas.

Exercício 8.10. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 8x_1 + 11x_2 + 6x_3 + 4x_4$$

Sujeito a:

$$5x_1 + 7x_2 + 4x_3 + 3x_4 \leq 14$$

$$x_j \in \{0, 1\}, j = 1, \dots, 4.$$

Na Tabela reftabbb60 apresentam-se os passos realizados na resolução deste problema pelo método de partição e avaliação.

- Apresente a árvore de pesquisa obtida até ao momento, representado as restrições de partição.
- Resolva o subproblema SP7 por inspeção.
- A solução óptima foi encontrada ou é necessário resolver mais algum subproblema?

SP por resolver	SP resolvido	$(x_1, x_2, x_3, x_4, z_{SP})$	z_{INC}	z_{LM}	Análise / Novos SP	gap_{ABS}	gap_{REL}
$\{\text{RL}\}$ $\{\text{SP1}, \text{SP2}\}$ $\{\text{SP2}, \text{SP3}, \text{SP4}\}$ $\{\text{SP3}, \text{SP4}, \text{SP5}, \text{SP6}\}$ $\{\text{SP3}, \text{SP4}, \text{SP6}\}$ $\{\text{SP3}, \text{SP4}, \text{SP7}, \text{SP8}\}$	RL	(1, 1, 0.5, 0, 22)	$-\infty$	22	{SP1, SP2}	∞	100%
	SP1	(1, 1, 0, 0.667, 21.65)	$-\infty$	?	{SP3, SP4}	∞	100%
	SP2	(1, 0.714, 1, 0, 21.85)	$-\infty$	?	{SP5, SP6}	∞	100%
	SP5	(1, 0, 1, 1, 18)	18	?	incumbente	?	?
	SP6	(0.6, 1, 1, 0, 21.80)	18	?	{SP7, SP8}	?	?
	SP7 (SP6 + $x_1 \leq 0$)	?	?	?	?	?	?

Tabela 8.4: Tabela com a aplicação passo a passo (parcial) do método de partição e avaliação ao Exercício 8.10.

- Exercício 8.11.** a) O que pode concluir sobre um problema inteiro cuja relaxação linear é impossível?
- b) O que pode concluir sobre um problema inteiro cuja relaxação linear não tem solução ótima finita (é ilimitada)?
- c) Quais as diferenças entre a aplicação do método de partição e avaliação a um problema de maximização e a um problema de minimização?

Exercício 8.12. Considere o seguinte modelo de PI:

$$\text{Maximizar } z = 23x_1 + 19x_2 + 28x_3 + 14x_4 + 44x_5$$

Sujeito a:

$$8x_1 + 7x_2 + 11x_3 + 6x_4 + 19x_5 \leq 25$$

$$x_j \in \{0, 1\}, j = 1, \dots, 5.$$

Através da **utilização de software** para a resolução dos problemas dos nodos da árvore de pesquisa, obtenha a solução ótima pelos métodos:

- a) Partição e avaliação. Se possível, seleccione o nodo cuja última restrição é de menor ou igual.
- b) Partição e avaliação e cortes. Considere os cinco cortes que correspondem a i) apenas duas das variáveis x_1, x_2 e x_3 poderem tomar valor um e ii) a variável x_5 e qualquer outra variável não poderem tomar valor um simultaneamente.