

Universidade do Minho

Escola de Engenharia

Departamento de Informática

Machine Learning

Preparação de Dados

MESTRADO EM ENGENHARIA DE TELECOMUNICAÇÕES E INFORMÁTICA

MESTRADO integrado EM ENGENHARIA DE TELECOMUNICAÇÕES E INFORMÁTICA

Inteligência Artificial para as Telecomunicações

2025/2026



Porquê preparar os dados?

- O principal objetivo da **preparação dos dados** consiste em **transformar** os *data sets* por forma a que a **informação** neles contida esteja **adequadamente exposta à ferramenta** de extração de conhecimento;
- A preparação dos dados “também prepara o preparador” por forma seleccionar os modelos de EC mais adequados;
- Os dados têm de ser formatados para se adequarem a uma determinada ferramenta de EC;
- Os dados recolhidos do “mundo real”:
 - são incompletos;
 - contêm lixo;
 - podem conter inconsistências.




ISLab

Synthetic Intelligence Lab

Preparação de dados

■ Preparação dos Dados (Pré-processamento). Como?

- Discretização;
(classes etárias)
- Limpeza;
(nº BI)
- Integração e Transformação;
(fontes; diários/mensais)
- Redução de dados.
(moradas/regiões)



Data Mining – Descoberta de Conhecimento em Bases de Dados
Manuel Filipe Santos, Carla Azevedo




ISLab

Synthetic Intelligence Lab

Porquê preparar os dados?

- Os dados recolhidos do “mundo real”:
 - são incompletos:
 - falta de valores em alguns atributos;
 - falta de alguns atributos;
 - dados agregados ou generalizados;
 - Código postal: 4710-... Braga;
 - Nº de filhos: “”;
 - contêm lixo;
 - podem conter inconsistências.






ISLab

Synthetic Intelligence Lab

■ Os dados recolhidos do “mundo real”:

- são incompletos;
- contêm lixo:
 - identificam valores impossíveis;
 - Salário: -1.000EUR;
 - Idade: 321;
 - Data: 31/novembro/2017;
 - País: Catalunha;
- podem conter inconsistências.

Porquê preparar os dados?



Porquê preparar os dados?

- Os dados recolhidos do “mundo real”:
 - são incompletos;
 - contêm lixo;
 - podem conter inconsistências:
 - encontram-se discrepâncias entre valores ou nomes;
 - Idade = 35; Data de nascimento = 31/maio/1969;
 - Sexo: “M/F”; “0/1”; “Masculino/Feminino/Desconhecido”;
 - diferenças entre valores de registos duplicados.





Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação;
- Redução.



Tarefas na preparação de dados

- Discretização/Enumeração:
 - Redução de dados com importante aplicação a dados numéricos;
- Limpeza;
- Integração;
- Transformação;
- Redução.






ISLab

Synthetic Intelligence Lab


Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza:
 - Preenchimento de valores de atributos;
 - Remoção de lixo dos dados;
 - Remoção de valores impossíveis;
 - Resolução de inconsistências;
- Integração;
- Transformação;
- Redução.



Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração:
 - Múltiplas fontes de dados (BD's, ficheiros, papel, web, etc.);
- Transformação;
- Redução.





ISLab

Synthetic Intelligence Lab

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação:
 - Normalização e agregação de dados;
- Redução.

Tarefas na preparação de dados



Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação;
- Redução:
 - Obtenção de representações de dados menos volumosas, mas com capacidade para produzir idênticos resultados analíticos;
 - Redução de dimensões;
 - Compressão de dados.



Tipos de dados

- Os tipos dos dados diferem na sua natureza e na quantidade de informação que proporcionam:
- **Qualitativos ou Quantitativos.**



Eu estou **correto!**



Mas só **5%!**

Tipos de dados

- **Nominais:**
 - Atribui nomes únicos a objetos:
 - Não existe outra informação que se possa deduzir;
 - Nomes de pessoas;
 - Códigos de identificação;
- **Categorias;**
- **Ordinais;**
- **Intervalos;**
- **Rácios.**




Tipos de dados

- Nominais;
- Categorias:
 - Atribui categorias a objetos:
 - Podem ser valores numéricos, mas são **não ordenados**;
 - Código postal;
 - Sexo;
 - Cor dos olhos;
- Ordinais;
- Intervalos;
- Rácios.




Tipos de dados

- Nominais;
- Categorias;
- Ordinais:
 - Os valores podem ser ordenados naturalmente;
 - Classificação: excelente, bom, suficiente, etc.;
 - Temperatura: frio, morno, quente;
- Intervalos;
- Rácios.



Tipos de dados

- Nominais;
- Categorias;
- Ordinais;
- Intervalos:
 - É possível calcular a distância entre dois valores;
 - Temperatura;
 - Humidade;
- Rácios.




Tipos de dados

- Nominais;
- Categorias;
- Ordinais;
- Intervalos;
- Rácios:
 - Os valores podem ser utilizados para determinar um rácio significativo entre eles:
 - Salário;
 - Balanço bancário.



Country	Converted values			National rates and developments		
	2020 (€)	2021 (€)	Change (%)	2020 (€ unless otherwise stated)	2021 (€ unless otherwise stated)	Change (%)
Luxembourg	2,142	2,202	2.8	2,142/month	2,202/month	2.8
UK*†	1,790	1,903	6.3	GBP 8.72/hour	GBP 8.91/hour	2.2
Ireland*	1,707	1,724	1.0	10.1/hour	10.2/hour	1.0
Netherlands	1,654	1,685	1.9	1,654/month	1,685/month	1.9
Belgium*	1,626	1,626	0.0	1,626/month	1,626/month	0.0
Germany	1,584	1,610	1.6	9.35/hour	9.5/hour	1.6
France	1,539	1,555	1.0	1,539/month	1,555/month	1.0
Slovenia	1,019	1,110	8.9	1,019/month	1,110/month	8.9
Spain	1,108	1,108	0.0	1,108/month	1,108/month	0.0
Malta	777	785	1.0	179/week	181/week	1.0
Portugal	741	776	4.7	741/month	776/month	4.7
Greece	758	758	0.0	758/month	758/month	0.0
Lithuania	607	642	5.8	607/month	642/month	5.8
Slovakia	580	623	7.4	580/month	623/month	7.4
Poland	611	614	0.5	PLN 2,600/month	PLN 2,800/month	7.7
Estonia	584	584	0.0	584/month	584/month	0.0
Czechia	575	579	0.8	CZK 14,600/month	CZK 15,200/month	4.1
Croatia	546	563	3.1	HRK 4,063/month	HRK 4,250/month	4.6
Latvia	430	500	16.3	430/month	500/month	16.3
Romania	466	472	1.3	RON 2,230/month	RON 2,300/month	3.1
Hungary†	487	467	-4.1	HUF 161,000/month	HUF 167,400/month	4.0
Bulgaria	312	332	6.6	BGN 610/month	BGN 650/month	6.6

Tipos de dados





Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação;
- Redução.




Discretização/Enumeração

- Utiliza-se a discretização (ou enumeração) para reduzir o número de valores de um atributo contínuo, dividindo-o em intervalos;
 - Os métodos mais utilizados (Naïve Bayes, CHAID, etc.), requerem valores discretos;
 - Redução do tamanho dos dados;
 - Método utilizado para produzir sumariação dos dados;
 - (Sinónimo de *binning*.)



Discretização de igual largura

- *Equal-width binning*:
- Divide a gama de valores em N intervalos de igual largura, resultando numa grelha uniforme;
- Sendo A e B os limites da gama de valores, a largura dos intervalos será $L = (B - A) / N$:






Discretização de igual largura

■ Vantagens:

- Simples e fácil de implementar;
- Produz abstrações de dados razoáveis;

■ Desvantagens:


- Não supervisionado;
- Quem determina N?;
- Sensível a valores fronteira.





Discretização de igual altura

- *Equal-height binning*:
- Divide a gama de valores em N intervalos, contendo, cada um, **aproximadamente** a mesma quantidade de valores:




Discretização de igual altura

- Normalmente preferida à discretização de igual largura, uma vez que permite evitar o “amontoar” de valores;
- Na prática, utiliza-se uma discretização de “quase-igual” altura, garantindo intervalos mais intuitivos;
- Deverá impedir a dispersão de valores frequentes por diferentes intervalos;
- Deverá criar intervalos separados para valores especiais (“0”).

Discretização: outros métodos

- Método 1R:
 - Método supervisionado, baseado na divisão por *binning*;
- Discretização baseada em Entropia;
- Discretização baseada em Impurezas;
- Detecção de limites;
- etc.






ISLab

Synthetic Intelligence Lab

- Discretização/Enumeração;
- **Limpeza;**
- Integração;
- Transformação;
- Redução.

Tarefas na preparação de dados





ISLab

Synthetic Intelligence Lab

Limpeza de dados

- Ausência de valores em determinados atributos devido a:
 - inconsistência;
 - dados não registrados;
 - análise incorreta;
 - dados registrados de forma errada;
 - etc.
- **A ausência de dados pode revelar algo sobre que campos não foram preenchidos!**

Limpeza de dados: como tratar a ausência de dados?

- Ignorar os registos onde faltam os dados e lidar, apenas com os dados conhecidos;
 - não aconselhável se a quantidade de dados em falta em cada atributo for elevada;
- Ignorar os atributos onde faltam os dados;
 - não aconselhável se os atributos onde acontece revelarem informação importante;
- Preencher (manualmente) os dados em falta:
 - é mais trabalhoso preencher ou é mais difícil adivinhar?
- Preencher os dados em falta com um mesmo valor (“talvez”):
 - pode criar tendências nos dados ou novas classes;
- Preencher com o valor médio do atributo:
 - pouco impacto negativo, desde que o desvio padrão não seja grande;
- Preencher com o valor mais frequente do atributo;
- Quanto mais valores “inventados”, maior o desvio dos dados que caracterizam o problema face à realidade que o problema ilustra!


Limpeza de dados: como tratar a ausência de dados?

- Ignorar os registos onde faltam os dados e lidar, apenas com os dados conhecidos;
 - não aconselhável se a quantidade de dados em falta em cada atributo for elevada;
- Ignorar os atributos onde faltam os dados;
 - não aconselhável se os atributos onde acontece revelarem informação importante;
- Preencher (manualmente) os dados em falta;
 - é mais trabalhoso preencher ou é mais difícil adivinhar?
- Preencher os dados em falta com um mesmo valor (“talvez”);
 - pode criar tendências nos dados ou novas classes;
- Preencher com o valor médio do atributo;
 - pouco impacto negativo, desde que o desvio padrão não seja grande;
- Preencher com o valor mais frequente do atributo;
- Quantos mais valores “imputados”, maior o desvio dos dados que caracterizam o problema face à realidade que o problema ilustra!

Evitar adicionar distorção aos dados.


Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- **Integração;**
- Transformação;
- Redução.



Integração de dados

- Os dados que caracterizam o problema podem ter proveniências diversas;
- O objetivo da integração é o de compor um conjunto de peças de informação numa coleção coerente e integrada de dados.
- Detetar e resolver conflitos entre os dados:
 - qual a fonte de dados mas fiável, quando os valores que transportam são inconsistentes?
- Integração exige “**conhecimento do negócio**”.



- Discretização/Enumeração;
- Limpeza;
- Integração;
- **Transformação;**
- Redução.

Tarefas na preparação de dados



Transformação de dados

- Alisamento (*smoothing*):
 - Remover lixo/ruído dos dados (*binning*, regressão, *clustering*);
- Agregação;
- Generalização;
- Construção de Atributos;
- Uniformização;
- Detecção de valores atípicos.





ISLab

Synthetic Intelligence Lab

Transformação de dados

- Alisamento (*smoothing*);
- Agregação:
 - Pressupõe que o resultado sumaria os dados iniciais;
(resumo de vendas trimestrais, durante 5 anos, em valores anuais)
- Generalização;
- Construção de Atributos;
- Uniformização;
- Detecção de valores atípicos.





ISLab

Synthetic Intelligence Lab

Transformação de dados

- Alisamento (*smoothing*);
- Agregação;
- Generalização:
 - Hierarquização de conceitos:
 - distrito → cidade → rua;
 - Valores diferentes: 18 → centenas → (largos) milhares
- Construção de Atributos;
- Uniformização;
- Detecção de valores atípicos.





ISLab

Synthetic Intelligence Lab

Transformação de dados

- Alisamento (*smoothing*);
- Agregação;
- Generalização;
- Construção de atributos:
 - Construção de novos atributos a partir de outros (cálculo do preço líquido baseado no preço ilíquido e no IVA);
- Uniformização;
- Detecção de valores atípicos.




Transformação de dados

- Alisamento (*smoothing*);
- Agregação;
- Generalização;
- Construção de atributos;
- Uniformização:
 - Pretende evitar que atributos com uma gama alargada de valores sobressaiam em relação a outros atributos com menor quantidade de valores:
 - Normalização (*normalization*: [0;1]);
 - Padronização (*standardization/Z-score normalization*: $\bar{x}=0$; $\partial=1$);
- Detecção de valores atípicos.




Transformação de dados

- Alisamento (*smoothing*);
- Agregação;
- Generalização;
- Construção de atributos;
- Uniformização;
- Detecção de valores atípicos:
 - Por visualização:
 - Box plots



Transformação de dados

- Alisamento (*smoothing*);
- Agregação;
- Generalização;
- Construção de atributos;
- Uniformização;
- Detecção de valores atípicos:
 - Por visualização:
 - Box plots
 - Z-Score (desvio padrão)




Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação;
- **Redução.**



Redução de dados


- Um *Data Warehouse* pode armazenar largos terabytes de dados;
- Realizar tarefas de EC em tais quantidades de dados pode tornar-se impraticável!
- A **Redução de dados** pretende obter uma representação reduzida do volume de dados, mas produzindo os mesmos (ou quase os mesmos) resultados analíticos.





Redução de dados: estratégias

- Construção de cubos de dados:
 - as operações de agregação são aplicadas de modo a construir cubos de dados;
- Redução de dimensões:
 - remoção de atributos que se mostrem irrelevantes, redundantes ou pouco interessantes para a análise;
 - *Principle Component Analysis (PCA)*;
- Compressão de dados:
 - aplicação de técnicas de compressão ou de transformação para comprimir a representação dos dados originais;
- Redução de quantidade:
 - redução do volume de dados (técnicas paramétricas ou não paramétricas)
- Discretização e generalização de conceitos:
 - redução da quantidade de valores por atributo.






ISLab

Synthetic Intelligence Lab

Referências bibliográficas

- Data Preparation for Data Mining
Dorian Pyle
- Data Mining: Concepts and Techniques
Jiawei Han, Micheline Kamber
- Data Mining: Practical Machine Learning Tools and Techniques with JAVA Implementations
Ian Witten, Eibe Frank
- Data Mining: Descoberta de Conhecimento em BDs
Manuel Filipe Santos, Carla Azevedo



Universidade do Minho

Escola de Engenharia

Departamento de Informática

Machine Learning

Preparação de Dados

MESTRADO EM ENGENHARIA DE TELECOMUNICAÇÕES E INFORMÁTICA

MESTRADO integrado EM ENGENHARIA DE TELECOMUNICAÇÕES E INFORMÁTICA

Inteligência Artificial para as Telecomunicações

2025/2026