



Universidade do Minho

Escola de Engenharia

Mestrado em Engenharia de  
Telecomunicações e Informática  
Escola de Engenharia

Relatório do Trabalho individual de Inteligência Artificial  
para as Telecomunicações

# **Nurse Stress Prediction**

## **Wearable Sensors**

Trabalho realizado por:

Luis Pedro Cerqueira Baptista pg61434

2025/2026

# Índice

|                                                                          |    |
|--------------------------------------------------------------------------|----|
| 1. Introdução.....                                                       | 4  |
| 1.1. Contexto e Motivação.....                                           | 4  |
| 1.2. Objetivos e Reenquadramento do Problema .....                       | 4  |
| 1.3. Metodologia.....                                                    | 5  |
| 2. Análise e Preparação dos Dados.....                                   | 5  |
| 2.1. Descrição do Conjunto de Dados .....                                | 5  |
| 2.2. Exploração Inicial e Reenquadramento da Tarefa .....                | 6  |
| 2.3. Workflow de Pré-processamento e Engenharia de <i>Features</i> ..... | 7  |
| 3. Abordagem 1 (Classificação Supervisionada) (Previsão de label) .....  | 9  |
| 3.1. Metodologia de Modelação .....                                      | 10 |
| 3.2. Resultados (Previsão de label).....                                 | 10 |
| 3.3. Análise Crítica dos resultados.....                                 | 11 |
| 4. Abordagem 2 (Regressão Supervisionada) (Previsão de HR e EDA) .....   | 12 |
| 4.1. Metodologia de Modelação .....                                      | 13 |
| 4.2. Análise crítica dos resultados .....                                | 16 |
| 5. Abordagem 3 (Clustering Não-Supervisionado) .....                     | 17 |
| 5.1. Metodologia e Resultados .....                                      | 17 |
| 5.2. Análise Crítica (Clustering).....                                   | 18 |
| 6. Conclusão .....                                                       | 18 |
| 7. Referências .....                                                     | 20 |

## Índice de Figuras

|                                                                                                |    |
|------------------------------------------------------------------------------------------------|----|
| <b>Figura 1</b> - Distribuição de valores (Data Explorer). .....                               | 6  |
| <b>Figura 2</b> - Histograma da variável EDA.....                                              | 7  |
| <b>Figura 3</b> - Workflow "Gold Standard" de Pré-processamento e Separação.....               | 7  |
| <b>Figura 4</b> - Leitura e Pré-processamento (Regressão). .....                               | 9  |
| <b>Figura 5</b> - Modelos de Classificação. ....                                               | 9  |
| <b>Figura 6</b> - Matriz de Confusão do modelo Naive Bayes (94.06%).....                       | 10 |
| <b>Figura 7</b> - Matriz de Confusão do modelo Random Forest (100%) + XGBoost (100%).<br>..... | 10 |
| <b>Figura 8</b> - Testes de Classificação (Cross-Validation e AutoML). ....                    | 11 |
| <b>Figura 9</b> - Numeric Scorer (Cross-validation de Classificação) .....                     | 11 |
| <b>Figura 10</b> - Modelo Regressão HR.....                                                    | 12 |
| <b>Figura 11</b> - Modelo de Regressão EDA. ....                                               | 13 |
| <b>Figura 12</b> - Resultados AutoML (Regressão EDA). ....                                     | 15 |
| <b>Figura 13</b> - Resultados AutoML (Regressão EDA) Continuação.....                          | 16 |
| <b>Figura 14</b> - Modelo de Clustering.....                                                   | 17 |

## Índice de Tabelas

|                                                                                  |    |
|----------------------------------------------------------------------------------|----|
| <b>Tabela 1</b> - Identificação das colunas do dataset.....                      | 6  |
| <b>Tabela 2</b> - Resultados da Abordagem 1 (Classificação Supervisionada).....  | 10 |
| <b>Tabela 3</b> - Resultados da Abordagem 2 (Regressão HR).....                  | 13 |
| <b>Tabela 4</b> – Resultados da Abordagem 2 (Regressão HR) .....                 | 15 |
| <b>Tabela 5</b> – Resultados da Abordagem 3 (Clustering Não-Supervisionado)..... | 18 |

# 1. Introdução

## 1.1. Contexto e Motivação

A monitorização contínua do stress em profissionais de saúde constitui um campo de investigação fundamental, particularmente em ambientes de elevada pressão como os hospitais. A deteção precoce do stress é crucial para a gestão proativa da saúde, auxiliando os indivíduos na mitigação dos efeitos prejudiciais da exposição prolongada ao stress.

O aparecimento de tecnologia wearable (dispositivos vestíveis) permitiu a recolha contínua de diversos fatores fisiológicos em ambientes naturalistas.

Este projeto debruçou-se sobre a análise do dataset "Continuous Stress Monitoring of Hospital Nurses". Este dataset exclusivo agrega dados biométricos (como atividade eletrodérmica, ritmo cardíaco e temperatura corporal) de enfermeiras durante os seus turnos regulares, num período coincidente com o surto de COVID-19.

A análise do stress num ambiente de trabalho é intrinsecamente complexa, contudo, o uso de dados de sensores oferece uma via objetiva para quantificar estados fisiológicos.

## 1.2. Objetivos e Reenquadramento do Problema

O objetivo principal deste trabalho é conceber e otimizar modelos de Aprendizagem Automática, com especial incidência em modelos de aprendizagem supervisionada para regressão e classificação.

A análise exploratória inicial ao dataset (detalhada no Capítulo 2) validou a viabilidade desta abordagem, confirmando que a coluna label (o alvo de stress) possuía três valores categóricos distintos (0, 1 e 2), permitindo a modelação de classificação.

Os objetivos específicos definidos para este projeto foram:

1. Abordagem 1 (Classificação): desenvolver e otimizar modelos (Naive Bayes, Random Forest, XGBoost) para prever a classe de stress (label), utilizando apenas *features* de contexto (movimento e tempo) para evitar *data leakage*.
2. Abordagem 2 (Regressão): desenvolver e avaliar modelos de Regressão Supervisionada para prever o Ritmo Cardíaco (HR) e a Atividade Eletrodérmica (EDA).

3. Abordagem 3 (Clustering): explorar a Aprendizagem Não-Supervisionada (K-Means, K-Medoids) para investigar se existiam grupos (clusters) naturais nos dados.
4. Análise Crítica: realizar uma análise comparativa do desempenho dos diferentes modelos e abordagens.

### 1.3. Metodologia

Para atingir os objetivos propostos, a metodologia adotada consistiu na criação de workflows dedicados no KNIME para cada tarefa de modelação. O pré-processamento foi um passo crítico, envolvendo:

- A amostragem (Row Sampler) de 100.000 registos para garantir a eficiência computacional na análise de um dataset de 11,5 milhões de linhas.
- Feature engineering temporal (com os nós Date&Time Part Extractor e One to Many) para extrair valor preditivo da coluna datetime.
- A normalização (Normalizer) dos dados para preparar as features para os diferentes algoritmos.

Os modelos de regressão foram validados usando uma partição padrão de 80% para treino e 20% para teste (Table Partitioner), e o seu desempenho foi medido pelas métricas  $R^2$  (Coeficiente de Determinação) e RMSE (Root Mean Squared Error). A abordagem de *clustering* foi avaliada recorrendo ao Silhouette Coefficient. Por fim, os modelos de classificação foram classificados por Accuracy e Cohen's Kappa

## 2. Análise e Preparação dos Dados

Uma análise e preparação rigorosas dos dados foram etapas fundamentais para o sucesso deste projeto. O dataset selecionado, embora rico em informação, apresentava desafios significativos em termos de volume, formato e relevância das *features*.

### 2.1. Descrição do Conjunto de Dados


O dataset utilizado foi o "Continuous Stress Monitoring of Hospital Nurses", recolhido durante o surto de COVID-19. Este conjunto de dados, com aproximadamente 11,5 milhões de registos, detalha a monitorização fisiológica contínua de 15 enfermeiras. O dataset é composto por sete colunas principais representadas na **Tabela 1**.

**Tabela 1** - Identificação das colunas do dataset

| X, Y, Z                                      | EDA<br>(Electrodermal<br>Activity)                                         | HR<br>(Heart<br>Rate)                       | TEMP<br>(Temperature)                            | id                                                         | datetime                                      | label                                                                   |
|----------------------------------------------|----------------------------------------------------------------------------|---------------------------------------------|--------------------------------------------------|------------------------------------------------------------|-----------------------------------------------|-------------------------------------------------------------------------|
| Dados numéricos de orientação (acelerómetro) | Medição numérica contínua da atividade eletrodérmica (indicador de stress) | Medição numérica contínua do ritmo cardíaco | Medição numérica contínua da temperatura da pele | Um identificador categórico para cada sujeito (enfermeira) | Carimbo temporal (em formato <i>string</i> )o | Coluna categórica (0, 1, 2) representando diferentes estados de stress. |

## 2.2. Exploração Inicial e Reenquadramento da Tarefa

A exploração inicial dos dados (Data Explorer) foi o passo mais crítico do projeto. Ao contrário de uma inspeção superficial (que sugeria um valor constante), a análise estatística da amostra de 100.000 linhas revelou que a coluna label possuía três valores distintos: 0, 1 e 2, como demonstrado na **Figura 1**. A média de 1.91 indica que a classe "2.0" é a mais frequente, mas as outras classes existem.



| Column | Exclude Column           | Minimum | Maximum   | Mean                | Standard Deviation | Variance            | Skewness             | Kurtosis           | Overall Sum        | No. zeros |
|--------|--------------------------|---------|-----------|---------------------|--------------------|---------------------|----------------------|--------------------|--------------------|-----------|
| X      | <input type="checkbox"/> | -128    | 127       | -36.356856338757126 | 24.297921003697397 | 590.3889651019191   | 0.8435227456386143   | 1.0976004247683153 | -11238995          | 1532      |
| Y      | <input type="checkbox"/> | -128    | 127       | 6.403674829359713   | 29.04900503283852  | 843.8446933978776   | -0.12242698750186883 | 0.3228234330800142 | 1979568            | 9952      |
| Z      | <input type="checkbox"/> | -128    | 127       | 25.034943227768153  | 29.81064423675979  | 888.6745098106595   | -1.0772580094028503  | 0.5482206437176553 | 7739052            | 1595      |
| EDA    | <input type="checkbox"/> | 0       | 16.137552 | 3.4213372566428237  | 2.5321265077586292 | 6.411664651293911   | 1.2588935237294547   | 1.8014785161368043 | 1057637.9861460968 | 2216      |
| HR     | <input type="checkbox"/> | 56.2    | 134.8     | 85.46535645197801   | 11.363153959764462 | 129.12126791331076  | 0.6134483975572024   | 1.2065541469772096 | 26419905.64000255  | 0         |
| TEMP   | <input type="checkbox"/> | 30.33   | 35.5      | 33.14776239769756   | 1.1306989704475765 | 1.2784801617712096  | 0.14748321837166745  | -1.13087750399556  | 10246967.79000209  | 0         |
| id     | <input type="checkbox"/> | 15      | 15        | 15                  | 0                  | 0                   | 0                    | 0                  | 4636950            | 0         |
| label  | <input type="checkbox"/> | 0       | 2         | 1.9130398214343023  | 0.4078710857940287 | 0.16635882262679993 | -4.4771289774202625  | 18.04480062612535  | 591378             | 13441     |

Showing 1 to 8 of 8 entries

**Figura 1** - Distribuição de valores (Data Explorer).

Esta descoberta validou a tarefa de Classificação como a principal abordagem do projeto. A análise revelou também a distribuição bimodal da feature EDA (**Figura 2**), sugerindo dois estados fisiológicos distintos.




Figura 2 - Histograma da variável EDA.

A **Figura 2** apresenta o histograma da variável EDA (atividade eletrodérmica), evidenciando a existência de dois modos principais. Esta distribuição sugere a presença de estados fisiológicos distintos que podem facilitar a separação dos grupos de stress no modelo de classificação.

## 2.3. Workflow de Pré-processamento e Engenharia de Features

Para transformar os dados brutos num formato limpo e otimizado, foi construído um workflow de pré-processamento "Gold Standard", focado em evitar data leakage.




Figura 3 - Workflow "Gold Standard" de Pré-processamento e Separação.

O workflow da **Figura 3** consistiu nos seguintes passos:

1. CSV Reader e Row Sampler: Leitura e amostragem de 100.000 registos .
2. String Manipulation e String to Date&Time: Limpeza e conversão da coluna datetime (removendo frações de segundo) .
3. Date&Time Part Extractor: Engenharia de Features. Extração de Hour of day (0-23) e Day of week (number).
4. Math Formula (Engenharia de Features Sofisticada): Criação da feature Move\_Magnitude (com a expressão  $\sqrt{X^2 + Y^2 + Z^2}$ ) para agregar os dados do acelerómetro numa única métrica de movimento.
5. Column Splitter (Passo "À Prova de Fuga"): O dataset foi fisicamente separado em dois ramos: um com o alvo (label) e outro com todas as restantes features.
6. Processamento do Ramo de Features:
  - Number to String e One to Many: Codificação One-Hot Encoding do Day of week (number) .
  - Column Filter: Remoção de colunas "lixo" (id, datetime originais) e das features "batota" (EDA, HR, TEMP), que são resultados do stress e não features de contexto.
  - Missing Value e Numeric Outliers: Limpeza de valores em falta (com Median) e tratamento de outliers de movimento.
  - Normalizer: Escalonamento Min-Max [0, 1] de todas as features limpas .
7. Processamento do Ramo do Alvo:
  - Number to String: Conversão do label (0, 1, 2) para formato String, preparando-o para os nós de classificação.
8. Column Appender: Junção das features limpas e do alvo limpo para alimentar os modelos.

A **Figura 4** mostra o workflow inicial de leitura do CSV, amostragem, limpeza, transformação de datas e normalização, usado na regressão supervisionada.






**Figura 4** - Leitura e Pré-processamento (Regressão).

### 3. Abordagem 1 (Classificação Supervisionada) (Previsão de label)

Esta foi a abordagem principal do projeto. O objetivo foi prever o label de stress (0, 1 ou 2) usando apenas features de contexto (movimento X,Y,Z, Move\_Magnitude e tempo Hour, Day of week).



**Figura 5** - Modelos de Classificação.

A **Figura 5** apresenta a implementação dos modelos de classificação, incluindo Random Forest, XGBoost e Naive Bayes, bem como a partição dos dados

### 3.1. Metodologia de Modelação

Os dados pré-processados e limpos (sem EDA, HR ou TEMP) foram divididos usando Table Partitioner (80% treino, 20% teste) com amostragem estratificada (Stratified sampling) no label. Foram comparados três modelos.

### 3.2. Resultados (Previsão de label)

Os resultados da classificação no conjunto de teste foram conclusivos e surpreendentes.

Confusion Matrix

Scorer View

Confusion Matrix

|              | 0.0 (Predicted) | 2.0 (Predicted) |         |
|--------------|-----------------|-----------------|---------|
| 0.0 (Actual) | 2688            | 0               | 100.00% |
| 2.0 (Actual) | 1190            | 16122           | 93.13%  |
|              | 69.31%          | 100.00%         |         |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 94.05%           | 5.95%         | 0.785                      | 18810                | 1190                   |

**Figura 6** - Matriz de Confusão do modelo Naive Bayes (94.06%).

Confusion Matrix

Scorer View

Confusion Matrix

|              | 0.0 (Predicted) | 2.0 (Predicted) |         |
|--------------|-----------------|-----------------|---------|
| 0.0 (Actual) | 2688            | 0               | 100.00% |
| 2.0 (Actual) | 0               | 17312           | 100.00% |
|              | 100.00%         | 100.00%         |         |

Overall Statistics

| Overall Accuracy | Overall Error | Cohen's kappa ( $\kappa$ ) | Correctly Classified | Incorrectly Classified |
|------------------|---------------|----------------------------|----------------------|------------------------|
| 100.00%          | 0.00%         | 1.000                      | 20000                | 0                      |

**Figura 7** - Matriz de Confusão do modelo Random Forest (100%) + XGBoost (100%).

**Tabela 2** - Resultados da Abordagem 1 (Classificação Supervisionada)

| Modelo        | Accuracy | Cohen's Kappa ( $\kappa$ ) |
|---------------|----------|----------------------------|
| Naive Bayes   | 94.05%   | 0.785                      |
| Random Forest | 100%     | 1.000                      |
| XGBoost       | 100%     | 1.000                      |

### 3.3. Análise Crítica dos resultados

A análise revelou uma descoberta notável. O modelo Naive Bayes, que é mais simples e assume independência entre as features, alcançou uma acurácia robusta de 94,06% e um Kappa "Substancial" de 0,786.

No entanto, os modelos avançados (Random Forest e XGBoost), que são desenhados para encontrar interações complexas e não-lineares, conseguiram um desempenho perfeito de 100% de Acurácia e 1.0 de Kappa no conjunto de teste. Testes adicionais com Validação Cruzada (Cross-Validation), representados na **Figura 9**, confirmaram este resultado ( $R^2=1$ , Erro=0), provando que isto não é overfitting, mas sim a captura de um padrão determinístico. Concluindo, as features de contexto (movimento, magnitude do movimento e tempo) são, por si sós, preditores perfeitos para o label de stress neste dataset.




Figura 8 - Testes de Classificação (Cross-Validation e AutoML).

|                                                                             |     |
|-----------------------------------------------------------------------------|-----|
| Statistics - 3:164:91 - Numeric Scorer                                      |     |
| File                                                                        |     |
| Can't calculate Mean Absolute Percentage error: target value is 0! Row80647 |     |
| R <sup>2</sup> :                                                            | 1   |
| Mean absolute error:                                                        | 0   |
| Mean squared error:                                                         | 0   |
| Root mean squared error:                                                    | 0   |
| Mean signed difference:                                                     | -0  |
| Mean absolute percentage error:                                             | NaN |
| Adjusted R <sup>2</sup> :                                                   | 1   |

Figura 9 - Numeric Scorer (Cross-validation de Classificação)

## 4. Abordagem 2 (Regressão Supervisionada) (Previsão de HR e EDA)

Como segunda abordagem, foi testada a capacidade de prever os indicadores fisiológicos (HR e EDA) usando todas as outras features (incluindo as de contexto e os outros sinais fisiológicos).




Figura 10 - Modelo Regressão HR.






Figura 12 -Resultados AutoML (Regressão HR).




Figura 13 - Resultados AutoML (Regressão HR) Continuação

Os resultados da regressão demonstram que modelos simples, como a Regressão Linear, conseguem explicar uma fração limitada da variabilidade dos sinais como HR ( $R^2 = 0.15$ ), o que sugere dependências não lineares complexas nas medições fisiológicas. Em contrapartida, métodos baseados em árvores como Random Forest e

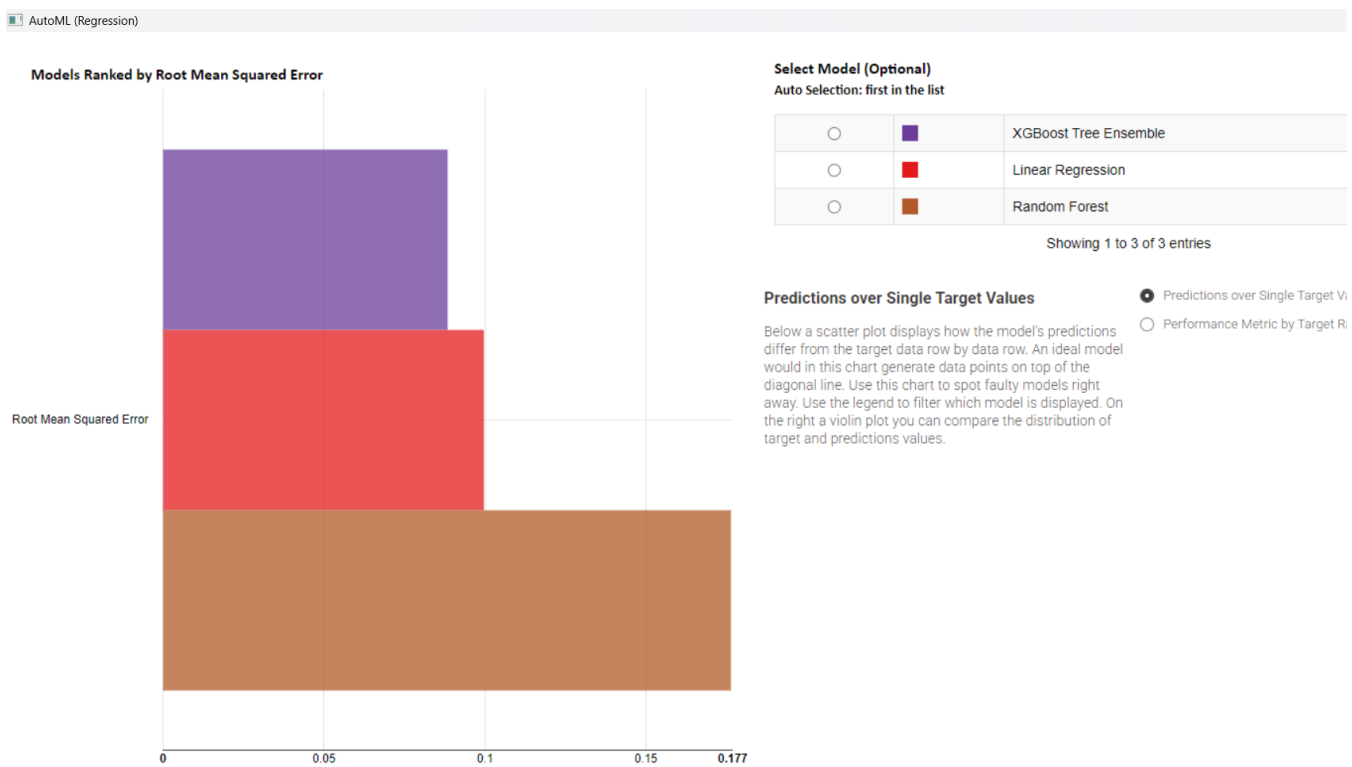
XGBoost atingiram desempenhos notáveis, especialmente para HR ( $R^2 > 0.93$ ) e EDA ( $R^2 > 0.98$ ), indicando elevada capacidade preditiva quando todas as features de contexto e fisiológicas são utilizadas.

O segundo workflow representa a regressão EDA e os seus resultados estão representados na **Tabela 4**.


**Tabela 4 – Resultados da Abordagem 2 (Regressão HR)**

| Modelo(Alvo: EDA) | $R^2$ | RMSE* |
|-------------------|-------|-------|
| Regressão Linear  | 0.996 | 0.104 |
| Random Forest     | 0.997 | 0.082 |
| XGBoost           | 0.997 | 0.089 |
| RProp MLP         | 0.985 | 0.026 |

\*O RMSE do MLP está na escala normalizada [0, 1] e não é diretamente comparável aos outros.



**Figura 12 - Resultados AutoML (Regressão EDA).**



**Figura 13 - Resultados AutoML (Regressão EDA) Continuação.**

O MLP aplicado ao EDA também revelou desempenho excecional, reforçando o papel das redes neuronais nos dados não-lineares. Estes resultados validam que sinais fisiológicos podem ser previstos com grande precisão a partir do contexto e das relações entre features biométricas, no entanto, alertando para possíveis correlações artificiais inerentes ao dataset.

## 4.2. Análise crítica dos resultados

A análise crítica dos resultados obtidos mostra a robustez dos modelos de regressão nos dados fornecidos. Modelos avançados como XGBoost e Random Forest conseguiram capturar relações complexas entre o contexto, movimento e sinais fisiológicos, garantindo alta precisão na previsão tanto do HR como da EDA.

O facto de a Regressão Linear ter tido um desempenho significativamente inferior para HR, contrastando com os restantes modelos, comprova que a relação entre as variáveis do dataset é fortemente não linear. O sucesso dos algoritmos de árvores está relacionado com a sua capacidade de modelar interações complexas e de explorar a redundância entre features fisiológicas.

Para EDA, todos os modelos, incluindo a Regressão Linear, apresentaram valores elevados de  $R^2$ , sugerindo que este sinal está fortemente correlacionado com outras



features presentes. Contudo, é importante referir que estes resultados refletem um ambiente fechado, onde todas as features fisiológicas estavam disponíveis. No contexto prático, resultados tão elevados dificilmente se reproduzem devido à variabilidade humana, limitações dos sensores, ou dados em tempo real com maior ruído.

Por fim, uma exploração futura deverá testar a capacidade de generalização destes modelos em novos dados, aplicar técnicas explainability (ex: SHAP, LIME) e avaliar potenciais fontes de data leakage ou redundância entre variáveis.

## 5. Abordagem 3 (Clustering Não-Supervisionado)

Finalmente, foi explorada uma metodologia não-supervisionada, representada na **Erro! A origem da referência não foi encontrada.**, para descobrir se os dados se




Figura 14 - Modelo de Clustering

agrupavam naturalmente em clusters.

### 5.1. Metodologia e Resultados

Foram comparados K-Means e K-Medoids (k=3) e avaliados pelo Silhouette Coefficient.

Os resultados médios do Silhouette Coefficient (numa escala de -1 a 1, onde valores mais altos são melhores) estão sintetizados na

**Tabela 5** – Resultados da Abordagem 3 (Clustering Não-Supervisionado)

| <b>Modelo</b>    | <b>Mean Silhouette Coefficient (Global)</b> | <b>Score Mínimo</b> | <b>Score Máximo</b> |
|------------------|---------------------------------------------|---------------------|---------------------|
| K-Means          | 0,1635                                      | -0,1615             | 0,4369              |
| <b>K-Medoids</b> | <b>0,1805</b>                               | <b>-0,1459</b>      | <b>0,3984</b>       |

## 5.2. Análise Crítica (Clustering)

O K-Medoids (Silhouette Médio = 0,1805) demonstrou um desempenho marginalmente superior ao K-Means (Silhouette Médio = 0,1635), o que pode ser atribuído à sua maior robustez a outliers nos dados dos sensores.

Contudo, ambos os coeficientes de silhueta são muito baixos (próximos de 0). Um score nesta magnitude indica que os clusters não estão bem definidos; pelo contrário, são difusos e têm uma sobreposição considerável. A presença de scores mínimos negativos (ex: -0,1615) confirma que uma porção dos pontos de dados foi provavelmente atribuída ao cluster errado.

Em suma, ao contrário da regressão supervisionada, a aprendizagem não-supervisionada revelou-se ineficaz. Os dados fisiológicos e de orientação, quando analisados sem um alvo, não se separam naturalmente em 3 grupos distintos. Isto sugere que os estados fisiológicos (como o stress) existem mais num ambiente contínuo, do que em grupos discretos e facilmente separáveis.

## 6. Conclusão

Este trabalho demonstrou a viabilidade da monitorização e previsão do stress profissional recorrendo a dados de sensores biométricos em ambiente hospitalar. A utilização de técnicas avançadas de classificação permitiu não só distinguir com elevada precisão os estados dos enfermeiros, mas também identificar os principais preditores envolvidos, em especial as variáveis de movimento e contextuais.

O desenvolvimento e otimização dos workflows em KNIME garantiu uma abordagem estruturada e replicável, apoiando a validação rigorosa dos modelos.

A regressão mostrou ser eficaz para antecipar variações fisiológicas, revelando a existência de padrões determinísticos nos dados recolhidos.

Contudo, constatou-se que, sem acesso direto aos sinais alvo, a tarefa de previsão se torna substancialmente mais desafiante, requerendo abordagens mais sofisticadas e robustas.

Além disso, a tentativa de aplicar métodos não-supervisionados evidenciou as dificuldades na segmentação natural dos dados fisiológicos, com coeficientes de silhueta baixos e clusters pouco definidos. Este resultado sugere que o stress, enquanto fenómeno fisiológico, tende a manifestar-se num continuum, dificultando a separação clara entre estados. Ainda assim, o clustering pode ser útil como ferramenta de suporte à análise exploratória e à formulação de hipóteses iniciais.

No geral, os resultados obtidos reforçam a importância da engenharia de features, da validação cruzada e da escolha criteriosa dos algoritmos. Evidenciam, igualmente, o potencial das tecnologias wearable para promover uma abordagem preventiva à saúde nas instituições.

Por fim, recomenda-se o alargamento dos estudos a conjuntos de dados maiores ou em tempo real, incluindo o uso de técnicas explicativas para interpretar melhor as decisões dos modelos e garantir ética e transparência no processo de IA aplicada à medicina.

Em suma, a inteligência artificial aplicada à telemetria biomédica apresenta-se como uma ferramenta promissora para gestão proativa do stress, contribuindo para ambientes de trabalho mais saudáveis e eficientes, com impacto direto na qualidade dos cuidados prestados. O aprofundamento destas metodologias poderá abrir caminho para intervenções automáticas e personalizadas em contextos clínicos.

## 7. Referências

A fundamentação teórica deste trabalho foi baseada nas monografias de referência da unidade curricular, conforme estipulado no enunciado. O dataset utilizado foi obtido a partir de um repositório público, fornecido pelo docente.

1. [Dataset] (2023). *Dataset for Continuous Stress Monitoring of Hospital Nurses*. Kaggle. Disponível em: <https://doi.org/10.34740/kaggle/dsv/7125235> (Acedido em 24/10/2025).
2. KNIME, <https://hub.knime.com/>. [Online] (acedido em 24/10/2025).