

Teoria da Informação e Digitalização

Serviços de Rede e Aplicações Multimédia

Mestrado em Engenharia de Telecomunicações e Informática

Ivo Miguel Menezes Silva

2º Semestre (25/26)

Adaptação dos slides originais do Prof. Bruno Dias (Dept. Informática – UMinho)

O que é a Informação? 🤔

- **Informação** = Redução de Incerteza
Quanto mais improvável algo é, mais informação temos ao sabê-lo!
- **Exemplo simples:** "Amanhã nasce o sol" = Pouca informação (certo)
- **vs.** "Vou ganhar na lotaria" = Muita informação (porque há incerteza!)

Claude Shannon (1916-2001)

Matemático e Engenheiro Americano
que revolucionou a Teoria da Informação
em 1948

- ✓ Criou o conceito de **BIT**
- ✓ Desenvolveu a **Entropia**
- ✓ Fundou a Criptografia Moderna

Shannon's Legacy

A informação é medível como
quantidade de bits




Teoria da Informação

Teorema Fundamental da Teoria da Informação

“Dado um **canal de comunicação** e uma **fonte de informação** cujo débito de informação não excede a capacidade do canal, existe um código tal que a informação pode ser transmitida através do canal com uma frequência de erros arbitrariamente pequena, apesar da presença de ruído no canal.”

Sistema de Comunicação

Fluxo de uma mensagem através de um sistema:



O BIT: Unidade de Informação

💡 CONCEITO-CHAVE

Um **BIT** é uma escolha entre 2 alternativas igualmente prováveis

Exemplos

- Cara ou Coroa 🪙
- Ligado ou Desligado ⚡
- 0 ou 1 🇧🇷
- Sim ou Não ?

Múltiplos bits

- 2 bits = 4 combinações (2^2)
- 3 bits = 8 combinações (2^3)
- 8 bits = 256 combinações (2^8)
- **N bits = 2^N combinações**

Bit como unidade de informação

Portanto, e por definição, a quantidade de informação, ou informação própria, I_i numa mensagem x_i é dada por:

$$I_i \stackrel{\text{def}}{=} \log_2 \frac{1}{P_i} \text{ [bits]}$$

Onde:

P_i representa a probabilidade de ocorrência do símbolo ou da mensagem x_i
 $\log_2$ faz com que a unidade seja o bit

Quando $P_i \rightarrow 0$, a informação I_i **AUMENTA** (ocorrência muito improvável)

Quando $P_i \rightarrow 1$, a informação I_i **DIMINUI** (ocorrência muito provável)

Entropia: Informação Média

DEFINIÇÃO FORMAL

ENTROPIA (H) = Quantidade média de bits necessários para codificar cada símbolo de uma fonte, considerando as probabilidades de ocorrência de cada símbolo

Assumir que uma fonte emite uma série de símbolos $X = \{x_1, \dots, x_m\}$ com probabilidades $\{P_1, \dots, P_m\}$

$$\mathcal{H}(X) = \sum_{i=1}^m P_i I_i = \sum_{i=1}^m P_i \log_2 \frac{1}{P_i} \text{ [bits/símbolo]}$$

Onde: $\sum_{i=1}$ =somatório de todos i símbolos | P_i = probabilidade do símbolo i | $\log_2$ logaritmo base 2, porque usamos bits



EXERCÍCIO 1: Entropia Binária

? Problema:

Uma fonte binária emite 2 símbolos: A com $P(A)=0.8$ e B com $P(B)=0.2$

Calcular a entropia desta fonte e discutir o resultado.

Quais os limites da entropia de uma fonte?

O valor da entropia depende:

- ✓ Das **probabilidades** dos símbolos
- ✓ Da **cardinalidade** (número de símbolos, m)

Então o limite da entropia é dado por:

$$0 \leq \mathcal{H}(X) \leq \log_2 m$$

Débito de Informação

DEFINIÇÃO

DÉBITO DE INFORMAÇÃO (R) = é a velocidade real a que a informação flui

$$R = r_s \mathcal{H}(X) \text{ [bits/seg]}$$

Onde:

r_s é a cadência de símbolos (símbolos/seg.)

$\mathcal{H}(X)$ é a entropia (quanta informação média cada símbolo carrega)

Exemplo Entropia e Débito de Informação


Exemplo 2:

Fonte emite 2000 símbolos/seg. de um alfabeto de 4 símbolos ($m=4$) com probabilidades apresentadas na tabela.

Qual a entropia? Qual o débito de informação?

x_i	P_i	I_i
A	1/2	1
B	1/4	2
C	1/8	3
D	1/8	3

Comprimento médio do código



$$\bar{N} = \sum_{i=1}^m P_i N_i \text{ [dig bin/símbolo]}$$

Onde:

$\bar{N}$ representa o número esperado de bits por símbolo

m é o número total de símbolos diferentes que a fonte pode gerar (o alfabeto da fonte)

P_i é a probabilidade de o símbolo i ocorrer

N_i é o comprimento (número de bits) da palavra de código atribuída a esse símbolo específico

Rendimento do Código



DEFINIÇÃO RENDIMENTO (ρ) O rendimento de uma codificação mede-se pela aproximação conseguida entre os valores numéricos do comprimento médio do código e da entropia da fonte

$$\rho = \frac{\mathcal{H}(X)}{\bar{N}} \leq 1$$

Onde:

$\mathcal{H}(X)$ representa a entropia, ou seja, o limite mínimo teórico de bits necessários para representar a fonte sem perda de informação.

$\bar{N}$ é o comprimento médio do código, ou seja, o número de bits que o código realmente utiliza em média.

Compressão



DEFINIÇÃO COMPRESSÃO (c) = compressão relativa (em percentagem)

A compressão obtida numa determinada codificação da fonte mede-se pela redução percentual do número médio de dígitos, $\bar{N}$, de dígitos binários por símbolo relativamente à codificação da mesma fonte, se esta fosse feita com o código de comprimento fixo mínimo N_f .

$$c = \frac{N_f - \bar{N}}{N_f} \times 100\%$$

Onde:

c indica a percentagem de bits que “poupamos” ao enviar a informação

N_f codificação com um código de comprimento fixo.

$\bar{N}$ é o comprimento médio do código



EXERCÍCIO 2: Rendimento do Código

Uma fonte com 4 símbolos (A, B, C, D) tem entropia $H = 1.8$ bits/símbolo

Comparar dois códigos:

- Código 1: comprimento médio $N_1 = 2$ bits
- Código 2: comprimento médio $N_2 = 1.9$ bits



EXERCÍCIO 3

Exemplo: diferentes codificações para uma fonte que gera quatro símbolos (entropia 1.75 bits/símbolo)
Determinar comprimentos médios e rendimentos dos códigos?

x_i	P_i	Código I	Código II	Código III	Código IV
A	1/2	00	0	0	0
B	1/4	01	1	01	10
C	1/8	10	10	011	110
D	1/8	11	11	0111	111
$\bar{N}$		2.0	1.25	1.875	1.75

Códigos de Shannon-Fano/Huffman e variantes

- ✓ Podem ser usados para construir códigos decifráveis
- ✓ Geram códigos de comprimento variável
- ✓ Geram códigos com “bom” rendimento
- ✓ Algoritmos para geração de códigos?

Vamos analisar um dos algoritmos mais simples para construção de códigos deste tipo:

Códigos de Shannon-Fano

Códigos de Shannon-Fano

Propriedades Fundamentais

- ✓ Código de Kraft-McMillan: univocamente decifrável, obedece à desigualdade de Kraft: $Kr = \sum_{i=1}^m 2^{-N_i} \leq 1$
- ✓ Comprimento médio $\bar{N}$ satisfaz: $\mathcal{H}(X) \leq \bar{N} < \mathcal{H}(X) + 1$
- ✓ Rendimento típico 95-98%

🎯 ALGORITMO DE CONSTRUÇÃO

1. Ordenar símbolos por ordem decrescente de probabilidade
2. Dividir lista ordenada em dois grupos tais que, a soma das probabilidades em cada um deles seja metade da soma das probabilidades do conjunto anterior. Manter ordenação.
3. O dígito seguinte do código binário dos símbolos do primeiro dos sub-conjuntos é o 0 e o dos símbolos do outro sub-conjunto é o 1
4. Se os sub-conjuntos contêm um só elemento, a codificação terminou para esses sub-conjuntos
5. Repetir para cada um dos restantes sub-conjuntos (passo 2)

Condições Importantes (Shannon-Fano)

Código *prefix free* (livre de prefixo)

- Nenhuma palavra-código pode ser prefixo de outra.
- Isto garante que a descodificação é imediata e sem ambiguidades.

Probabilidade maior → código mais curto

- Símbolos (ou blocos) mais prováveis devem receber menos bits.
- Símbolos menos prováveis recebem códigos mais longos.

Divisões devem ser o mais equilibradas possível

- Em cada passo, os grupos devem ter somas de probabilidade semelhantes, mas nem sempre é possível obter uma divisão exatamente a meio.

Existem vários códigos Shannon–Fano válidos

- Dependendo de como são feitas as divisões (quando há empates ou escolhas próximas), podem existir diferentes códigos corretos para o mesmo alfabeto e blocos.

O código final não é necessariamente ótimo

- Shannon–Fano produz um código eficiente, mas o código de Huffman pode gerar compressão igual ou melhor.



EXERCÍCIO: Codificação da Fonte

Aplicar o algoritmo anterior para codificar a fonte com oito símbolos ($m=8$).

Determinar: Entropia, código, comprimento médio, rendimento e compressão.

x_i	A	B	C	D	E	F	G	H
P_i	0.50	0.15	0.15	0.08	0.08	0.02	0.01	0.01

x_i	P_i	Passos de Codificação						Código
		1	2	3	4	5	6	
A	0.50	0						0
B	0.15	1	0	0				100
C	0.15	1	0	1				101
D	0.08	1	1	0				110
E	0.08	1	1	1	0			1110
F	0.02	1	1	1	1	0		11110
G	0.01	1	1	1	1	1	0	111110
H	0.01	1	1	1	1	1	1	111111

© iSilva 2025



EXERCÍCIO: Codificação da Fonte

Um canal de comunicação recebe os dados (binários) transmitidos por 10 destas fontes de informação. Cada fonte emite, em média, 200 símbolos por segundo. Considere que os codificadores das fontes usam o código de tamanho variável calculado anteriormente. Ao fim de 10 horas de operação, quantos bytes “poupamos” na transmissão no canal?

x_i	A	B	C	D	E	F	G	H
P_i	0.50	0.15	0.15	0.08	0.08	0.02	0.01	0.01

x_i	P_i	Passos de Codificação						Código
		1	2	3	4	5	6	
A	0.50	0						0
B	0.15	1	0	0				100
C	0.15	1	0	1				101
D	0.08	1	1	0				110
E	0.08	1	1	1	0			1110
F	0.02	1	1	1	1	0		11110
G	0.01	1	1	1	1	1	0	111110
H	0.01	1	1	1	1	1	1	111111

Codificação por blocos

- Agrupar símbolos da fonte e proceder à sua codificação
- Daí a noção de "bloco"
- Blocos de K símbolos
- Normalmente leva a melhorias no rendimento do código...
- ... e na compressão obtida

Exemplos reais: JPEG ; MP3 ; vídeo 

Exemplo: Fonte c/ dois símbolos

Fonte emite símbolos de um alfabeto X com apenas dois símbolos

- Entropia=0.722 bits/símbolo

Novo alfabeto Y com K=2 (agrupar símbolos em blocos)

- Por se tratar de uma fonte sem memória
- Ou seja, símbolos estatisticamente independentes
- Assim temos:
 - $P(AA) = 0.64$, $P(AB) = P(BA) = 0.16$, $P(BB) = 0.04$



EXERCÍCIO: Código Shannon-Fano para Y

Para a fonte anterior com $K=2$, calcular o código (tabela de probabilidades/palavras de código), o comprimento médio, rendimento e compressão.

y_i	P_{y_i}	Código
AA	0.64	0
AB	0.16	11
BA	0.16	100
BB	0.04	101
$\bar{N}_2 = 1.56$		

Rendimento e compressão (K=3)

Bloco	Cálculo de Probabilidade	Prob. (Pi)	Código
AAA	$0.8 \times 0.8 \times 0.8$	0.512	0
AAB	$0.8 \times 0.8 \times 0.2$	0.128	100
ABA	$0.8 \times 0.2 \times 0.8$	0.128	101
BAA	$0.2 \times 0.8 \times 0.8$	0.128	110
ABB	$0.8 \times 0.2 \times 0.2$	0.032	11100
BAB	$0.2 \times 0.8 \times 0.2$	0.032	11101
BBA	$0.2 \times 0.2 \times 0.8$	0.032	11110
BBB	$0.2 \times 0.2 \times 0.2$	0.008	11111

Comprimento Médio (K=3), alfabeto Z={AAA, AAB, ..., BBB}

$$\bar{N}_3 = 0.512 \times 1 + 0.128 \times 3 \times 3 + 0.032 \times 3 \times 5 + 0.008 \times 5 = 2.184 \text{ dígitos binários/bloco}$$

$$\bar{N} = \frac{\bar{N}_3}{K} = 2.184/3 = 0.728 \text{ bits/símbolo}$$

Rendimento e compressão (K=3)

Rendimento e Compressão (K=3)

$$\rho = \frac{\mathcal{H}(X)}{\bar{N}} = \frac{0.722}{0.728} = 0.9918, \quad c = \frac{N_f - \bar{N}}{N_f} \times 100 = \frac{1 - 0.728}{1} \times 100 = 27.2\%$$

O que está a acontecer ao comprimento médio dos códigos?

K=1 (sem blocos)

$$\bar{N} = 1, \quad \rho = 0.722, \quad c = 0\%$$

K=2

$$\bar{N} = 0.780, \quad \rho = 0.926, \quad c = 22\%$$

K=3

$$\bar{N} = 0.728, \quad \rho = 0.9918, \quad c = 27.2\%$$

À medida que K aumenta, o comprimento médio $\bar{N}$ diminui (aproxima-se da entropia), o rendimento ρ aumenta e a compressão c também aumenta

Teorema da Teoria de Informação

Toda a fonte de informação caracterizada por um valor da entropia $\mathcal{H}(X)$ bits/símbolo, pode ser codificada em binário de tal forma que o comprimento médio do código, $\bar{N}$, é limitado por:

$$\mathcal{H}(X) \leq \bar{N} < \mathcal{H}(X) + \varepsilon$$

Na codificação por blocos temos $\varepsilon = \frac{1}{K}$

Código ideal será aquele em que $\varepsilon = 0$; na prática nem sempre é possível sendo satisfatório um código que possua bom rendimento.

Fontes com Memória

DEFINIÇÃO

Uma fonte onde a probabilidade do próximo símbolo depende dos símbolos anteriores.

EXEMPLO

Em português, após a letra "Q" vem quase sempre a letra "U"

IMPLICAÇÃO

Podemos explorar estas dependências para compressão e eficiência

Comparação SEM vs COM Memória

Sem memória

$P(X_i) = P(x)$ a probabilidade de o símbolo X_i aparecer é fixa (independente do passado)

Com memória

$P(X_i|X_j) = P_{X_i|X_j} = P(i|j) = P_{i|j}$ é a probabilidade de o símbolo X_i aparecer depois do símbolo X_j

Fontes com memória de primeira ordem

- $P(X_i|X_j) = P_{X_i|X_j} = P(i|j) = P_{i|j}$ é a probabilidade de o símbolo X_i aparecer depois do símbolo X_j .
- $P(X_iX_j) = P_{X_iX_j} = P(ij) = P_{ij}$ é a probabilidade da ocorrência da **mensagem** contendo o símbolo X_i a seguir ao símbolo X_j (os símbolos mais à direita aparecem primeiro na fonte).
- $P'(X_i) = P'_{X_i} = \sum_{i=1}^N \sum_{j=1}^N (P_{X_j} * P_{X_i|X_j})$ é a probabilidade condicional da ocorrência do símbolo X_i tendo em consideração a memória da fonte com N símbolos.

Fontes com memória de primeira ordem

Informação Própria Condicional do símbolo X_i :

$$I'(X_i) = I'_{X_i} = \sum_{j=1}^N (P_{j|i} * \log_2 \frac{1}{P_{j|i}})$$

Onde:

$P_{j|i}$ representa a probabilidade condicional do símbolo j ocorrer, dado que o símbolo i ocorreu anteriormente

Entropia Condicional (ou Entropia Real) numa fonte com memória de primeira ordem e cardinalidade N :

$$\mathcal{H}' = \sum_{i=1}^N (P_i * I'_{X_i}) \text{ [bits/símbolo]}$$

Nas tabelas de Shannon-Fano utilizam-se blocos de dois símbolos $X_i X_j$.

Entropia condicional é SEMPRE menor que a entropia clássica de Shannon, porque há redundância (parte da informação do símbolo atual está contida no símbolo anterior).

Fontes com memória de ordem M

Redundância em Fontes com Memória

Quando as probabilidades condicionais reduzem significativamente a entropia, a fonte é redundante. Nestes casos, métodos por dicionário (ex: LZ77, LZ78) são mais eficientes que os métodos puramente estatísticos como os de Shannon-Fano ou Huffman.

Compressão com Perdas (Lossy)

Em muitas fontes, a codificação com perda de alguma informação (sistemas de compressão lossy) pode ser considerada uma melhor alternativa.

Mecanismos/algoritmos de compressão

1010
1010
Lossless

Permitem recuperar **todos** os dados originais a partir do ficheiro comprimido.

● ● ● ●
● ● ● ●
● ● ● ●
Lossy

Só permitem recuperar uma **aproximação** dos dados do ficheiro original.

Os algoritmos mais eficientes são os desenhados para lidar com tipos de dados específicos, tendo em consideração as características próprias desses dados.

Mecanismos/algoritmos de compressão

Lossless

 Geral: RLE, LZ78, LZW, LZF, DEFLATE, bzip2, LZMA, Brotli, 7z, etc.

 Áudio: LDAC, ALAC, ATRAC, DST, FLAC, RealPlayer, TTA, WavPack, WMA Lossless, etc.

 Gráficos: PNG, TIFF, TGA, PCX, ILBM, JBIG2, etc.

 Vídeo: Dirac Lossless, FFV1, H.264 Lossless, etc.

Lossy

 Gráficos: JPEG, JPEG2000, DjVu, JBIG2, PGF, etc.

 Vídeo: Motion JPEG, H.264/MPEG-4 AVC, Dirac, VC-1, H.265/HEVC, etc.

 Áudio : AAC, ADPCM, ATRAC, Dolby Digital (AC-3), MP2, MP3, Musepack, Ogg Vorbis, WMA Lossy, etc.

 Voz: Adaptive Multi-Rate, Codec2, Speex, etc.

O canal de transmissão/comunicação

O ritmo máximo teórico de símbolos que é possível transmitir num canal de transmissão depende da largura de banda (B_T) e é dado pelo ritmo de *Nyquist* (r_s):

$$r_s \leq 2 * B_T$$

Por outro lado, a capacidade real do canal de transmissão dependente da relação entre a potência do sinal e da potência do ruído e da largura de banda de transmissão (Teorema de *Hartley-Shannon*):

$$C = B_T * \log_2(1 + \frac{S}{N}), \text{ em que } N = \eta * B_T$$

Teoria da Informação

Teorema Fundamental da Teoria da Informação

“Dado um **canal de comunicação** e uma **fonte de informação** cujo débito de informação não excede a capacidade do canal, existe um código tal que a informação pode ser transmitida através do canal com uma frequência de erros arbitrariamente pequena, apesar da presença de ruído no canal.”

Teoria da Informação

17 Equations That Changed the World by Ian Stewart		
1. Pythagoras's Theorem	$a^2 + b^2 = c^2$	Pythagoras, 530 BC
2. Logarithms	$\log xy = \log x + \log y$	John Napier, 1610
3. Calculus	$\frac{df}{dt} = \lim_{h \rightarrow 0} \frac{f(t+h) - f(t)}{h}$	Newton, 1668
4. Law of Gravity	$F = G \frac{m_1 m_2}{r^2}$	Newton, 1687
5. The Square Root of Minus One	$i^2 = -1$	Euler, 1750
6. Euler's Formula for Polyhedra	$V - E + F = 2$	Euler, 1751
7. Normal Distribution	$\Phi(x) = \frac{1}{\sqrt{2\pi}\rho} e^{-\frac{(x-\mu)^2}{2\rho^2}}$	C.F. Gauss, 1810
8. Wave Equation	$\frac{\partial^2 u}{\partial t^2} = c^2 \frac{\partial^2 u}{\partial x^2}$	J. d'Alembert, 1746
9. Fourier Transform	$f(\omega) = \int_{-\infty}^{\infty} f(x) e^{-2\pi i x \omega} dx$	J. Fourier, 1822
10. Navier-Stokes Equation	$\rho \left(\frac{\partial \mathbf{v}}{\partial t} + \mathbf{v} \cdot \nabla \mathbf{v} \right) = -\nabla p + \nabla \cdot \mathbf{T} + \mathbf{f}$	C. Navier, G. Stokes, 1845
11. Maxwell's Equations	$\nabla \cdot \mathbf{E} = \frac{\rho}{\epsilon_0}$ $\nabla \times \mathbf{E} = -\frac{1}{c} \frac{\partial \mathbf{H}}{\partial t}$ $\nabla \cdot \mathbf{H} = 0$ $\nabla \times \mathbf{H} = \frac{1}{c} \frac{\partial \mathbf{E}}{\partial t}$	J.C. Maxwell, 1865
12. Second Law of Thermodynamics	$dS \geq 0$	L. Boltzmann, 1874
13. Relativity	$E = mc^2$	Einstein, 1905
14. Schrodinger's Equation	$i\hbar \frac{\partial}{\partial t} \Psi = H\Psi$	E. Schrodinger, 1927
15. Information Theory	$H = -\sum p(x) \log p(x)$	C. Shannon, 1949
16. Chaos Theory	$x_{t+1} = kx_t(1 - x_t)$	Robert May, 1975
17. Black-Scholes Equation	$\frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} + \frac{\partial V}{\partial t} - rV = 0$	F. Black, M. Scholes, 1990

